Lecture 1 数据要素与数据经济

谢佳松

东北财经大学

Fall 2026

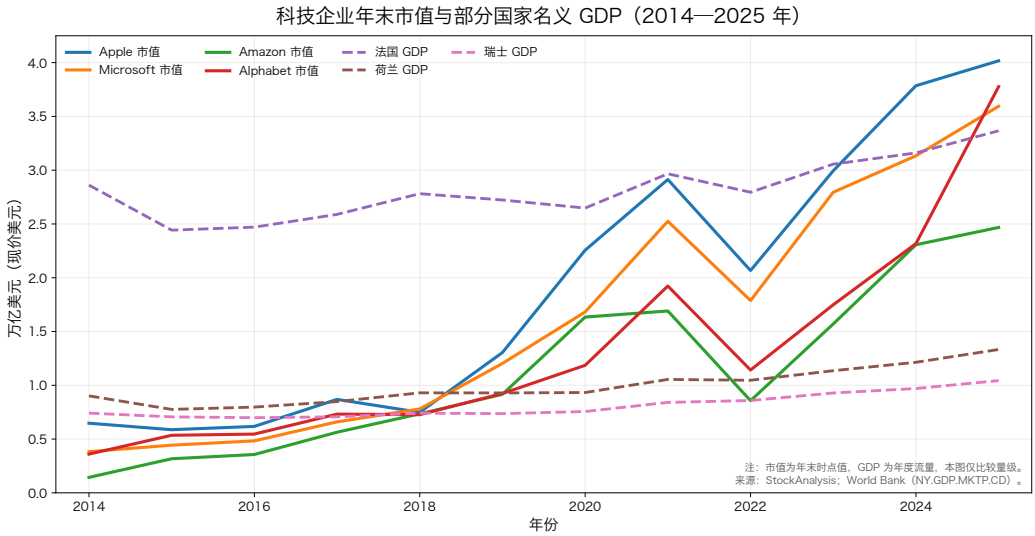
目录

1. 楔子：21 世纪的“新石油”
2. 数据与传统经济学理论
3. 数据的特征
4. 《数据要素理论与实践》课程安排
5. 课程考核方式

数据：21 世纪的“新石油”

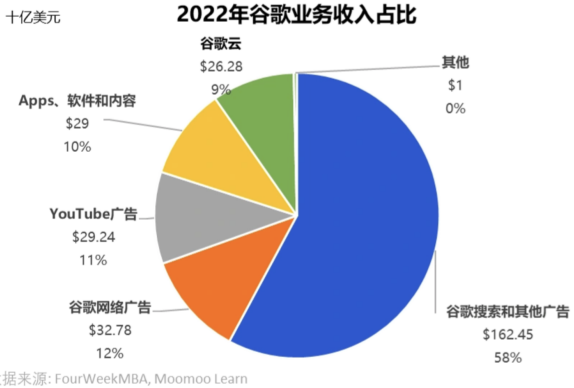
- 全球经济中最有价值的公司的价值很大程度上取决于它们拥有的数据。Amazon、Google、Apple 和其他科技公司的市值已经超过了许多小国的总资产。
- Google 每天处理超过 20 PB（即 2,000 TB）数据，相当于每分钟处理约 2 百万 GB 数据。其数据基础设施可处理每秒 13 PB 带宽，换算成视频通话带宽，足以同时服务全球 80 亿人。
- Amazon Simple Storage Service （S3, 简易储存服务）是 Amazon 提供的一项网络在线存储服务，通过 Web 服务接口，用户能够轻易把文件存储到网络服务器上。截止至 2024 年 11 月，Amazon 存储规模超过 400 万亿（400 trillion）对象。

数据：21 世纪的“新石油”


科技企业年末市值与部分国家名义 GDP（2014—2025 年）
Apple 市值
Microsoft 市值
Amazon 市值
Alphabet 市值
法国 GDP
荷兰 GDP
瑞士 GDP
万亿美元（现价美元）
年份
0.0
0.5
1.0
1.5
2.0
2.5
3.0
3.5
4.0
2014
2016
2018
2020
2022
2024
注：市值为年末时点值，GDP 为年度流量，本图仅比较量级。
来源：StockAnalysis；World Bank（NY.GDP.MKTP.CD）。

Google

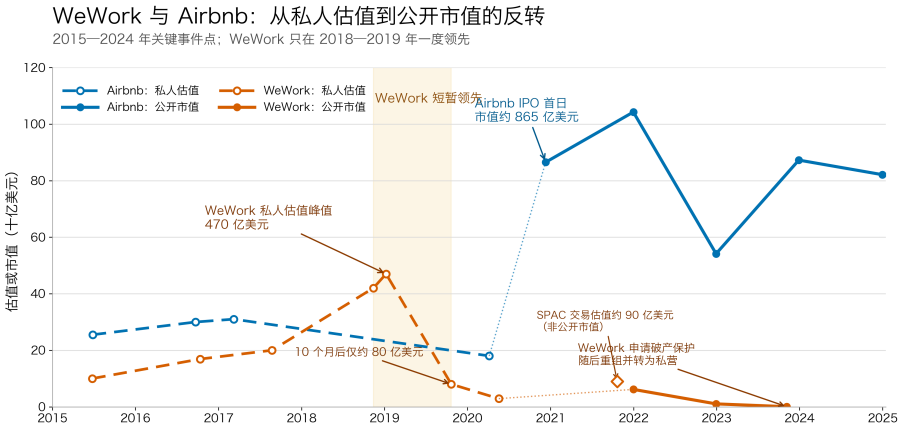

十亿美元
谷歌市值：从在线搜索到综合性科技巨头
2000
1500
1000
500
0
2004年
谷歌上市
发布Gmail
2006年
收购YouTube
2008年
发布Chrome
发布安卓操作系统
发布谷歌云
2012年
发布Google Drive
2014年
收购DeepMind
2015年
重组成Alphabet Inc
2017年
设立Google AI
2018年
发布BERT
2023年
发布 Google Bard AI
2004/09
2005/07
2006/05
2007/03
2008/01
2008/11
2009/09
2010/07
2011/05
2012/03
2013/01
2013/11
2014/09
2015/07
2016/05
2017/03
2018/01
2018/11
2019/09
2020/07
2021/05
2022/03
2023/01
数据来源： Bloomberg, Officetimeline, Moomoo Learn


十亿美元
2022年谷歌业务收入占比
谷歌云
$26.28
9%
其他
$1
0%
Apps、软件和内容
$29
10%
YouTube广告
$29.24
11%
谷歌网络广告
$32.78
12%
谷歌搜索和其他广告
$162.45
58%
数据来源: FourWeekMBA, Moomoo Learn

为什么当今数据变得如此重要?

- **历史上：**高价值公司依赖高价值实物资产（工厂、办公室、设备）。
  - 20 世纪的通用汽车（General Motors）与通用电气（GE），依靠庞大工厂和设备成为全球市值最高的公司之一。
- **当今：**拥有高精度设备与优质办公地产的公司仍然创造价值，但**数据才是长期竞争优势来源**。
  - WeWork 即使拥有全球高端办公空间，但因缺乏数据壁垒，市值暴跌；对比之下，Airbnb 凭借用户数据和算法，市值超越许多传统地产巨头。Why?

WeWork V.S Airbnb



注：虚线空心点=上市前融资/交易隐含估值；实线实心点=上市后公开市值。两种口径不可严格等同，本图仅比较数量级与相对走势。
菱形为 WeWork 上市时的 SPAC 交易估值（不是市值）。WeWork 2023 年 11 月申请 Chapter 11，2024 年 6 月重组后转为私营，故曲线终止而非记为 0。
来源：Reuters、CNBC、WSJ、TechCrunch、公司公告及 StockAnalysis；详细链接见配套 CSV。

为什么当今数据变得如此重要?

- **原因一：数据存储成本持续下降**：云计算与分布式存储让企业可以低成本保存和处理海量数据。
  - 云计算：通过互联网按需提供计算、存储、网络、数据库和软件等 IT 资源的服务模式。
  - 分布式存储：将数据分散存储在多台独立服务器（节点）上，并通过网络协同工作，对外提供统一存储能力的系统架构。

为什么当今数据变得如此重要?

- **原因一：数据存储成本持续下降**：云计算与分布式存储让企业可以低成本保存和处理海量数据。
  - 云计算：通过互联网按需提供计算、存储、网络、数据库和软件等 IT 资源的服务模式。
  - 分布式存储：将数据分散存储在多台独立服务器（节点）上，并通过网络协同工作，对外提供统一存储能力的系统架构。
- **原因二：数据科学进步使数据价值提升**：AI、机器学习、高级算法让原本“沉睡”的数据转化为预测和决策能力。
  - 算法：处理这些数据、解决具体问题的核心大脑，赋予了机器思考和决策的能力。
  - 案例： Google 通过搜索与广告点击数据训练推荐模型，每年带来超过 **2,000 亿美元广告收入**。

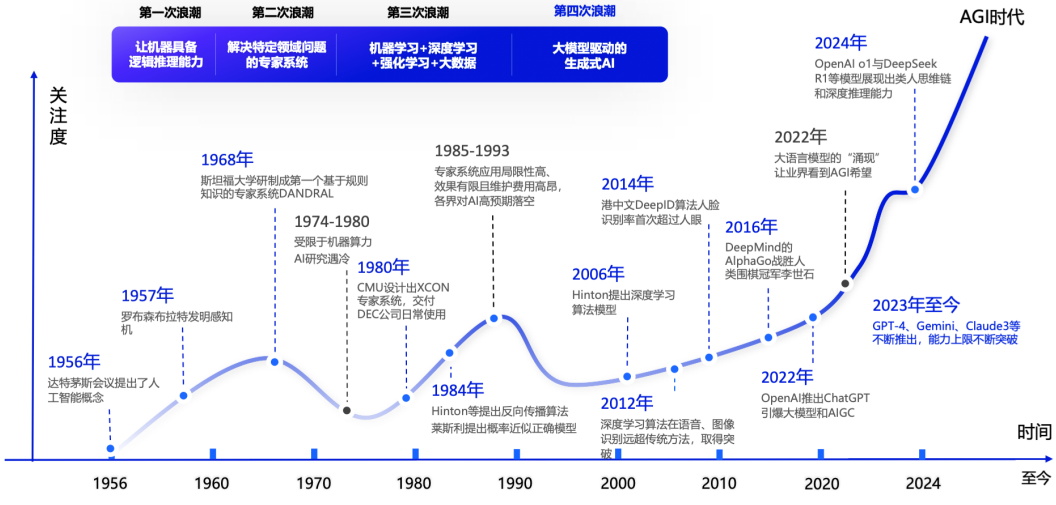
为什么当今数据变得如此重要？

- **原因一：数据存储成本持续下降**：云计算与分布式存储让企业可以低成本保存和处理海量数据。
  - 云计算：通过互联网按需提供计算、存储、网络、数据库和软件等 IT 资源的服务模式。
  - 分布式存储：将数据分散存储在多台独立服务器（节点）上，并通过网络协同工作，对外提供统一存储能力的系统架构。
- **原因二：数据科学进步使数据价值提升**：AI、机器学习、高级算法让原本“沉睡”的数据转化为预测和决策能力。
  - 算法：处理这些数据、解决具体问题的核心大脑，赋予了机器思考和决策的能力。
  - 案例： Google 通过搜索与广告点击数据训练推荐模型，每年带来超过 **2,000 亿美元广告收入**。
- **原因三：数据传输更快、成本更低**：光纤骨干网、5G 与海底光缆等数据传输基础设施的不断升级，让海量数据得以近实时、跨地域地传输与调用，数据得以真正“流动”起来并创造价值。
  - 光纤骨干网络：光信号在光纤中以接近光速（约每秒 20 万公里）传播，单纤带宽已达 Tbps 量级，是数据中心互联与全球互联网传输的物理主干。
  - 5G 与移动互联网：高带宽、低时延的移动网络把数据的采集与传输延伸到海量终端，支撑实时交互与万物互联。

数据储存成本下降与数据科学进步

- Netflix 依靠云计算服务处理全球数百万用户的流媒体数据。Netflix 通过分布式存储系统存储视频内容、用户数据和推荐算法生成的元数据，处理高峰时段的巨大流量。
- Airbnb 使用云服务管理其全球房东和租客网络的数据。分布式存储系统支持用户上传的图片、房源信息和交易记录，能够快速扩展以应对需求波动。
- Walmart 利用云计算（Microsoft Azure）和分布式存储（Hadoop HDFS）处理每日数亿笔交易数据，用于库存管理、供应链优化和客户行为分析。Walmart 的数据湖存储了 PB 级数据，包括销售记录、供应链物流和客户偏好，通过分布式架构实现高效查询和分析。
- Uber 使用 Google Cloud Platform（GCP）和 Apache Kafka 处理实时地理位置数据、司机行程记录和用户请求。分布式存储系统（如 Google Cloud Storage 和 BigTable）存储 PB 级的位置数据和历史行程，支持实时定价、路线优化和需求预测。

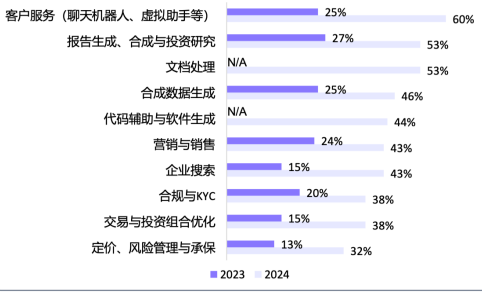
AI、算法与大型语言模型的发展：数据价值的新高地



AI、算法与大型语言模型的发展：数据价值的新高地

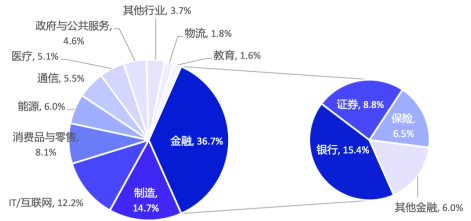
国际金融机构正积极将生成式AI运用于核心业务场景

- 根据英伟达调研，**52%**的机构已经在应用生成式AI，**98%**的机构表示将在2025年进一步加大AI基础设施投入
- 2024年相比2023年，AI在各个业务场景的渗透率大幅提升
- **核心的交易与投资组合优化、风险管理等场景，渗透率超30%**



国内金融行业是大模型落地的先行者

2024年大模型落地案例占比达**36.7%**。银行业具备较好的数字化转型基础，是资金、人才和知识密集型行业，具有大模型应用的先天优势，是国内大模型落地占比最高的行业。



数据来源：NVIDIA《State of AI in Financial Services: 2025 Trends》，沙丘智库《2025年中国银行业大模型应用跟踪报告》

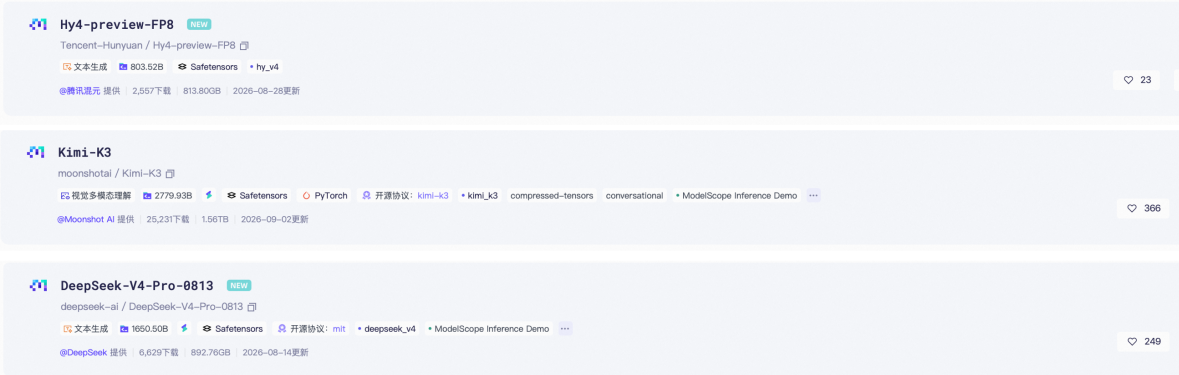
AI、算法与大型语言模型的发展：数据价值的新高地

- **大型语言模型（LLM）的崛起**：依赖数万亿词的训练数据与超大算力。
  案例：OpenAI GPT 系列、Google Gemini、Anthropic Claude、Deepseek 等，模型参数规模已超千亿甚至万亿级。

- **数据成为核心资产**：LLMs 的性能与训练数据质量高度相关。ChatGPT 的成功离不开大规模网页、书籍与对话数据。

- **数据壁垒与数据经济**：拥有独特数据的企业在 AI 时代具备持续优势。
  案例：特斯拉凭借车联网数据训练自动驾驶；抖音（TikTok）凭借海量用户交互数据优化推荐算法。

国内大模型的发展


Hy4-preview-FP8
NEW
Tencent-Hunyuan / Hy4-preview-FP8
文本生成
803.52B
Safetensors
hy_v4
@腾讯混元 提供
2,557下载
813.80GB
2026-08-28更新
23
Kimi-K3
moonshotai / Kimi-K3
视觉多模态理解
2779.93B
Safetensors
PyTorch
开源协议：kimi-k3
kimi_k3
compressed-tensors
conversational
ModelScope Inference Demo
@Moonshot AI 提供
25,231下载
1.56TB
2026-09-02更新
366
DeepSeek-V4-Pro-0813
NEW
deepseek-ai / DeepSeek-V4-Pro-0813
文本生成
1650.50B
Safetensors
开源协议：mit
deepseek_v4
ModelScope Inference Demo
@DeepSeek 提供
6,629下载
892.76GB
2026-08-14更新
249

数据与传统经济学

一、数据与传统经济学理论

数据与传统经济学

- 尽管数据作为一种战略资产的重要性日益增强，但现代教科书上的宏观经济学和金融学理论却忽视了它的作用。
- 传统经济学框架：劳动与物质资本结合，生产的商品或服务具有“竞争性”和“排他性”，只能由一个消费者使用。典型模型：
  - 新古典增长模型（Solow 模型）：产出仅依赖资本与劳动。
  - IS-LM 模型：分析宏观总需求与总供给，忽略数据在市场信息与投资决策中的作用。
  - RBC（实际经济周期模型）：技术冲击驱动经济波动，但未将数据作为独立的生产要素或信息载体。

数据与传统经济学

- 尽管数据作为一种战略资产的重要性日益增强，但现代教科书上的宏观经济学和金融学理论却忽视了它的作用。
- 传统经济学框架：劳动与物质资本结合，生产的商品或服务具有“竞争性”和“排他性”，只能由一个消费者使用。典型模型：
  - 新古典增长模型（Solow 模型）：产出仅依赖资本与劳动。
  - IS-LM 模型：分析宏观总需求与总供给，忽略数据在市场信息与投资决策中的作用。
  - RBC（实际经济周期模型）：技术冲击驱动经济波动，但未将数据作为独立的生产要素或信息载体。
- 当今“知识经济”中：企业可通过收集、挖掘、交易数据来增加价值，表现与传统资本-劳动模式完全不同。
- 数据驱动的企业增长方式：
  - 平台经济（如亚马逊、阿里巴巴）：通过数据匹配供需。
  - 数字广告（如 Google、Meta）：利用数据精准定价广告服务。
- 思考：若将数据纳入生产函数，数据是否应被视为新的生产要素？如何影响 GDP 测算与经济周期？

Solow 模型：揭示经济增长期规律

- 1956 年由 Robert Merton Solow 提出，是新古典经济增长理论的代表。
- 核心思想：长期经济增长由资本积累、劳动供给与技术进步驱动。
- 生产函数：

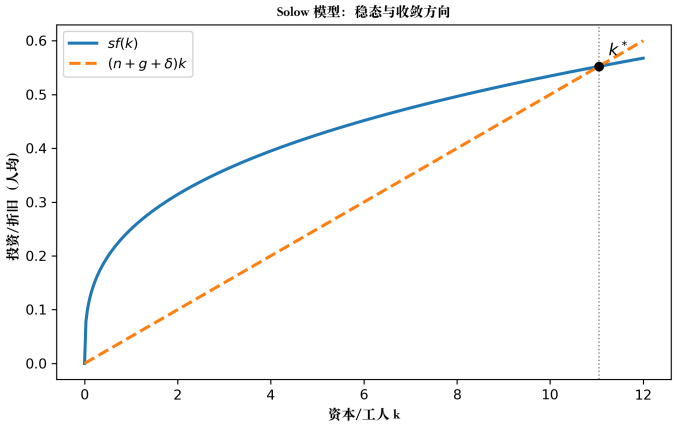
$$Y(t) = F(K(t), L(t), A(t)) = K(t)^{\alpha} \left[A(t)L(t)\right]^{1-\alpha}, \quad 0 < \alpha < 1$$

- 动态方程：资本积累

$$\dot{K}(t) = sY(t) - \delta K(t)$$

  其中 s 为储蓄率，δ 为折旧率。
- 结论：经济最终收敛到稳态 $k^* = \frac{s}{\delta+n+g}$，人均产出增长仅由技术进步率参数 g 决定。
- 仅靠提高储蓄率或增加资本投入，只能暂时提升增长速度，但无法实现永久的人均增长。
- 局限：模型中没有数据要素，忽视了信息与数据在生产率提升中的作用。

Solow 模型：稳态与收敛



- 生产函数：$y = f(k) = k^{\alpha}$，投资 $sf(k)$ 与折旧/扩张 $(n+g+\delta)k$ 的交点给出稳态 k^*。
- 若 $k < k^*$：$sf(k) > (n+g+\delta)k$，资本积累 $\Rightarrow k\uparrow$；反之 $k\downarrow$。
- 稳态下人均资本与人均产出保持常数增长（若 $g > 0$）。
- 用途：解释长期收入差异与收敛路径（政策变量 s, n, δ 的作用）。

Solow 模型的局限性

- **遗漏数据要素**：生产函数仅包含资本 K 与劳动 L，未将数据纳入。而在当今数字经济中，数据已成为驱动增长的核心生产要素。
- **忽视数据的独特属性**：模型假设要素边际报酬递减，但数据具有非竞争性与可复用性——同一份数据可被多人同时使用，复用边际成本几乎为零，与资本、劳动的属性完全不同。
- **无法刻画数据反馈循环**：数据 × 算法形成正反馈（更多数据 → 更强模型 → 吸引更多数据），平台企业呈超线性增长；而 Solow 模型的稳态收敛逻辑难以解释这一动态。
- **生产率悖论**：Solow 曾感叹"计算机时代随处可见，但在生产率统计中却无迹可寻"。今天 AI 与大模型同样面临测算难题——数据驱动的产出常以免费服务或质量提升呈现，传统 GDP 与生产率统计难以衡量。
- **技术进步被外生化**：Solow 模型将技术进步率参数 g 视为外生给定；但在数据经济中，技术进步（尤其是 AI）恰恰源自数据的积累与利用，应被内生化。

IS-LM 模型: 理解短期宏观经济波动与政策效果

- 核心思想：短期宏观均衡由产品市场（IS 曲线）和货币市场（LM 曲线）的相交决定。
- IS 曲线：商品市场均衡

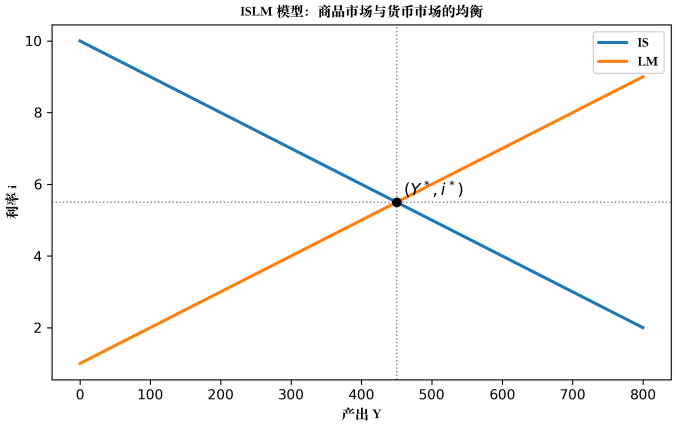
$$Y = C(Y - T) + I(r) + G$$

- LM 曲线：货币市场均衡

$$M/P = L(Y, r)$$

- 均衡：IS 与 LM 相交决定 (Y, r)。
- 政策含义：财政政策（IS 曲线移动）与货币政策（LM 曲线移动）通过 IS 或 LM 曲线的移动影响产出与利率。

IS–LM：商品与货币市场的同时均衡



- IS：商品市场均衡（总需求 = 产出），利率随产出下降（投资对利率敏感）。
- LM：货币市场均衡（实质货币供给 = 货币需求），利率随产出上升。
- 交点 (Y^*, i^*)：同时满足两市场出清条件；财政/货币政策使曲线移动，改变均衡。
- 用途：讨论短期总量波动与政策传导。

IS–LM 模型的局限性

- **忽视数据对投资的影响**：IS 曲线中投资 $I(r)$ 仅取决于利率，但现实中企业投资更由数据驱动的预测与不确定性评估决定；大数据与 AI 改变了投资预期与风险判断。
- **货币需求结构变化**：LM 曲线假设货币需求 $L(Y, r)$ 仅依赖产出与利率，但数字支付、移动支付与数字货币（央行数字货币 CBDC、稳定币等）改变了货币流通速度与货币需求结构。
- **政策传导渠道单一化**：模型假设货币政策仅通过利率渠道传导；但在量化投资与算法交易主导的金融市场中，数据与算法改变了风险定价与金融传导，政策效果更加难以预测。
- **忽略零价格数字商品**：数字平台提供大量边际成本为零的免费服务，未进入总需求与 GDP 核算，IS 曲线对总需求的度量存在系统性低估。
- **静态框架无法刻画数据更新**：IS-LM 是给定信息集下的静态均衡，而数据经济中预期随数据不断更新（贝叶斯学习、机器学习预测），政策与市场反应呈动态特征。

RBC 模型: 解释经济周期如何由外生技术冲击引发

- 核心思想：经济波动主要由外生技术冲击驱动，经济主体具有完全理性与跨期最优化。
- 家庭问题：

$$\max \ \mathbb{E}_0 \sum_{t=0}^{\infty} \beta^t U(C_t, L_t)$$

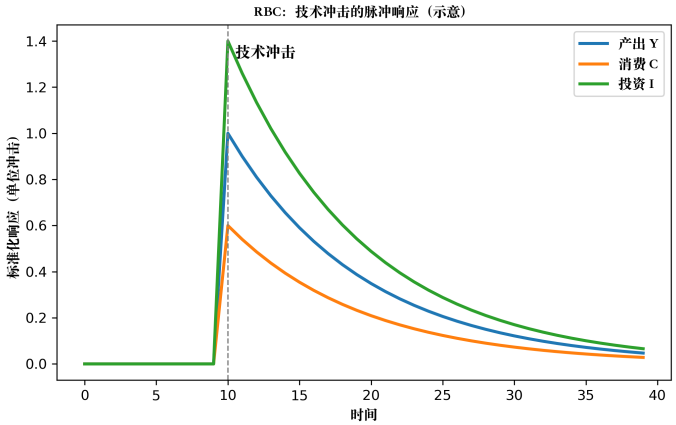
约束条件：$C_t + K_{t+1} = Y_t + (1-\delta)K_t$

- 企业问题：

$$Y_t = A_t K_t^{\alpha} L_t^{1-\alpha}$$

- 结论：技术冲击 A_t 的波动解释了产出、消费、投资与劳动的周期性波动。
- 局限：将所有冲击归因于“技术”，但未考虑现代经济中数据和信息结构的作用。

RBC：技术冲击的简化脉冲响应



- 假设一次性技术正冲击 A_t（持久度 ρ）：产出 Y 立即上升并逐步回落。
- **消费**更平滑（跨期调整），**投资**更波动（边际产出更敏感）。
- RBC 强调：无需名义摩擦，实质冲击即可驱动周期。
- 用途：对比新凯恩斯/粘性价格模型，理解冲击—传播—波动的机制。

RBC 模型的局限

- **将波动全部归因于技术冲击**：RBC 把经济周期归因于外生技术冲击 A_t，但数字经济中，波动往往源自数据冲击、信息冲击与算法行为，而非物理技术冲击。
- **技术冲击被外生化**：数字经济中的技术进步（AI、机器学习）是数据积累与利用的内生结果，RBC 无法解释数据如何内生地驱动技术演变。
- **完全理性与完全信息假设**：RBC 假设经济主体完全理性、拥有完全信息，而数字经济中主体通过数据与算法进行有限理性预测（机器学习、贝叶斯学习），信息不完全才是常态。
- **生产函数中数据缺席**：$Y_t = A_t K_t^{\alpha} L_t^{1-\alpha}$ 仅含资本与劳动；数据既非生产要素，也不构成独立的冲击与传播渠道（数据泄露、监管变化、平台算法更新均可引发波动）。
- **忽略数据网络效应的非均衡动态**：RBC 强调波动围绕均衡展开，但数据网络效应与正反馈使经济可能存在多重均衡或长期偏离，赢者通吃的动态超出其均衡波动叙事。

二、数据的特征

二、数据的特征

从外生技术冲击到内生预测能力

- 前面的 Solow/ RBC 模型把生产率 A_t 视为外生冲击；数据经济学新近文献进一步追问：

  企业能否通过交易数据学习需求与成本，从而内生地提高 A_{it}?

- 具体而言，可将企业生产写为：

$$Y_{it} = A(\Omega_{it}) K_{it}^{\alpha} L_{it}^{1-\alpha}, \qquad A'(\Omega_{it}) > 0,$$

  其中 Ω_{it} 表示数据带来的**预测精度**。

- 此外，生产与交易在创造产出的同时，会留下数据（点击、订单、反馈等副产品）；数据又反过来改善预测，形成自我强化的循环：

$$\text{生产/交易} \xrightarrow{\text{副产品}} \text{数据} \xrightarrow{\text{学习}} \text{预测更准} \xrightarrow{\text{不确定性}\downarrow} \text{生产率}\uparrow$$
$$\longrightarrow \text{更多生产/交易} \circlearrowleft$$

文献：Farboodi and Veldkamp (2022), *A Model of the Data Economy*.

特征一：非竞争，但可以排他

- **非竞争性**：同一份数据可以被多个部门、企业同时使用；复制不会耗损原数据。
- **非排他性**：理论上，数据可以被无限复制给多个主体同时使用，任何主体对数据的使用都不会影响其他使用者的利益，一方使用不排斥他人使用。但是现实是?

特征一：非竞争，但可以排他

- **非竞争性**：同一份数据可以被多个部门、企业同时使用；复制不会耗损原数据。
- **非排他性**：理论上，数据可以被无限复制给多个主体同时使用，任何主体对数据的使用都不会影响其他使用者的利益，一方使用不排斥他人使用。但是现实是?
- **事实上的排他性**：1. 数据持有者可以通过加密技术、法律保护或将其存储在私有服务器上，有效地排除他人轻易获取；2. 法律、接口、算力和组织边界决定谁能用；技术上可复制，不等于经济上会共享。
- **范围经济**：用户画像可同时用于推荐、定价、风控和研发，跨场景、甚至跨组织合并往往比孤立使用更有价值。

经济后果

私有数据持有者不会充分考虑他人复用数据的收益，因而可能出现共享不足；但强制开放又会损害隐私与采集激励–Trade off。由此，引出政府部门提供数据的相关政策————公共数据开放。

文献：Jones and Tonetti (2020), AER, *Nonrivalry and the Economics of Data*.

特征二：规模递增与信息递减同时存在

企业层面：规模递增

- 大企业交易多，产生的数据多；
- 数据改善决策，进一步扩大交易；
- 形成数据反馈循环与先发优势。

数据层面：边际收益递减

- 前几条观测最能减少不确定性；
- 样本继续增加时，精度改善越来越小；
- 随机性使预测误差不可能降为零。

数据少时，“谁数据多谁强”的规模效应占优；数据多了以后，“每新增一份数据的边际价值递减”的信息效应占优。

文献：Farboodi and Veldkamp (2022)；Farboodi et al. (2019).

特征三：可积累、会折旧，且在使用中自然产生

- **可积累**：历史交易不断累积成数据存量，能够持续支持未来的预测，因此数据像资本一样具有资产属性。
- **会折旧**：偏好、价格和技术环境一旦变化，旧数据对当前状态的预测力就会下降；“数据多”不等于“数据新”。
- **在使用中自然产生**：用户消费服务或完成交易时，行为数据被顺带记录下来；企业获得这些数据不需要额外付费，也不一定对应一笔显性的货币支付。

为什么许多数字服务价格为零？

“免费”服务本质上是一种以数据换服务的交换：你得到服务，企业得到你的使用数据。价格为零，不代表数据没有价值，也不代表消费者获得的福利已被 GDP 完整记录。

文献：Farboodi and Veldkamp (2022)；Farboodi and Veldkamp (2023), JEL.

微观结果：生产率提高，也会重塑企业规模分布

- **决策更准**：数据帮助企业预测需求、配置库存、选择产品与匹配劳动；采用数据驱动决策的企业，产出和生产率高出约 5%–6%。
- **企业更大**：模型实验显示，启用数据生产后，大企业数量增加，最大企业扩张最明显——规模效应可能压过数据的边际递减。
- **进入呈 J 型路径**：数据型新企业初期缺少历史样本，可能低利润甚至亏损；积累数据后快速提升质量、投资与产出。

并非“数据越多，竞争越充分”

数据提高效率的同时，也可能放大先发优势、融资约束和市场集中度。

文献：Brynjolfsson, Hitt and Kim (2011)；Farboodi et al. (2019), AEA P&P.

宏观结果：促进增长，但传统统计可能低估福利

- **提升生产率水平，但不保证永久增长**：数据能提高生产率水平；但预测误差有下限，仅靠积累交易数据无法让增长永久持续。只有数据进入研发、催生新想法，才可能支撑长期增长。
- **传统 GDP 统计有所遗漏**：零价格数字服务与“以数据换服务”缺少货币交易，难以被计入 GDP。按实验估计，仅 Facebook 一家的消费者福利，就相当于使美国 GDP-B（纳入免费数字服务的福利型产出指标）的年增长率提高约 0.05–0.11 个百分点。
- **降低跨境贸易摩擦**：eBay 引入机器翻译后，跨国购物的语言障碍下降，平台跨境出口提高约 17.5%。

文献：Farboodi and Veldkamp (2022, 2023)；Brynjolfsson et al. (2019)；Brynjolfsson, Hui and Liu (2019).

特征四：数据与算法、算力甚至组织能力高度互补

- 数据要素本身不会自动变成生产率：价值取决于**算法、算力、人才和业务流程**能否把原始记录转化为可验证的预测。
- AI 算法降低了处理非结构化文本和图像的成本，也带来新的测量风险：同一批原始材料可生成多种“看似合理”（AI 幻觉问题）的指标，必须使用明确的构念与验证样本。
- 新近模型表明，AI 扩散与市场集中可能呈**非单调关系**：早期由大型采用者扩大份额，广泛扩散后新进入者可能削弱其优势。

本节结论

数据兼具非竞争性、可排他性、动态折旧、反馈循环与算法互补性；因此它既能提高微观效率和宏观福利，也会带来集中、隐私、共享与统计测量问题。

前沿延伸：Dell and Rambachan (2026, working paper)；Firooz, Leduc and Liu (2026, working paper)

三、本课程安排

《数据要素理论与实践》本学期课程安排

本课程目标

- 理解数据作为要素在现代经济中的重要作用
- 掌握从统计到预测、从投资到政策的一整套数据要素分析工具
- 能够联系实际案例，理解数据在现实中的实际应用
- 对接数据经济学前沿研究
- 掌握 LLM、Agent 的使用

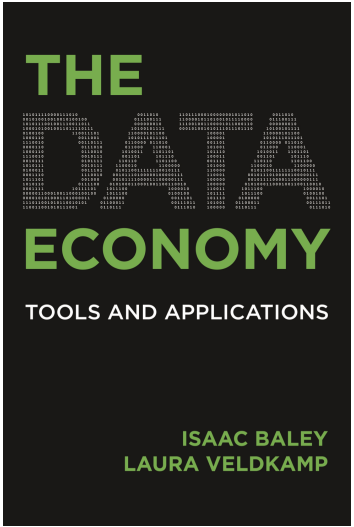
前半部分：理论与工具

1. 数据要素与数据经济
2. 贝叶斯定理
3. 卡尔曼滤波
4. 数据来源与学习机制

后半部分：实践与拓展

5. 数据如何驱动预测
6. 数据如何指导投资
7. 数据要素实践：从文本分析到智能决策
8. 大模型实践：从 API 调用到本地部署

参考书目

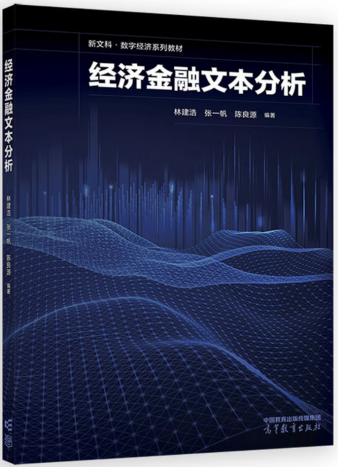


Laura Veldkamp
劳拉·维尔德坎普



参考书目


高等学校新文科数字经济学系列教材
大数据分析
Python实践与大型语言模型应用
谢佳松 主 编
刘 娟 副主编
东北财经大学出版社


新文科 · 数字经济系列教材
经济金融文本分析
林建浩 张一帆 陈良源 编著
中国教育出版传媒集团
高等教育出版社

参考论文

Begenau, J., Farboodi, M., & Veldkamp, L. (2018). Big Data in Finance and the Growth of Large Firms. *Journal of Monetary Economics*, 97, 71–87.

Beraja, M., Yang, D. Y., & Yuchtman, N. (2023). Data-Intensive Innovation and the State: Evidence From AI Firms in China. *The Review of Economic Studies*, 90(4), 1701–1723.

Farboodi, M., Mihet, R., Philippon, T., et al. (2019). Big Data and Firm Dynamics. In *AEA Papers and Proceedings*(Vol. 109, pp. 38–42). American Economic Association.

Farboodi, M., & Veldkamp, L. (2024). A Model of the Data Economy. Unpublished Manuscript.

Farboodi, M., Singal, D., Veldkamp, L., & Venkateswaran, V. (2025). Valuing Financial Data. *Review of Financial Studies*, 38(3), 938–980.

Jones, C. I., & Tonetti, C. (2020). Nonrivalry and the Economics of Data. *American Economic Review*, 110(9), 2819–2858.

Veldkamp, L. (2023). Valuing Data as an Asset. *Review of Finance*, 27(5), 1545–1562.

Veldkamp, L., & Chung, C. (2024). Data and the Aggregate Economy. *Journal of Economic Literature*, 62(2), 458–484.

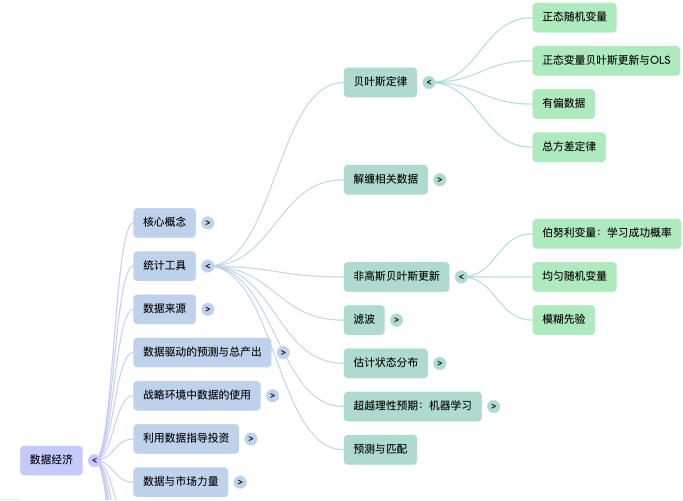
谢佳松等 (2025). 信息摩擦、公共数据与企业创新边界. 经济研究, 60(11), 51–73.

第二讲　贝叶斯定理

数据要素理论核心统计工具

- **数据科学的本质：预测技术**数据之所以成为有价值的资产，在于它能作为预测不确定结果的输入。
- **更多数据 ⇒ 更好的预测**数据可与人工、资本投入（如计算机设备）结合，提高预测精度。
- 现实案例：电商平台通过更多用户行为数据，更准确预测消费需求。
- **数据与决策优化**企业利用数据改进决策，降低不确定性：
  - 预测广告投放的效果（如 Google Ads）
  - 预测哪些产品将有高需求（如 Amazon 推荐系统）
  - 预测哪些供应商能长期降本（如制造业供应链优化）
- 如何从数据中提取预测能力？需要**统计工具**。贝叶斯定理 是现代数据科学的基石，用于更新预测。是数据要素理论模型的核心工具。

第二讲　贝叶斯定理

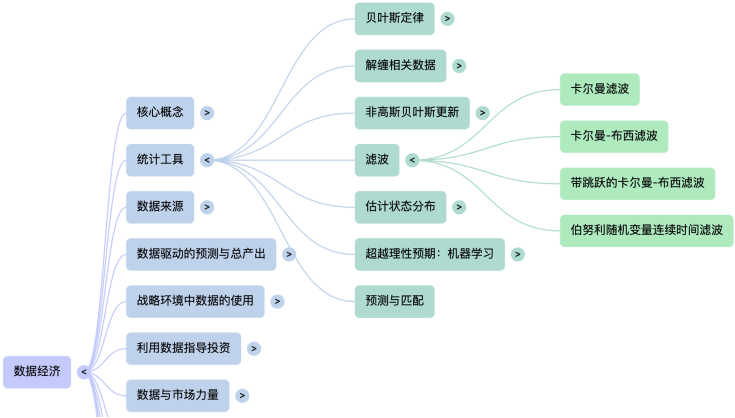

数据经济
核心概念
统计工具
数据来源
数据驱动的预测与总产出
战略环境中数据的使用
利用数据指导投资
数据与市场力量
贝叶斯定律
正态随机变量
正态变量贝叶斯更新与OLS
有偏数据
总方差定律
解缠相关数据
非高斯贝叶斯更新
伯努利变量：学习成功概率
均匀随机变量
模糊先验
滤波
估计状态分布
超越理性预期：机器学习
预测与匹配

第三讲　卡尔曼滤波

从贝叶斯到卡尔曼滤波：动态学习的需求

- **贝叶斯定理**告诉我们如何利用新数据不断修正对不确定性的判断。
- 但现实问题常常具有**时间序列特征**：信息是逐步到达的，状态在随时间演化。
- 例子：
  - 经济学：央行如何根据最新通胀和就业数据调整对未来经济的预测？
  - 工程学：自动驾驶汽车如何实时更新对车辆位置的估计？
- 这就需要一种**动态的贝叶斯更新方法**，能够处理“信号 + 状态演化”。
- **卡尔曼滤波（Kalman Filter）**正是实现这一过程的核心工具。

第三讲　卡尔曼滤波


数据经济
核心概念
统计工具
数据来源
数据驱动的预测与总产出
战略环境中数据的使用
利用数据指导投资
数据与市场力量
贝叶斯定律
解缠相关数据
非高斯贝叶斯更新
滤波
估计状态分布
超越理性预期：机器学习
预测与匹配
卡尔曼滤波
卡尔曼-布西滤波
带跳跃的卡尔曼-布西滤波
伯努利随机变量连续时间滤波

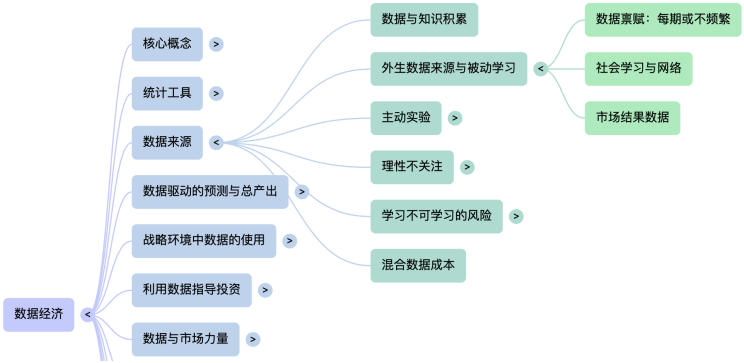
第四讲　数据来源与学习机制

数据如何产生与被利用？

- 数据经济带来了新的商业模式：**Facebook、Google** 依赖搜索与信息共享获取数据，并通过出售数据或广告服务盈利。
- **亚马逊、eBay** 等平台通过中介交易收集数据，长期从客户行为和交易信息中获益。
- 数据也可以直接被“出售”或“打包”成广告服务，广告投放成为类似**风险投资组合**的行为。
- 这些现象提示我们：**数据的来源与获取方式多样化**，而这些数据如何被捕获、存储、选择与加工，直接决定了企业能否形成竞争优势。

第四讲，将系统探讨数据的来源渠道、获取机制与学习方式，理解数据如何成为企业与社会的重要生产要素。

第四讲　数据来源与学习机制

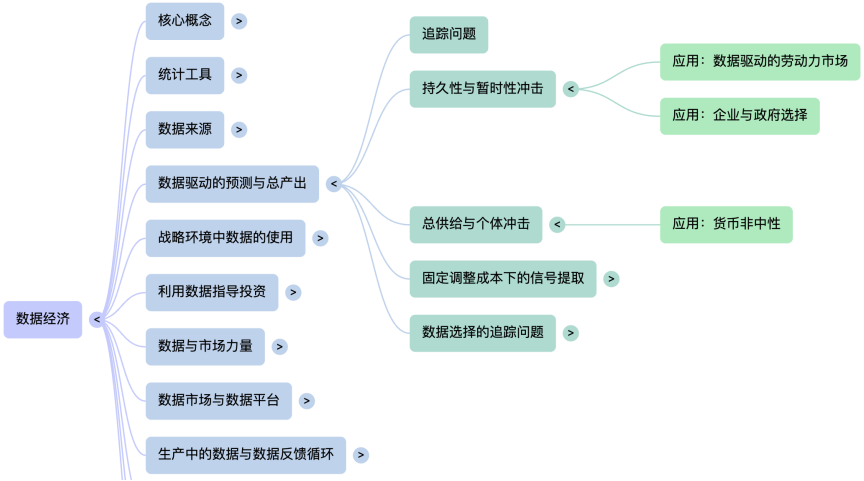


第五讲　数据如何驱动预测

预测问题的分类与剖析

- 企业利用数据预测成本、收入与冲击，并采取相应行动减少不确定性。
  - 案例：农民与天气预报、数据驱动的广告投放、采购与招聘决策。
- 核心：预测什么、**如何预测**，决定了企业是否能提升利润。
- 经济学意义：预测不仅影响企业个体，也会改变整体经济运行方式。
- 第五讲内容：对预测问题进行分类与剖析
  - 短期波动 vs. 长期趋势
  - 总体冲击 vs. 企业特有冲击
  - 普遍需求 vs. 个别需求
- 第五讲，将探讨如何将预测与数据结合，理解数据在决策中的作用。

第五讲　数据如何驱动预测

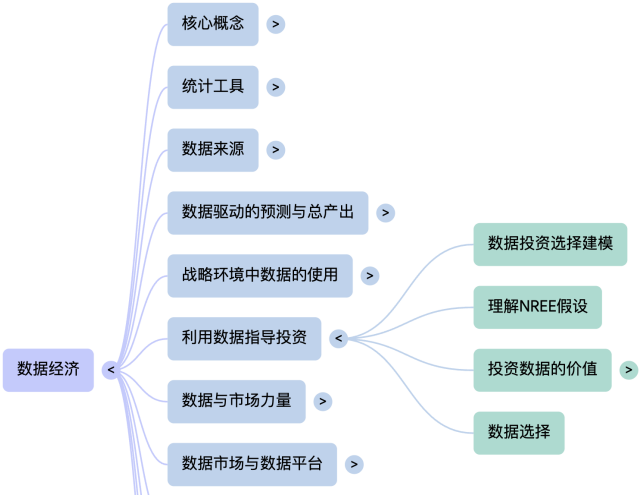


第六讲　数据如何指导投资

数据在投资决策中的作用

- **数据降低风险**：数据的核心是数字化信息，能减少不确定性，帮助企业更好地预测消费者需求、成本和投资收益。
- 数据通常用于在不确定的环境中分配资源。一个突出的例子就是金融资产组合的选择。
- 一个能够用数据预测风险资产未来收益的投资者，可以选择多买一些有利可图的资产，赚更多的钱。
- 数据不仅增加了预期利润，而且还有助于减少与承担风险有关的效用和财务成本。
- **现实案例**：金融市场中的量化投资、基金经理的数据驱动型选股策略，凸显了数据在投资配置中的关键作用。
- 本讲主要讲解投资者如何利用数据做出投资决策、如何评估数据的价值以及如何选择数据。

第六讲　数据如何指导投资



第七讲　数据要素实践：从文本分析到智能决策

如何从非结构化的文本数据中挖掘数据要素

- **文本数据：表格之外的数据要素**：除报表、价格等结构化数据外，年报、政策文件、新闻社媒、招聘与评论等非结构化文本，记录着“表达、判断、情绪与策略”，可回答政策强度与方向、管理层语调、市场情绪、技能需求等经管问题。
- **NLP 发展历程**：规则与词典法 → 统计方法（BoW、TF-IDF、LDA）→ 词向量 Word2Vec → 上下文表示 BERT → 大语言模型 LLM。
- **文本分析的主要方法**：预处理与分词（jieba）→ 特征构建（BoW / TF-IDF / N-gram）→ 文本度量（词典法、复杂度、情感分析）→ 文本相似度与 Embedding。
- **两条路径互补而非替代**：传统文本表征透明、稳定、低成本，适合构造长周期面板指标；LLM 端到端提取语义理解强、适合开放任务，但成本高、需验证——传统方法打底与复现，LLM 增强与扩展。
- 以辽宁省政府工作报告等真实文本为例，把原始语料加工成可回归、可预测的变量，实现从文本分析到智能决策的闭环。

第八讲　大模型实践：从 API 调用到本地部署

用大语言模型把文本数据变成“可计算的数据要素”

- **LLM 在数据要素挖掘中的定位**：对海量文本端到端地分类、抽取与结构化，把“供人阅读”的文本批量转化为可计算、可建模的数据要素。
- **API 调用起步**：接入 DeepSeek、Qwen、GPT、Claude 等，掌握 Prompt 设计与批量标注——无需 GPU，适合快速验证。
- **Embedding 与 RAG**：语义向量化支撑文本相似度与聚类，配合检索增强让模型基于给定语料作答，降低幻觉。
- **本地部署**：涉及隐私、批量成本与复现要求时，转向本地推理（Hugging Face、ModelScope、Ollama/vLLM），配合量化实现可控可复现。
- **工作流与 AI Agent**：Conda 环境管理 → AI 编程助手（Chat AI → IDE AI → Agent AI）→ Agent + MCP 接入爬虫、Stata、文献库等外部工具，贯通数据获取—变量构造—实证—写作。
- **案例与边界**：在政策文本结构化、上市公司文本指标、专利语义匹配等场景实践 LLM 在数据要素挖掘中的应用；警惕幻觉、黑箱、成本与可复现性。

课程考核方式

- 课程内容难度较大，要求学生具备一定的经济学、数学分析及 Python 基础。
- 课程考核不会难为大家。

课程考核方式

- 课程内容难度较大，要求学生具备一定的经济学、数学分析及 Python 基础。
- 课程考核不会难为大家。
- 课堂参与与出勤（40%）：考勤次数不定，按出勤比例算分数。
- 期末项目（60%）：选择一个数据驱动的实际问题进行深入分析与报告：
  - 格式要求：要求按照课程论文封皮标准格式提交论文，打印纸质版（可从研究生院网站 https://graduate.dufe.edu.cn/xzzq/pygz/ 下载《东北财经大学研究生课程论文封皮及课程论文成绩报告单》）。
  - 内容要求：2000 字内。需要包含：选题背景、研究目的、数据要素理论模型使用、分析方法、结论与政策建议等。鼓励结合实际案例与数据进行分析。
  - 加分项：
    - 运用数理模型
    - 运用文本分析、LLM 等数据挖局方法
  - 时间要求：第 17 周周三下课前（12.23 日）提交，纸质版现场提交，超过 ddl 时间恕不接受。