Lecture 2 贝叶斯定理

谢佳松

东北财经大学

Fall 2026

目录

1. 贝叶斯定理：离散和连续
2. 贝叶斯定理在正态分布中的应用
3. 正态贝叶斯更新与 OLS 回归的等价性
4. 有偏数据
5. 总方差定律
6. 非高斯贝叶斯更新
7. 弥散先验

一、贝叶斯定理：离散和连续

一个看似显然的推断

2026 年菲尔兹奖

四位获奖者中，王虹、邓煜、约翰·帕登和雅各布·齐默曼里，有三位会说汉语。

- 可知，在 2026 年获得菲尔兹奖的人中，会说汉语的比例是 75%。
- 那么，一个会说汉语的人获得菲尔兹奖的概率也是 75% 吗？



一个看似显然的推断

2026 年菲尔兹奖

四位获奖者中，王虹、邓煜、约翰·帕登和雅各布·齐默曼里，有三位会说汉语。

- 可知，在 2026 年获得菲尔兹奖的人中，会说汉语的比例是 75%。
- 那么，一个会说汉语的人获得菲尔兹奖的概率也是 75% 吗？



小心：问题把条件与结果对调了

条件对调后，概率还是同一个吗？

事件与已知信息

- A：获得菲尔兹奖
- B：会说汉语
- 已知：$P(B \mid A) = \dfrac{3}{4} = 75\%$
- 问题：$P(A \mid B) = ?$

关键核心

$P(B \mid A)$ 与 $P(A \mid B)$ 通常不相等；仅凭 75% 无法作答。

Bayes' Theorem

$$P(A \mid B) = \frac{P(A)P(B \mid A)}{P(B)}$$

若仅近似估计，取全球人口 82 亿、会说汉语者 14 亿，且本届有 4 位获奖者：

$$P(A \mid B) \approx \frac{(4/82\text{亿}) \times 75\%}{14/82} = \frac{3}{14\text{亿}},$$

$$P(A \mid B) \approx 2.1 \times 10^{-9}.$$

楔子：我们如何更新对世界未知事件的判断与信念？

- **天气预报**：昨天天气预报今日下雨的概率为 30%，今天上午，你看到乌云密布 → 你对会下雨的概率是不是提高了？
- **医疗检测**：一个人咳嗽，医生怀疑可能是流感；如果检测阳性 → 你对他真得了流感的信念是否变强了？
- **足球比赛**：赛前觉得 A 队胜率 40%，但上半场 B 队领先 2 球 → 此时你觉得 A 队胜率会降低吗？
- **考研**：你想考 985 高校，但是你自己在做卷子时发现，英语经常不及格 → 你会调整对自己考上的概率的判断吗？

楔子：我们如何更新对世界未知事件的判断与信念？

- **天气预报**：昨天天气预报今日下雨的概率为 30%，今天上午，你看到乌云密布 → 你对会下雨的概率是不是提高了？
- **医疗检测**：一个人咳嗽，医生怀疑可能是流感；如果检测阳性 → 你对他真得了流感的信念是否变强了？
- **足球比赛**：赛前觉得 A 队胜率 40%，但上半场 B 队领先 2 球 → 此时你觉得 A 队胜率会降低吗？
- **考研**：你想考 985 高校，但是你自己在做卷子时发现，英语经常不及格 → 你会调整对自己考上的概率的判断吗？

共同点： 我们会根据 新信息 来 调整原先的信念。

为什么更新信念（后验信念）很重要?

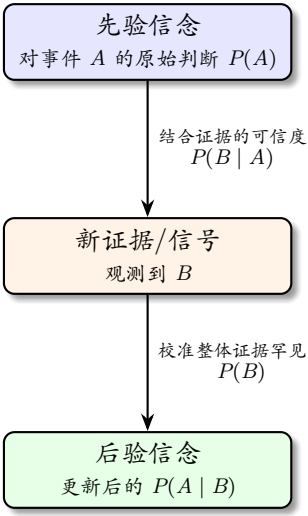
- **科学研究**：新的实验数据出现 → 旧的假说需要修正，否则会误导结论。
- **商业决策**：电商预测销量，若实时数据表明需求更高 → 不更新预测就会库存不足。
- **风险管理**：疫情初期对传染率的估计偏低，随着病例上升 → 必须快速调整信念和政策。
- **个人生活**：如果坚持原有信念、拒绝更新（如“赌徒谬误”），往往会带来错误判断。

为什么更新信念（后验信念）很重要?

- **科学研究**：新的实验数据出现 → 旧的假说需要修正，否则会误导结论。
- **商业决策**：电商预测销量，若实时数据表明需求更高 → 不更新预测就会库存不足。
- **风险管理**：疫情初期对传染率的估计偏低，随着病例上升 → 必须快速调整信念和政策。
- **个人生活**：如果坚持原有信念、拒绝更新（如“赌徒谬误”），往往会带来错误判断。

结论：后验信念 = 在已有知识基础上，结合新证据或观测到的数据，得到更接近真实世界的判断。

我们如何用新信息更新判断？



- A 是世界状态，B 是我们观察到的信息。更新的过程即为：用 B 来更新对 A 的信念。
- 例如：A：今天会下雨；B 早上看见乌云。
- $P(B \mid A)$ 是似然函数 (likelihood)，即在事件 A 发生的前提下，观察到数据 B 的概率——证据 B 的可信度。
- 我们不是推翻原判断，而是**在先验基础上，把新证据作为新的信息，对原先的推断进行调整**。
- **直觉：**这是一个**更新过程**，让我们的信念更接近真实世界。

贝叶斯定理要回答的问题

- 我们原来对一个世界状态有一个“**先验信念**”(Prior)：$P(A)$；
- 观察到新的“**证据 / 信号**”(Evidence)：B。
- 需要对世界状态 A 更新为一个新的“**后验信念**”(Posterior)：$P(A|B)$。

解释：

- $P(A)$ = 赛前我们对“球队赢”的先验信念
- B = 新证据（比如球队半场领先）
- $P(A|B)$ = 根据证据修正后的胜率

如何计算？

贝叶斯定理：离散形式

- 贝叶斯定理（Bayes' Law）：在给定观测数据下评估某一事件发生概率的一种工具。
- 贝叶斯定理描述了在已知一些新的证据或信息后，某个事件的概率如何更新。
- 数据就是“证据”或“信号”，我们需要用贝叶斯定理来更新我们对未知状态的信念。
- 由条件概率（本科内容）：$A \cap B$————交集：事件 A 和事件 B 同时发生。

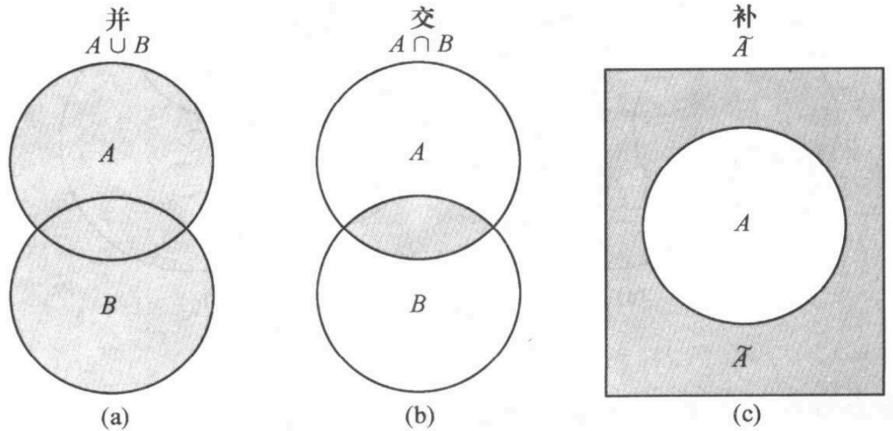
$$P(A|B) = \frac{P(A \cap B)}{P(B)} \tag{1}$$

$$P(B|A) = \frac{P(A \cap B)}{P(A)} \tag{2}$$

- （2）带入（1）得：

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)} \tag{3}$$

复习：集合相关概念



贝叶斯定理：离散形式

- 对于贝叶斯公式：

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

- $P(A|B)$ 是后验概率 (posterior probability)，即在观察到数据 B 后，我们对事件 A 发生的信念。
- $P(B|A)$ 是似然函数 (likelihood)，即在事件 A 发生的前提下，观察到数据 B 的概率。——证据 B 的可信度
- $P(A)$ 是先验概率 （prior probability)，即在观察到数据前，我们对事件 A 发生的信念。
- $P(B)$ 是边缘概率，通常也称为归一化常数。

对边缘概率的更直观理解

- 首先，后验概率 $P(A|B)$ 本质上是一个概率值。任何概率值都必须在 0 到 1 之间。
- 在不考虑分母的情形下：$P(A \mid B) \propto P(B \mid A) \cdot P(A)$，但是，这个“正比于”的关系告诉我们后验概率的趋势，但它不是一个完整的等式。
- 换句话说，这个乘积的结果，其数值本身不一定在区间内
- 此时，$P(B)$ 就登场了。它的唯一任务就是作为一个归一化因子，将上面的乘积结果缩放到正确的概率范围内，从而得到一个真正的、合法的概率值，即这就是为什么它也叫“归一化常数”。

对边缘概率的更直观理解

- 那么 $P(B)$ 到底是什么？
- $P(B)$ 代表的是证据 B 本身独立发生的总概率。在复杂情况下，它可以通过全概率公式计算得出：

$$P(B) = P(B|A)P(A) + P(B|\neg A)P(\neg A)$$

- 这代表了产生证据 B的所有可能路径。无论是从原因 A 导致 B，还是从原因 $\neg A$ 导致 $\neg B$，我们将所有可能性加起来，就得到了 B 的总概率。
- 总结：P(B) 的作用就是校准。它确保了当我们根据新证据（B）更新我们的信念时，得到的最终结果（后验概率）是一个有意义的、完整的概率。

贝叶斯定理：离散形式案例

- 如果一个个体去医院检查呈阳性？你直观觉得生病的概率有多大?
- 条件一：生病概率 1%
- 条件二：生病有 90% 概率测出为阳性
- 条件三：假阳性：无论是否生病，测出阳性概率为 10%

贝叶斯定理：离散形式案例

- 案例一转化为数学符号问题：
- 事件 A 为生病，事件 B 为去医院测出阳性（证实生病）
- 假设 $P(A) = 0.01$ ：即生病概率 1%
- 若 $P(B|A) = 0.9$ ：生病的话 90% 测出阳性
- $P(B) = 0.1$ ：表明无论是否生病，测出阳性概率为 10%
- 那么，检测出阳性条件下，你觉得生病的概率有多大？90%？还是接近 100%？

贝叶斯定理：离散形式案例

- 案例一转化为数学符号问题：
- 事件 A 为生病，事件 B 为去医院测出阳性（证实生病）
- 假设 $P(A) = 0.01$ ：即生病概率 1%
- 若 $P(B|A) = 0.9$ ：生病的话 90% 测出阳性
- $P(B) = 0.1$ ：表明无论是否生病，测出阳性概率为 10%
- 那么，检测出阳性条件下，你觉得生病的概率有多大？90%？还是接近 100%？
- 这一结果似乎和直觉不符：先验概率为 1%，后验更新的概率为 9%。

贝叶斯公式的三要素

- 刚才的例子体现了贝叶斯公式的逻辑：

$$P(A|B) = \frac{P(B|A)\,P(A)}{P(B)}$$

- 在例子中，分母 $P(B)$ 有时直接给出，但其实来源于 **全概率公式**：

$$P(B) = P(B|A)P(A) + P(B|\neg A)P(\neg A)$$

- 含义：无论 A 是否发生，B 的概率 = 各种情况的加权和。（$\neg$：补集，即 A 不发生）。
- 在我们前面的医疗检测例子中，

$$P(\text{检测阳性}) = P(\text{阳性} \mid \text{生病})P(\text{生病}) + P(\text{阳性} \mid \text{没生病})P(\text{没生病})$$

- 因此，分母起到了**校准作用**，让后验概率在不同世界状态下平衡。

常见误区：基率忽视（base-rate neglect）

- 另外，很多人只看似然 $P(B|A)$，忽视了先验 $P(A)$ 的重要性。
- 例子：某检测的准确率高达 90%，很多人直觉认为“阳性就大概率是真的”。
- 但若疾病先验概率 $P(A)$ 只有 1%，后验 $P(A|B)$ 其实只有不到 10%。
- **思考：**你会如何解释这种“反直觉”结果？

思考：为什么是反直觉结果?

- 错误的直觉：检测阳性 $\Rightarrow$ 应该“几乎一定得病了”。
  实际计算：$P(A|B) = 9\%$

- 原因解释：
  1. **稀有事件效应：**生病本身很少见，先验概率只有 1%。
  2. **假阳性影响大：**没病的人很多，即使小概率出假阳性，绝对数量也远超真阳性。
  3. **结果：**阳性结果更可能来自“没病但假阳性”，而不是“真的生病”。

- 启示：直觉可能会欺骗我们，
  稀有事件 + 不完美检测 = 阳性结果也未必可靠

过渡：从离散事件到连续变量

- **刚才：**我们以离散事件为例（生病/阳性）讲解了贝叶斯定理：

$$P(A \mid B) = \frac{P(B \mid A)P(A)}{P(B)}$$

- **但在经济学和现实世界中，变量往往是连续的**：收入、价格、产量、收益率等是**连续变量**；对于连续变量，单点的概率：$P(X = x) = 0$。

- 因此我们要用概率密度函数 (PDF) 来刻画事件的概率，并把贝叶斯公式改写成密度的形式：条件概率 $\Rightarrow$ 条件**密度**，求和 $\Rightarrow$ **积分**。

连续情形

离散：后验 = 先验 × 似然 / 证据概率；
连续：**后验密度** = 先验密度 × 似然密度 / **证据密度**。

贝叶斯定理：连续形式

- 对连续变量，用密度写作：

$$\boxed{f(A \mid B) = \frac{f(B \mid A)\, f(A)}{f(B)}} \qquad \text{其中} \quad f(B) = \int f(B \mid A)\, f(A)\, dA \; > \; 0$$

- **共轭分布：** 若先验分布 $f(A)$ 与后验 $f(A \mid B)$ 分布属于同一家族，称为共轭分布；计算与推导最为简洁（如正态–正态、Beta–二项、Gamma–泊松）。

- 共轭分布非常容易计算和推导，我们将在后面详细介绍。

一句话总结

连续情形依旧是：　后验密度 $\propto$ 先验密度 $\times$ 似然密度，　再用 $f(B)$ 做归一化。

连续贝叶斯：硬币偏斜的例子

我们不确定“正面概率 θ”的真实值

- **问题：** 抛掷一枚硬币是否公平？正面概率 θ 是多少？
- **先验信念：** θ 大概在 0.5 附近，但**不是确定值**（有不确定性）。
- **观测：** 抛了 10 次，出现 7 次正面、3 次反面。
- **更新：** 看到“正面偏多”，我们就把对 θ 的信念 **往 0.5 的右侧推一点**（比如 $0.6 \sim 0.8$ 区间更可能），形成一条新的“**后验可能性曲线**”。
- **直觉结论：** 连续贝叶斯不是给出“$\theta = 0.7$”这样的定值，而是**用一条分布曲线**来表示我们对未知参数 θ 的最新看法；数据越多，这条曲线越尖锐（即分布越集中，方差越小，不确定性越小）。

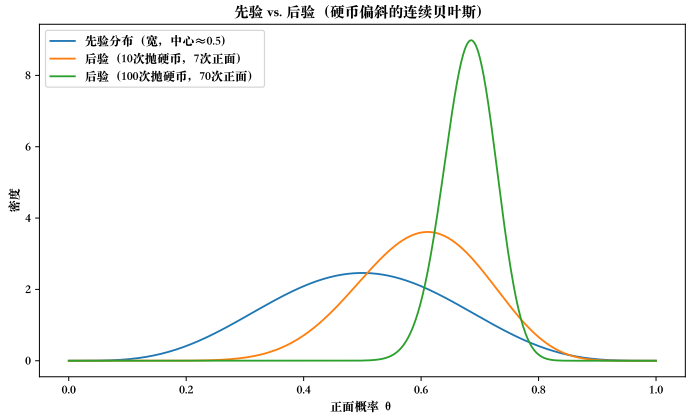
硬币偏斜问题计算：

- 先把“起初认为接近 0.5”的想法，形式化为一条**宽而平**的先验曲线（对 $\theta \in [0,1]$ 开放）——如均匀分布。
- 观测到 k 次正面、$n-k$ 次反面后，后验曲线的“形状参数”只和这两个计数有关：

$$\text{后验曲线} \ \propto \ \theta^{k}(1-\theta)^{n-k}$$

  - 若 k 大（正面多），曲线峰值向**右**移（偏正面）；
  - 若 k 小（正面少），曲线峰值向**左**移（偏反面）。
- 例：n=10, k=7 时，曲线在 0.6∼0.8 更高；若再抛 20 次仍偏正面，曲线会更**尖**（更确定）。
- **总结：**连续贝叶斯把“**次数信息**”直接转化为对 θ 的**整条后验曲线**，数据越多，判断越稳。

连续贝叶斯：先验 vs 后验



- 蓝线：先验分布，表示我们原始对 θ 的“宽泛”认识（大约在 0.5 附近）。
- 橙线：少量数据更新后的后验（10 次实验），分布开始收缩，但仍比较宽。
- 绿线：大量数据更新后的后验（100 次实验），分布更尖锐，说明我们对 θ 的认识更加确定。
- 直观理解：**数据越多，后验分布越集中**，不确定性逐渐减少。

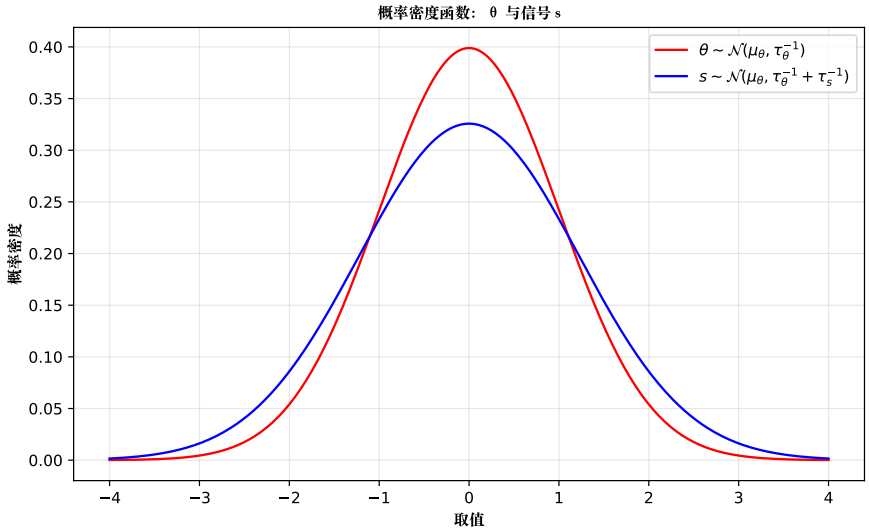
二、贝叶斯定理在正态分布中的应用

贝叶斯定理在正态分布中的应用

- 在数据经济学中，通常假设状态 θ 和信号 s 服从正态分布。
- 对于正态随机变量和具有正态分布噪声的信号，有一个非常简洁和直观的解，这个公式广泛应用于论文中，需要重点学习牢记。
- 假设，未来市场状态或某个变量 θ:
  - 尚未观测到任何信号前，对 θ 有一个先验信念：$\theta \sim \mathcal{N}(\mu_\theta, \tau_\theta^{-1})$，其中 μ_θ 是先验均值，τ_θ 是先验精度 (precision)。
  - 如果能够观测到一个信号：$s = \theta + \eta$，其中 $\eta \sim \mathcal{N}(0, \tau_s^{-1})$，先验误差 η 与信号误差 θ 独立。τ_s 是信号精度。
- 结合上述两个不完美信息，可基于 Bayes' Law 得到对 θ 的后验信念（条件概率）:

$$\hat{\theta} = E[\theta|s] = \frac{\tau_\theta \mu_\theta + \tau_s s}{\tau_\theta + \tau_s} \tag{4}$$

概率密度分布


概率密度函数： θ 与信号 s
$\theta \sim \mathcal{N}(\mu_\theta, \tau_\theta^{-1})$
$s \sim \mathcal{N}(\mu_\theta, \tau_\theta^{-1} + \tau_s^{-1})$
概率密度
取值
0.40
0.35
0.30
0.25
0.20
0.15
0.10
0.05
0.00
−4
−3
−2
−1
0
1
2
3
4

贝叶斯定理在正态分布中的应用

- 如何证明式 (4)?
- 提示一：正态分布概率密度函数：

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

- 提示二：忽略非 θ 项————贝叶斯推导中的重要技巧。
  - 在贝叶斯推导里，我们常写做：$p(\theta \mid s) \propto p(s \mid \theta)\, p(\theta)$，只关心作为 θ 的函数的部分（称为核 kernel）。
  - 任何不含 θ 的因子都可以并且应当忽略，因为它们只会改变最后的归一化常数，使 $\int p(\theta \mid s)\, d\theta = 1$，但不改变关于 θ 的形状、均值或方差。

公式与经济学意义：数据与先验的“精度加权平均”

后验均值（式 (4)）与方差：

$$\hat{\theta} = \mathbb{E}[\theta \mid s] = \frac{\tau_\theta\, \mu_\theta + \tau_s\, s}{\tau_\theta + \tau_s}, \qquad \mathrm{Var}(\theta \mid s) = \frac{1}{\tau_\theta + \tau_s}.$$

直觉：

- 后验信念是数据（信息）与先验信念的精度加权平均：谁更“可信”（精度 τ 越大），谁的权重越高。
- 数据融合：用新数据 s 更新旧知识的先验信念 μ_θ。
- 在引入新的数据后，事件不确定性衰减：后验方差 $1/(\tau_\theta + \tau_s)$ 小于任何一方的方差。

公式与经济学意义：数据与先验的“精度加权平均”

后验均值（式 (4)）与方差：

$$\hat{\theta} = \mathbb{E}[\theta \mid s] = \frac{\tau_\theta\, \mu_\theta + \tau_s\, s}{\tau_\theta + \tau_s}, \qquad \mathrm{Var}(\theta \mid s) = \frac{1}{\tau_\theta + \tau_s}.$$

直觉：

- 后验信念是数据（信息）与先验信念的精度加权平均：谁更“可信”（精度 τ 越大），谁的权重越高。
- 数据融合：用新数据 s 更新旧知识的先验信念 μ_θ。
- 在引入新的数据后，事件不确定性衰减：后验方差 $1/(\tau_\theta + \tau_s)$ 小于任何一方的方差。

经济学意义（数据要素视角）：

- 数据质量 = 精度：数据要素的边际价值随质量提升而上升（$\tau_s \uparrow$ 则 $\hat{\theta}$ 更靠近 s）。
- 知识资本 = 先验：组织既有知识（μ_θ, τ_θ）决定了新数据能“撬动”决策的幅度。
- 动态学习：重复观测可递归更新，体现“数据推动知识边界外延”的过程。

经济学解释

- 后验均值：
  - $E[\theta|s] = \frac{\tau_\theta}{\tau_\theta+\tau_s}\mu_\theta + \frac{\tau_s}{\tau_\theta+\tau_s}s$
  - 后验均值是先验均值 μ_θ 和新信号 s 的加权平均。
  - 权重由各自的精度（precision）决定。
  - 如果先验精度 τ_θ 很高（即先验信念很确定），则我们更相信先验均值。
  - 如果信号精度 τ_s 很高（即新数据非常可靠），则我们更相信新信号。

- 后验方差：
  - $\mathrm{Var}[\theta|s] = \frac{1}{\tau_\theta+\tau_s}$
  - 后验方差的倒数（后验精度）等于先验精度和信号精度的加和。
  - 这意味着，每当我们获得新的数据，我们的信念就会变得更加精确。
  - 这是数据经济学的核心思想：数据是用来减少不确定性的。

思考

思考如下问题：

1. 如果信号噪声非常大（$\tau_s \to 0$），后验均值会如何变化？
2. 如果先验非常精确（$\tau_\theta \to \infty$），后验均值会如何变化？
3. 如果我们获得了多个独立数据观测 $s_1, s_2, \ldots, s_n$，每条数据的精度均为 τ_s，那么后验均值和方差会如何变化？
4. 如果信号 s 有偏（即 $s = \theta + b + \eta$，其中 b 是一个常数水平偏差），那么后验均值会如何变化？

思考题参考答案

答案：

1. **信号噪声非常大** ($\tau_s \to 0$)：后验均值趋近于先验均值 μ_θ，即几乎完全依赖先验；后验方差 $\to 1/\tau_\theta$。

思考题参考答案

答案：

1. **信号噪声非常大**（$\tau_s \to 0$）：后验均值趋近于先验均值 μ_θ，即几乎完全依赖先验；后验方差 $\to 1/\tau_\theta$。
2. **先验非常精确**（$\tau_\theta \to \infty$）：后验均值收敛于先验均值 μ_θ，同时方差 $\to 0$；即先验“锁定”结论，数据几乎没有影响。

思考题参考答案

答案：

1. **信号噪声非常大** ($\tau_s \to 0$)：后验均值趋近于先验均值 μ_θ，即几乎完全依赖先验；后验方差 $\to 1/\tau_\theta$。

2. **先验非常精确** ($\tau_\theta \to \infty$)：后验均值收敛于先验均值 μ_θ，同时方差 $\to 0$；即先验“锁定”结论，数据几乎没有影响。

3. **多条独立数据** $s_1, \ldots, s_n$，每个精度 τ_s：后验精度为 $\tau_\theta + n\tau_s$，后验均值为

$$\hat{\theta} = \frac{\tau_\theta \mu_\theta + \tau_s \sum_{i=1}^{n} s_i}{\tau_\theta + n\tau_s}.$$

   数据数量越多，后验方差 $1/(\tau_\theta + n\tau_s)$ 越小，均值更靠近样本平均。

思考题参考答案

答案：

1. **信号噪声非常大** ($\tau_s \to 0$)：后验均值趋近于先验均值 μ_θ，即几乎完全依赖先验；后验方差 $\to 1/\tau_\theta$。

2. **先验非常精确** ($\tau_\theta \to \infty$)：后验均值收敛于先验均值 μ_θ，同时方差 $\to 0$；即先验“锁定”结论，数据几乎没有影响。

3. **多条独立数据** $s_1, \ldots, s_n$，每个精度 τ_s：后验精度为 $\tau_\theta + n\tau_s$，后验均值为

$$\hat{\theta} = \frac{\tau_\theta \mu_\theta + \tau_s \sum_{i=1}^{n} s_i}{\tau_\theta + n\tau_s}.$$

   数据数量越多，后验方差 $1/(\tau_\theta + n\tau_s)$ 越小，均值更靠近样本平均。

4. **信号有偏** $s = \theta + b + \eta$：后验均值变为：

$$\hat{\theta} = \frac{\tau_\theta \mu_\theta + \tau_s (s - b)}{\tau_\theta + \tau_s},$$

   即在信号中去掉偏差 b后再更新。若忽略 b，估计结果会系统性偏移。

案例：GDP 增长率预测（模拟）

设定：

- 真实 GDP 增长率（不可见）$\theta = 4\%$；先验 $\mu_\theta = 2\%$，先验标准差 $\sigma_\theta = 1.5\%$（$\tau_\theta = 1/\sigma_\theta^2$）。
- 月度信号 $s_t = \theta + \eta_t$，其中 $\eta_t \sim \mathcal{N}(0,\ \sigma_s^2)$，取 $\sigma_s \in \{1\%, 3\%\}$ 比较数据质量。
- 递归贝叶斯更新 $t = 1, \ldots, 24$（两年），跟踪后验均值与方差。

目标：

1. 第一，假设第一期信号 s 无偏，尝试写出后验均值公式。
2. 展示高质量数据（小 σ_s、大 τ_s）如何使后验更快靠近真值并且方差更快下降。
3. 讨论数据要素的边际价值：当 τ_θ 已很大时，再增加数据精度的收益如何变化？

讨论：

- 若把先验改得更精确（减小 σ_θ），结果如何？（先验“更重”）
- 若中途出现异常噪声（增大 σ_s），后验收敛如何被拖慢？

课堂练习：计算不同数据质量下的后验均值

已知： $\mu_\theta = 2\%$，$\sigma_\theta = 1.5\%$；假设高、低质量信号的观测值均为 $s_H = s_L = 4\%$，且 $\sigma_H = 1\%$、$\sigma_L = 3\%$。

第一步：写出后验均值公式

$$\hat{\theta}_j = \mathbb{E}[\theta \mid s_j] = \frac{\tau_\theta \mu_\theta + \tau_j s_j}{\tau_\theta + \tau_j} = \frac{\mu_\theta/\sigma_\theta^2 + s_j/\sigma_j^2}{1/\sigma_\theta^2 + 1/\sigma_j^2}, \qquad j \in \{H, L\}.$$

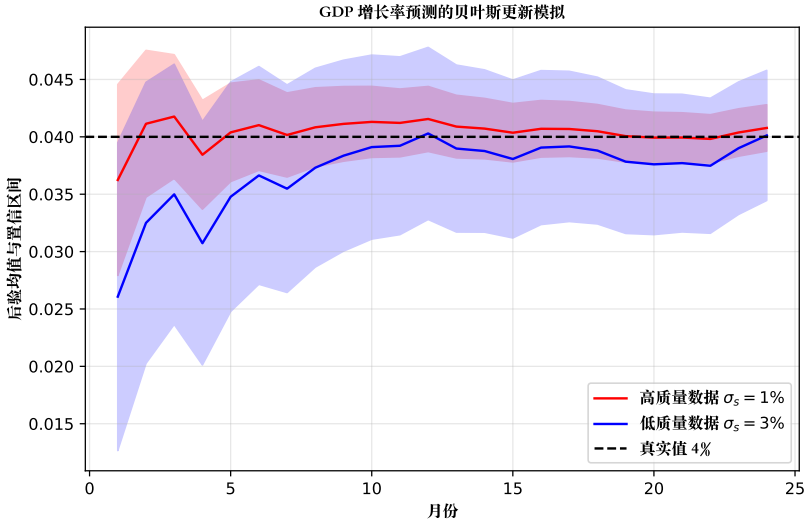
第二步：分别代入数值

$$\hat{\theta}_H = \frac{2/1.5^2 + 4/1^2}{1/1.5^2 + 1/1^2}\,\% = \frac{0.8889 + 4}{0.4444 + 1}\,\% = 3.3846\%,$$

$$\hat{\theta}_L = \frac{2/1.5^2 + 4/3^2}{1/1.5^2 + 1/3^2}\,\% = \frac{0.8889 + 0.4444}{0.4444 + 0.1111}\,\% = 2.4000\%.$$

结论： 在观测值相同时，高质量信号的精度更高，因而 $\hat{\theta}_H$ 更接近新信号 4%。

GDP 预测模拟结果图


GDP 增长率预测的贝叶斯更新模拟
后验均值与置信区间
月份
0.045
0.040
0.035
0.030
0.025
0.020
0.015
0
5
10
15
20
25
高质量数据 $\sigma_s = 1\%$
低质量数据 $\sigma_s = 3\%$
真实值 4%

讨论答案

1. 高质量数据 vs. 低质量数据:
图中红线（$\sigma_s = 1\%$）更快收敛到真实值 4%，置信区间明显比蓝线（$\sigma_s = 3\%$）窄，说明 **数据质量高 $\Rightarrow$ 学习更快，不确定性下降更快**。

2. 数据要素的边际价值:
当先验精度 τ_θ 已经很大时，再提高 τ_s 的效果递减：新的信号对均值的“拉动”有限。

3. 若先验更精确（σ_θ 更小）:
后验更依赖先验，均值曲线整体更接近先验均值，置信区间也更窄。

4. 若中途出现异常噪声（σ_s 突然增大）:
会导致某一阶段后验更新变慢，置信区间暂时变宽，收敛到真值的速度下降。

三、正态贝叶斯更新与 OLS 回归的等价性

正态贝叶斯更新与 OLS 回归结果的等价性

正态贝叶斯更新与 OLS 回归结果具有等价性。

对于正态分布变量，线性无偏且不相关的信号，贝叶斯后验信念均值 $E[\theta|s]$ 与将 θ 对信号 s 进行 OLS 回归得到的估计结果是等价的。

如何证明？

回忆：普通最小二乘法 (OLS) 原理

设定： 我们有 n 个观测样本 (x_i, y_i)，想用一个线性关系解释：

$$y_i = \beta_0 + \beta_1 x_i + u_i, \qquad i = 1, \ldots, n$$

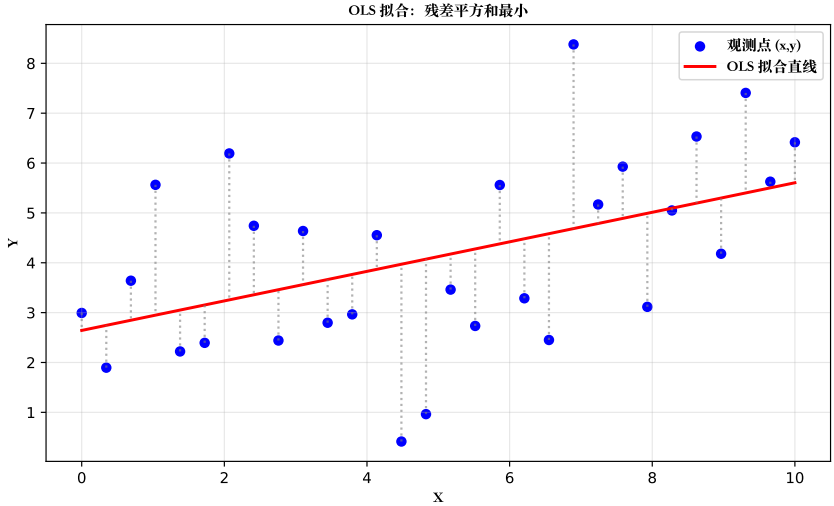
其中 u_i 是误差项。
目标： 找到合适的 β_0, β_1，使得预测值 $\hat{y}_i = \beta_0 + \beta_1 x_i$ 尽量接近真实值 y_i。
最小二乘准则：

$$\min_{\beta_0, \beta_1} \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2$$

直观理解：

- 把观测点 (x_i, y_i) 尽量“贴近”一条直线。
- 残差平方和 (SSR) 最小 $\Rightarrow$ 直线是最佳拟合。

OLS 估计模拟图



OLS 估计结果的表达式

一阶条件 (FOC)： 对 β_0, β_1 求导并令其为零，得到：

$$\sum_{i=1}^{n}(y_i - \beta_0 - \beta_1 x_i) = 0, \qquad \sum_{i=1}^{n} x_i(y_i - \beta_0 - \beta_1 x_i) = 0.$$

解：

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2} = \frac{\mathrm{Cov}(x, y)}{\mathrm{Var}(x)},$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = \mu_\theta - \frac{Cov[\theta, s]}{Var[s]}\mu_\theta.$$

OLS 预测值为：

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x = \bar{y} + \frac{\mathrm{Cov}(x, y)}{\mathrm{Var}(x)}(x - \bar{x}).$$

贝叶斯更新与普通最小二乘法 (OLS) 回归

- 我们已知：

$$\mathbb{E}[\theta \mid s] = \frac{\tau_\theta \mu_\theta + \tau_s s}{\tau_\theta + \tau_s} = \mu_\theta + \underbrace{\frac{\tau_s}{\tau_\theta + \tau_s}}(s - \mu_\theta)$$

- 为了和 OLS 估计对齐，把精度改写为方差及协方差：
  - $\mathrm{Var}(\theta) = 1/\tau_\theta, \mathrm{Var}(\eta) = 1/\tau_s$
  - $\mathrm{Var}(s) = \mathrm{Var}(\theta) + \mathrm{Var}(\eta) = 1/\tau_\theta + 1/\tau_s$
  - $\mathrm{Cov}(\theta, s) = \mathrm{Cov}(\theta, \theta + \eta) = \mathrm{Var}(\theta)$
- 因此，

$$\frac{\mathrm{Var}(\theta)}{\mathrm{Var}(s)} = \frac{\mathrm{Cov}(\theta, s)}{\mathrm{Var}(s)}$$

- 同时，$\mathbb{E}[s] = \mathbb{E}[\theta] = \mu_\theta$ 带入后得，

$$\mathbb{E}[\theta \mid s] = \mathbb{E}[\theta] + \frac{\mathrm{Cov}(\theta, s)}{\mathrm{Var}(s)}\big(s - \mathbb{E}[s]\big)$$

贝叶斯更新与普通最小二乘法 (OLS) 回归

- 现在，我们可以看到贝叶斯后验均值的表达式与 OLS 回归的形式非常相似。
- 代入这些表达式并整理各项，我们可以得到 OLS 回归中常数项 β_0 和斜率 β_1 的标准表达式:

$$E[\theta|s] = \underbrace{\left(\mu_\theta - \frac{Cov[\theta, s]}{Var[s]}\mu_\theta\right)}_{\beta_0} + \underbrace{\frac{Cov[\theta, s]}{Var[s]}}_{\beta_1} s. \tag{5}$$

- 其中，$\bar{y} = \mu_\theta$，$\bar{x} = \mu_\theta$。
- 这种等价性在考虑相关信息和更丰富的信号结构时也成立。

为什么贝叶斯更新 = OLS 回归很重要?

1. 理论层面：统一两大范式

- 贝叶斯：先验 + 数据 $\Rightarrow$ 后验
- 计量经济学 (OLS)：样本二阶矩 $\Rightarrow$ 回归参数
- 在正态-正态框架下二者等价 $\Rightarrow$ 统计推断的统一性

2. 实证与应用层面

- OLS 斜率 $\beta_1 = \dfrac{\mathrm{Cov}(\theta, s)}{\mathrm{Var}(s)} =$ 贝叶斯权重 $\dfrac{\tau_s}{\tau_\theta + \tau_s}$
- 揭示“可靠度比 (reliability ratio)”与“衰减偏误 (attenuation bias)”的来源

3. 延展性

- 多维信号 $\Rightarrow$ 卡尔曼滤波
- 搭建后续学习桥梁

四、有偏数据

有偏数据 (Biased Data)

前面我们看到，在正态 + 无偏独立噪声的条件下：

- 贝叶斯更新的后验均值 $\mathbb{E}[\theta \mid s]$ 与 OLS 回归预测是**等价的**。
- 信号 $s = \theta + \eta$，其期望刚好是 θ，不会系统性偏离。

新问题：

- 现实中，信号往往不是完全无偏的。
- 例如：信号中存在**系统性截距偏差 (bias)**：

$$s = \theta + b + \eta, \quad b \neq 0$$

- 或更复杂的**线性偏差**：

$$s = c\theta + d + \eta, \quad c \neq 1, d \neq 0$$

- 此时，信号平均值系统性偏离 θ，后验均值会受到什么影响？**是否会被带偏？**

这引出了一个更现实、更重要的话题——有偏数据的识别与校正。————如何计算后验？

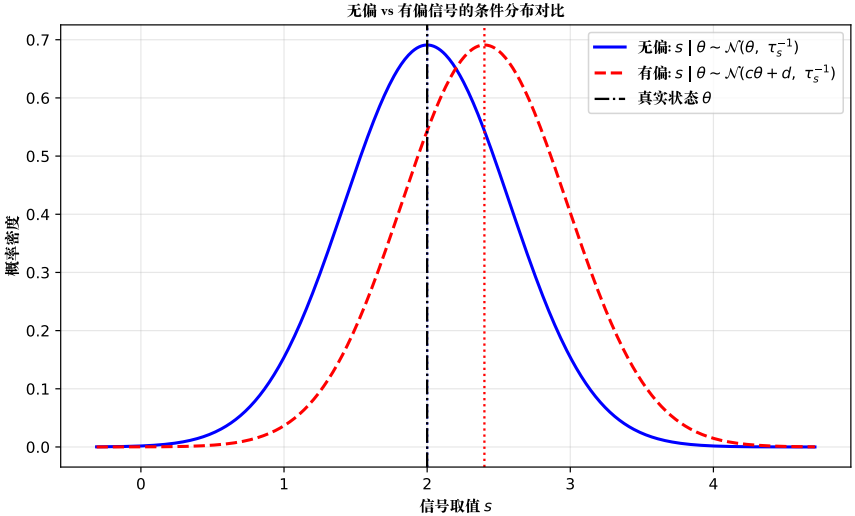
有偏数据 (Biased Data)

- 在实际应用中，我们观察到的数据 s 往往并不是对未知状态 θ 的准确测量：如分析师推荐信息与股价。
- **信号的偏向性**：观察到的信号 s 的均值可能系统性地偏离了真实状态 θ。这种偏离性在论文中通常可以被建模为一个线性函数：

$$s|\theta \sim \mathcal{N}(c\theta + d, \tau_s^{-1}). \tag{6}$$

- 对比初始设定：$s \mid \theta \sim \mathcal{N}(\theta,\ \tau_s^{-1})$，这里引入了两个新的参数 c 和 d。
- **变量含义**：
  - c：信号对真实状态 θ 的敏感度。如果 $c = 0$，信号与真实状态无关；如果 $c = 1$，信号是无偏的。
  - d：信号中的固定偏向或偏移量。
  - τ_s^{-1}：信号的方差，反映了信号的噪声或不确定性。

有偏数据分布模拟图


无偏 vs 有偏信号的条件分布对比
无偏: $s \mid \theta \sim \mathcal{N}(\theta,\ \tau_s^{-1})$
有偏: $s \mid \theta \sim \mathcal{N}(c\theta + d,\ \tau_s^{-1})$
真实状态 θ
概率密度
信号取值 s
0.0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0
1
2
3
4

有偏数据 (Biased Data)

- **数据去偏**：为了将有偏数据转换为无偏数据，我们可以通过对原始数据进行线性变换来构造新的无偏数据 $\tilde{s}$:

$$\tilde{s}|\theta \equiv \frac{s|\theta - d}{c} \sim \mathcal{N}\left(\theta, \frac{\tau_s^{-1}}{c^2}\right). \tag{7}$$

- 此时，$\tilde{s}$ 的精度为 $c^2\tau_s$。

- **变换的经济学含义**：这种变换的本质是将有偏的信号 s 重新校准 (recalibration)，使其成为一个以 θ 为中心，但方差发生变化的无偏信号 $\tilde{s}$。

- 可以看到，经过变换后，方差会乘以 $1/c^2$，这意味着信号敏感度越高 ($|c|$ 越大)，新信号的方差越小，其提供的信息量越大。

有偏信号的贝叶斯更新

- 设定：先验 $\theta \sim \mathcal{N}(\mu_\theta, \tau_\theta^{-1})$；有偏信号：

$$s \mid \theta \sim \mathcal{N}(c\theta + d,\ \tau_s^{-1}), \qquad c \neq 1 \text{ 或 } d \neq 0.$$

- **去偏变换：** $\tilde{s} \equiv \dfrac{s-d}{c} \ \Rightarrow\ \tilde{s} \mid \theta \sim \mathcal{N}\Big(\theta,\ \dfrac{1}{c^2\tau_s}\Big)$，其精度为 $c^2\tau_s$。
- 请计算后验方差和后验均值。

有偏信号的贝叶斯更新

- 设定：先验 $\theta \sim \mathcal{N}(\mu_\theta, \tau_\theta^{-1})$；有偏信号：

$$s \mid \theta \sim \mathcal{N}(c\theta + d,\ \tau_s^{-1}), \qquad c \neq 1 \ \text{或}\ d \neq 0.$$

- **去偏变换：** $\tilde{s} \equiv \dfrac{s-d}{c} \ \Rightarrow\ \tilde{s} \mid \theta \sim \mathcal{N}\Big(\theta,\ \dfrac{1}{c^2\tau_s}\Big)$，其精度为 $c^2\tau_s$。
- 请计算后验方差和后验均值。
- **后验：** 像无偏情形一样对 $\tilde{s}$ 更新，得到：

$$\theta \mid \tilde{s} \ \sim\ \mathcal{N}\Big(\underbrace{\frac{\tau_\theta \mu_\theta + c\tau_s(s-d)}{\tau_\theta + c^2\tau_s}}_{\mathbb{E}[\theta \mid s]},\ \underbrace{\frac{1}{\tau_\theta + c^2\tau_s}}_{\mathrm{Var}(\theta \mid s)} \Big).$$

- 总结：若误把 s 当无偏（$c=1, d=0$），会得到 $\hat{\theta}_{\text{naive}} = \dfrac{\tau_\theta \mu_\theta + \tau_s s}{\tau_\theta + \tau_s}$，结果导致既**有偏**又方差评估**不正确**。

与 OLS 的对应：可靠度权重如何变化？

由 $s = c\theta + d + \eta$，$\eta \sim \mathcal{N}(0, \tau_s^{-1})$，独立，得

$$\mathrm{Cov}(\theta, s) = c\,\mathrm{Var}(\theta) = \frac{c}{\tau_\theta}, \quad \mathrm{Var}(s) = c^2\,\mathrm{Var}(\theta) + \mathrm{Var}(\eta) = \frac{c^2}{\tau_\theta} + \frac{1}{\tau_s}.$$

OLS 斜率（可靠度比）：

$$\beta_1 = \frac{\mathrm{Cov}(\theta, s)}{\mathrm{Var}(s)} = \frac{c\,\tau_s}{c^2\tau_s + \tau_\theta}.$$

于是 OLS 预测

$$\widehat{\theta}_{\mathsf{OLS}}(s) = \mathbb{E}[\theta] + \beta_1\big(s - \mathbb{E}[s]\big) = \mu_\theta + \frac{c\,\tau_s}{c^2\tau_s + \tau_\theta}\big(s - (c\mu_\theta + d)\big),$$

与上一页的 $\mathbb{E}[\theta \mid s]$ 完全一致。

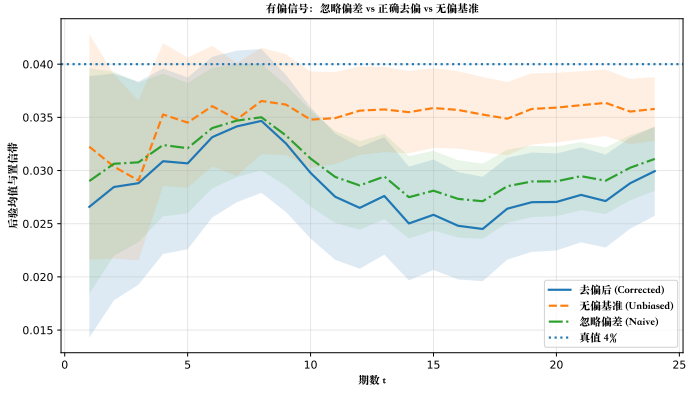
直觉：

- $|c|$ 越大（信号对真值更敏感），有效精度 $c^2\tau_s$ 越大，s 权重上升。
- d 只影响中心，必须先校正（去偏）才能正确更新。

实验：忽略偏差 vs 正确去偏 vs 无偏基准

对比三条轨迹：

1. **Naive 绿线**（忽略偏差）：当作 $c = 1, d = 0$ 更新；
2. **Corrected 蓝线**（去偏）：用 $\tilde{s} = (s - d)/c$ 更新；
3. **Unbiased baseline 橙线**：直接用无偏信号（同方差）更新。



图中三条轨迹如何解读?

统一设定： $s_t = c\,\theta^\star + d + \eta_t$, $\eta_t \sim \mathcal{N}(0, \tau_s^{-1})$；逐期贝叶斯更新并绘制后验均值与 ± 1 个后验标准差带。虚线为真值 $\theta^\star$。

蓝线（Corrected，去偏）：

- 先做 $\tilde{s}_t = (s_t - d)/c$，有效精度为 $c^2\tau_s$；再按无偏公式更新。
- 均值向真值收敛；带宽随 t 缩小，收敛速度取决于 $c^2\tau_s$（$|c|\uparrow \Rightarrow$ 更快）。

橙线（Unbiased，无偏基准）：

- 假想能直接观测 $\theta^\star + \varepsilon_t$（同噪声方差）。更新精度为 τ_s。
- 作为理想对照：当 $|c| < 1$ 时，橙线通常比蓝线更快；当 $|c| > 1$ 时，蓝线可能更快。

绿线（Naive，忽略偏差）：

- 错把 s_t 当无偏使用（当作 $c = 1, d = 0$）。
- 均值稳定地收敛到错误中心：极限偏差 $= (1 - c)\theta^\star + d$；带宽虽缩小但围绕“错中心”。

关键信息：

- 去偏后的“可靠度/权重”$= \dfrac{c^2\tau_s}{\tau_\theta + t\,c^2\tau_s}$；无偏基准为 $\dfrac{\tau_s}{\tau_\theta + t\,\tau_s}$。
- d 只影响中心，必须先校正；c 同时影响中心与有效精度（信息量）。

信号灵敏度的直观案例

- 设 θ 表示公司真实价值，s 是投资者观察到的分析师推荐信号。
- 信号模型为：$s|\theta \sim \mathcal{N}(c\theta + d, \tau_s^{-1})$，其中 c 表示信号对真实价值的灵敏度。
- **情形一：$c = 0.2$（信号迟钝）**
  - 公司价值变化 10 点，信号仅变化 2 点。
  - 信号响应缓慢，信息被“压缩”，去偏后噪声被放大，$\bar{s}$ 方差增大，信息量较低。
- **情形二：$c = 3$（信号灵敏）**
  - 公司价值变化 1 点，信号放大为 3 点。
  - 信号反应强烈，放大信息差异，去偏后噪声被压缩，$\bar{s}$ 方差减小，信息量更高。
- 就如同调节收音机音量，c 越大，相当于音量越高，信号越清晰，噪声影响越小。

有偏数据的经济学应用案例：投资决策中的信号校正

- **案例背景**：某投资经理正在评估一家公司的真实价值 θ。
  - 她的先验信念：$\theta \sim \mathcal{N}(\mu_\theta, \tau_\theta^{-1})$。
  - 她收到一份市场分析师的数据，这份数据是信号 s。
  - 她知道这位分析师总是习惯性地高估公司价值，并且数据的预测值与真实值并非 1:1 对应。
- **偏向性建模**：
  - $s = c\theta + d + \eta$
  - $c = 1.2$：分析师的报告对真实价值敏感度很高，但存在 20% 的系统性夸大。
  - $d = 10$：报告中还包含一个固定的乐观偏差，相当于在任何估值上额外增加 10 个单位。
- **更新过程**：
  1. **去偏**：投资经理首先通过线性变换 $\tilde{s} = \frac{s-10}{1.2}$ 将报告去偏。
  2. **更新信念**：然后，她将这个无偏信号 $\tilde{s}$ 代入贝叶斯公式，以更新她对公司真实价值 θ 的后验信念。
  3. **结论**：通过这种方式，她能够纠正分析师的系统性偏见，从而做出更理性的投资决策。

总结：有偏数据的贝叶斯更新

- 先验信念：$\theta \sim \mathcal{N}(\mu_\theta, \tau_\theta^{-1})$
- 无偏信号：$\tilde{s} \sim \mathcal{N}\left(\theta, \left(\frac{\tau_s^{-1}}{c^2}\right)\right)$ （对 s 的重新校准）
- **后验均值**：同样是先验均值 μ_θ 和无偏信号 $\tilde{s}$ 的加权平均：

$$E[\theta|\tilde{s}] = \mu_\theta + \frac{\text{新信号的精度}}{\text{总精度}}(\tilde{s} - \mu_\theta) = \mu_\theta + \frac{\tau_s c^2}{\tau_\theta + \tau_s c^2}(\tilde{s} - \mu_\theta)$$

- **后验方差**：后验方差的倒数（后验精度）等于先验精度和新信号精度的加和：

$$\text{Var}[\theta|\tilde{s}] = \frac{1}{\text{总精度}} = \frac{1}{\tau_\theta + \tau_s c^2}$$

关键

- 有偏信号的贝叶斯更新，本质上是先对信号进行去偏，然后用去偏后的新信号进行更新。
- 信号的偏向性 $(c$ 和 $d)$ 会影响其提供的信息量，即影响后验信念的更新权重和最终的不确定性。

五、总方差定律

总方差定律 (Law of Total Variance)

刚刚我们做了什么？

- 把有偏信号 $s = c\theta + d + \eta$ 通过去偏 $\tilde{s} = (s - d)/c$ 变成以 θ 为中心的无偏信号；
- 同时，**有效精度**从 τ_s 变为 $c^2\tau_s$ ——数据的信息量发生了变化。

接下来要回答的问题：

- 一次（或多次）更新之后，我们对 θ 的不确定性是如何下降的？
- 哪一部分不确定性是**数据无法消除**的（噪声/识别限制）？哪一部分是**通过观察 s 被消除**的？

总方差定律 (Law of Total Variance)

刚刚我们做了什么？

- 把有偏信号 $s = c\theta + d + \eta$ 通过去偏 $\tilde{s} = (s - d)/c$ 变成以 θ 为中心的无偏信号；
- 同时，**有效精度**从 τ_s 变为 $c^2\tau_s$ ——数据的信息量发生了变化。

接下来要回答的问题：

- 一次（或多次）更新之后，我们对 θ 的不确定性是如何下降的？
- 哪一部分不确定性是**数据无法消除**的（噪声/识别限制）？哪一部分是**通过观察 s 被消除**的？

工具：总方差定律（Law of Total Variance）

$$\underbrace{\mathrm{Var}[\theta]}_{\text{总体不确定性}} = \underbrace{\mathbb{E}\big[\mathrm{Var}(\theta \mid s)\big]}_{\text{更新后仍然剩余的平均不确定性}} + \underbrace{\mathrm{Var}\big(\mathbb{E}[\theta \mid s]\big)}_{\text{被数据“学到”的不确定性}}$$

经济学含义：数据把可学习的那一部分方差转化为后验均值的波动（信念变化），剩下的则是条件方差——即使看了数据也无法消除的不确定性。

总方差定律：如何理解与计算？

$$\underbrace{\mathrm{Var}(\theta)}_{\text{看数据前的总不确定性}} = \underbrace{\mathbb{E}[\mathrm{Var}(\theta \mid s)]}_{\text{看数据后仍剩下的不确定性}} + \underbrace{\mathrm{Var}(\mathbb{E}[\theta \mid s])}_{\text{数据能够解释的不确定性}}$$

经济学直觉

- $\mathrm{Var}(\theta)$：尚未获得数据时，我们对未知状态的**全部无知**。
- $\mathbb{E}[\mathrm{Var}(\theta \mid s)]$：即使已知 s，随机扰动等仍会造成**平均剩余不确定性**。
- $\mathrm{Var}(\mathbb{E}[\theta \mid s])$：不同数据会使后验均值不同，这种**信念波动**就是数据带来的学习成果。

案例：股票预期收益率

设 θ 是真实预期收益率（单位：百分点），报告 s 出现“利好”或“利空”的概率各为 $1/2$：

	$\mathbb{E}(\theta \mid s)$	$\mathrm{Var}(\theta \mid s)$
利好	8	4
利空	2	4

因此

$$\mathbb{E}[\mathrm{Var}(\theta \mid s)] = \tfrac{1}{2}(4) + \tfrac{1}{2}(4) = 4,$$
$$\mathrm{Var}(\mathbb{E}[\theta \mid s]) = \tfrac{1}{2}(8-5)^2 + \tfrac{1}{2}(2-5)^2 = 9,$$
$$\mathrm{Var}(\theta) = 4 + 9 = 13.$$

核心逻辑： 总不确定性 = 数据无法消除的不确定性 + 数据能够解释的不确定性。

总方差定律 (Law of Total Variance)

- **定义**：总方差定律阐述了如何将总不确定性分解为两部分。对于随机变量 θ 和 s，总方差定律可表示为：

$$\mathrm{Var}[\theta] = \mathbb{E}[\mathrm{Var}[\theta|s]] + \mathrm{Var}[\mathbb{E}[\theta|s]] \tag{8}$$

- 总体的不确定性（方差）= 你对未来知识的预期差异 + 你未来的预期不确定性
- 复习：概率论中重要的公式：方差=条件期望的方差 + 条件方差的期望

$$D(X|Y) = E[(X - E[X|Y])^2|Y] = E[X^2|Y] - 2(E[X|Y])^2 + (E[X|Y])^2 = E[X^2|Y] - (E[X|Y])^2$$

$$E[D(X|Y)] = E[E[X^2|Y] - (E[X|Y])^2] = E[X^2] - E[(E[X|Y])^2]$$

$$D(E(X|Y)) = E[(E(X|Y))^2] - (E[E(X|Y)])^2 = E[(E(X|Y))^2] - (E[X])^2$$

$$\begin{aligned} E[D(X|Y)] + D(E(X|Y)) &= E[X^2] - E[(E[X|Y])^2] + E[(E(X|Y))^2] - (E[X])^2 \\ &= E[X^2] - (E[X])^2 \\ &= D(X) \end{aligned}$$

总方差定律 (Law of Total Variance)

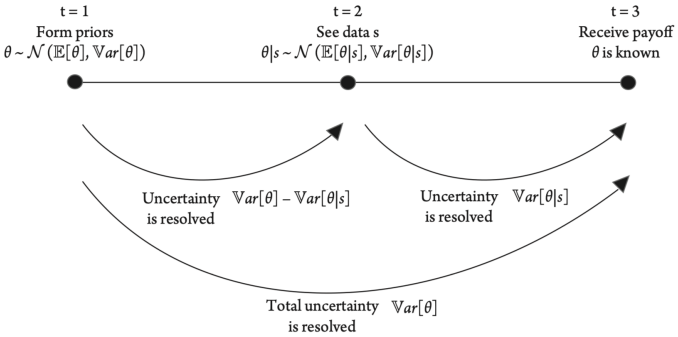
- **经济学含义**:
  - $\mathrm{Var}[\theta]$: **先验不确定性**，即在观察到任何信号前，我们对 θ 的总不确定性。
  - $\mathrm{Var}[\theta|s]$: **后验不确定性**，即在观察到信号 s 后，我们对 θ 的不确定性。
  - $E[\mathrm{Var}[\theta|s]]$: **未决不确定性**，即我们期望在观察到信号后，仍剩余的不确定性。
  - $\mathrm{Var}[E[\theta|s]]$: **被解决的不确定性**，即通过观察信号 s 所能减少的不确定性。——即后验方差。
- 注：在正态分布下，条件方差是一个常数，不依赖于具体的样本值 s，因此它本身就不是一个随机变量，即 $\mathbb{E}[\mathrm{Var}[\theta|s]] = \mathrm{Var}[\theta|s]$
- **核心洞见**：数据（信号 s）的价值在于其能够减少不确定性。数据所带来的价值，可以用被解决的不确定性 $\mathrm{Var}[E[\theta|s]]$ 来衡量。

总方差定律：一个时间轴上的例子

- **想象一个三阶段的时间轴：**

1. **第 1 阶段（先验）：** 数据 s 尚未被观察到，唯一能依赖的是先验。即我们对未知状态 θ 的不确定性是其先验方差 $\mathrm{Var}[\theta]$。
2. **第 3 阶段（真值揭示）：** 未来到来，状态 θ 的真实值被揭示。此时，我们对 θ 的不确定性为 0。
3. **第 2 阶段（观测到信号）：** 数据 s 将观察到。在这一刻，我们对未知状态 θ 的不确定性为 $\mathrm{Var}[\theta|s]$。因此：
   - 第 2 阶段和第 3 阶段间解决的不确定性总量为：$\mathrm{Var}[\theta|s]$。
   - 第 1 阶段和第 2 阶段间解决的不确定性必须为：$\mathrm{Var}[\theta] - \mathrm{Var}[\theta|s]$。
   - 由总方差定律：$\mathrm{Var}[\theta] - \mathrm{Var}[\theta|s] = \mathrm{Var}[\mathbb{E}[\theta|s]]$

总方差定律：一个时间轴上的例子



- 这个分解在信息价值评估（如：信息经济学、贝叶斯实验设计、政策分析）中至关重要。
- 可以用它来衡量“获得某个数据”能帮帮助减少多少不确定性————经济学模型中对数据要素的建模

总方差定律与数据价值

- **数据如何创造价值?**
  - 数据本身不创造价值，而是数据所带来的信息减少了不确定性，这种不确定性的减少就是数据的价值。
  - 在经济学中，不确定性的减少通常与更优的决策、更高的期望效用或更低的风险相关。
- **定量衡量数据价值**:
  - “总方差定律”不仅是一个概率论公式，而是贝叶斯学习的核心分解工具：左边：总体不确定性；右边：分为“数据解决掉的不确定性”+“数据无法解决的剩余不确定性”。
  - 数据所带来的信息价值可以用它所能减少的总方差来衡量，即 $\mathrm{Var}[E[\theta|s]]$（第一阶段到第二阶段由数据信息减少的不确定性）。
- **与贝叶斯更新的关系**:
  - 贝叶斯更新是实现不确定性减少的具体机制。
  - 总方差定律则为我们提供了一个宏观的视角，来理解这种不确定性减少的结构和量化方法。

数据价值

- 引申思考，数据本身真的不创造价值吗？
- Data-intensive Innovation and the State: Evidence from AI Firms in China
- 什么样的数据能够直接创造价值？————思考：进入生产函数

现实中的两类数据价值

1. 降低不确定性：帮助做出更好决策

作用链条： 数据 → 更准确的信念 → 更优决策

- **Google Maps 实时路况：** 聚合手机位置与车速数据，判断拥堵和到达时间，帮助用户选路、帮助平台调度。
- **支付平台反欺诈：** 利用交易时间、地点和行为模式，实时更新“是否欺诈”的概率，决定放行、验证或拦截。

价值来源：减少预测误差、错误决策与风险损失。

2. 直接创造价值：数据进入生产函数

作用链条： 数据 + 算法 + 算力 → 产品或服务

- **Tesla 自动驾驶：** 摄像头、激光雷达与车队路测数据直接驱动感知、轨迹预测和转向制动，是出行服务的必要生产投入。
- **ChatGPT 大模型：** 文本、代码、图像和人类反馈数据用于训练与对齐模型，直接决定内容生成服务的能力边界。

价值来源：提高产品质量、开启新功能，甚至产生新产品。

分类标准是“作用机制”：同一数据在不同场景中，可能同时具有两类价值。

总方差定律：市场信息案例

- **案例背景**：一家公司正考虑是否对一个新项目进行投资。项目的未来利润 θ 是不确定的。
- **先验信念**：在获得任何市场数据前，公司对 θ 的不确定性是 $\mathrm{Var}[\theta]$。
- **获取信号**：公司可以付费购买一份市场调研报告，这份报告是信号 s。
- **分析报告价值**：
  1. 市场调研公司提供的报告会包含一个预测值 $E[\theta|s]$。
  2. 尽管我们事先不知道报告的具体内容，但我们可以估计这份报告会如何影响我们的决策。
  3. 总方差定律告诉我们，这份报告的期望信息价值，正是其能减少的不确定性，即 $\mathrm{Var}[E[\theta|s]]$)。
- **决策**：
  - 如果 $\mathrm{Var}[E[\theta|s]]$ 所带来的期望收益大于购买报告的成本，那么购买这份报告就是理性的。
  - 反之，如果报告所能减少的不确定性微乎其微，那么购买它就是不划算的。

六、非高斯贝叶斯更新

非高斯贝叶斯更新

- 在许多经济学应用中，风险更准确或更方便地用伯努利 (Bernoulli)（二项分布）或均匀 (Uniform) 分布来表示，而不是正态分布。
- 由于正态分布又称作高斯（Gaussian）分布，所以上述分布统称为非高斯分布。
- 在这些情况下，传统的正态分布贝叶斯更新公式不再适用，我们需要使用非高斯分布的贝叶斯更新方法。
- 在这一小节，我们将首先讨论伯努利变量的贝叶斯更新，该变量用于对成功或失败等二元结果建模。

为什么需要非高斯贝叶斯更新？

对比：

- 在 **正态（高斯）分布**下，后验分布依然是正态（共轭），且有**解析解**：

$$\theta|s \sim \mathcal{N}\Big(\frac{\tau_\theta \mu_\theta + \tau_s s}{\tau_\theta + \tau_s},\ \frac{1}{\tau_\theta + \tau_s}\Big)$$

- 这种“共轭性”让推导与应用非常简洁。
- 但是在许多经济学应用中，状态变量并非连续正态，而是 **离散或有限区间**。

典型案例：

- 公司是否破产：$Y \in \{0, 1\}$ （伯努利分布）；
- 投资项目是否成功：$Y \in \{\text{成功}, \text{失败}\}$；
- 市场状态：$Y \in \{\text{好}, \text{坏}\}$；
- 政策效果评估：试点项目是否达到预期目标。

因此：

- 在这些情况下，传统的正态更新公式不再适用。
- 我们需要转向 **非高斯贝叶斯更新**方法，例如：伯努利分布、二项分布或 Beta 分布。

伯努利分布（单次试验）

- 又称两点分布或0-1 分布，是最简单的离散分布之一。
- 考虑一个随机变量 θ，它以概率 p 取值 1 (成功或发生)，以概率 $1-p$ 取值 0 (失败或不发生)。
- 这可以被看作是对一个“是或否”问题的结果，或者是一个只能取两个值的变量的实现，例如抛硬币正反面、新生儿是男是女、实验是否成功、用户是否点击了一次广告（点击/未点击）等。
- 因此，θ 服从参数为 p 的伯努利分布（x 只能取 0 或 1）：

$$\theta \sim \text{Bernoulli}(p) \iff \Pr[\theta = x] = p^x(1-p)^{1-x}, \quad x \in \{0,1\}.$$

- 期望与方差：$\mathbb{E}[\theta] = p, \quad \text{Var}(\theta) = p(1-p)$
- 伯努利分布就是“一次实验的成功或失败”，它是二项分布（Binomial）的特殊情况（n=1）。

二项分布：多次独立伯努利试验的结果

- 又称n 重伯努利试验，是伯努利分布从“一次试验”到“多次重复试验”的自然推广。
- 考虑将一次伯努利试验独立重复 n 次，每次成功的概率均为 p（例如连续抛 n 次硬币）。
- 令随机变量 θ 表示这 n 次试验中成功的总次数，则 θ 的取值为 $0, 1, \ldots, n$，而不再是伯努利分布中的 $\{0, 1\}$。
- 因此，θ 服从参数为 (n, p) 的二项分布（成功 k 次的概率由组合数决定）：

$$\theta \sim \text{Binomial}(n, p) \iff \Pr[\theta = k] = \binom{n}{k} p^k (1-p)^{n-k}, \quad k \in \{0, 1, \ldots, n\}.$$

- 期望与方差：$\mathbb{E}[\theta] = np, \quad \text{Var}(\theta) = np(1-p)$
- 直观理解：n 次独立试验的期望是单次期望的 n 倍；由于各次试验相互独立，方差同样放大 n 倍。
- 二项分布是伯努利分布的一般化，当 $n = 1$ 时二项分布退化为伯努利分布，即 $\text{Binomial}(1, p) = \text{Bernoulli}(p)$。

Beta 分布：对概率 p 的不确定性建模

- 在很多情境中，我们不仅关心一个事件的结果（成功/失败），还关心事件发生的**概率 p 本身**，而 p 也可能是不确定的。
- 例如：硬币是否公平（0.5 v.s. 0.5）？投资项目的成功概率是多少？这种概率参数可以用 Beta 分布来刻画。
- Beta 分布定义在区间 $[0,1]$ 上：

$$p \sim \text{Beta}(\alpha,\beta) \iff f(p) = \frac{1}{B(\alpha,\beta)} p^{\alpha-1}(1-p)^{\beta-1}, \quad 0 \le p \le 1,$$

其中 $B(\alpha,\beta)$ 是 Beta 函数。

- 期望与方差：

$$\mathbb{E}[p] = \frac{\alpha}{\alpha+\beta}, \quad \text{Var}(p) = \frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$$

- 直观理解：可以把 $\alpha-1$ 看作历史上的成功次数，$\beta-1$ 看作历史上的失败次数。

Beta 分布：共轭先验与贝叶斯更新

- 共轭性（三者最核心的联系）：若以 Beta 分布作为伯努利/二项分布中成功概率 p 的**先验**，则结合观测数据得到的**后验依然是 Beta 分布**——先验与后验同族，后验有解析解，无需数值积分。
- 视角差异：伯努利与二项分布刻画的是“已知成功概率 p，试验结果（*0/1* 或成功次数）如何分布”；而 Beta 分布刻画的是“成功概率 p 本身如何分布”，即把“概率”当作未知量来建模。
- 更新规则：设先验为 $\mathrm{Beta}(\alpha,\beta)$，进行 n 次伯努利试验并观测到 k 次成功、$n-k$ 次失败，则后验分布直接更新为

$$p \mid \mathcal{I} \sim \mathrm{Beta}(\alpha+k,\ \beta+n-k)$$

  即：**成功次数加到 α 上，失败次数加到 β 上**。
- 举例：估计一枚硬币正面朝上的概率 p。
  - 初始信念：毫无头绪时设先验为 $\mathrm{Beta}(1,1)$，即 $[0,1]$ 上的均匀分布；
  - 收集数据：抛掷 10 次，观测到 7 次正面（成功）、3 次反面（失败）；
  - 更新信念：后验分布变为 $\mathrm{Beta}(1+7,\ 1+3)=\mathrm{Beta}(8,4)$，此时

$$\mathbb{E}[p]=\frac{8}{8+4}\approx 0.67,$$

  且分布形态比先验更集中，代表对成功概率的估计更加确定。
- 简单总结：伯努利/二项分布解决“已知概率求结果”的问题，Beta 分布解决“已知结果反推概率”的问题，两者通过贝叶斯共轭性质完美结合。

思考：伯努利、二项与 Beta 分布的性质和概念

- **思考 1**：Beta 分布是连续分布，还是离散分布？

思考：伯努利、二项与 Beta 分布的性质和概念

- **思考 1**：Beta 分布是连续分布，还是离散分布？
  - 参考答案：连续分布。p 可以取 $[0,1]$ 内的任意实数，对应密度 $f(p) \propto p^{\alpha-1}(1-p)^{\beta-1}$；而伯努利分布（取值 $\{0,1\}$）与二项分布（取值 $\{0,1,\ldots,n\}$）都是离散分布。
  - 实际上，真实概率 p 可以是 0 到 1 之间的任何一个小数，我们无法预知它究竟是 0.3 还是 0.30001，所以必须用连续的分布来刻画这种“概率的不确定性”。

思考：伯努利、二项与 Beta 分布的性质和概念

- **思考 1**：Beta 分布是连续分布，还是离散分布？
  - 参考答案：连续分布。p 可以取 $[0,1]$ 内的任意实数，对应密度 $f(p) \propto p^{\alpha-1}(1-p)^{\beta-1}$；而伯努利分布（取值 $\{0,1\}$）与二项分布（取值 $\{0,1,\ldots,n\}$）都是离散分布。
  - 实际上，真实概率 p 可以是 0 到 1 之间的任何一个小数，我们无法预知它究竟是 0.3 还是 0.30001，所以必须用连续的分布来刻画这种“概率的不确定性”。
- **思考 2**：抛一枚硬币 n 次，正面出现的次数服从什么分布？当 $n=1$ 时呢？

思考：伯努利、二项与 Beta 分布的性质和概念

- **思考 1**：Beta 分布是连续分布，还是离散分布？
  - 参考答案：连续分布。p 可以取 $[0,1]$ 内的任意实数，对应密度 $f(p) \propto p^{\alpha-1}(1-p)^{\beta-1}$；而伯努利分布（取值 $\{0,1\}$）与二项分布（取值 $\{0,1,\ldots,n\}$）都是离散分布。
  - 实际上，真实概率 p 可以是 0 到 1 之间的任何一个小数，我们无法预知它究竟是 0.3 还是 0.30001，所以必须用连续的分布来刻画这种“概率的不确定性”。
- **思考 2**：抛一枚硬币 n 次，正面出现的次数服从什么分布？当 $n=1$ 时呢？
  - 参考答案：若各次试验相互独立且成功概率恒为 p，则成功次数 $\theta \sim \text{Binomial}(n,p)$；当 $n=1$ 时退化为 $\text{Bernoulli}(p)$，即二项分布是伯努利分布的推广。

思考：伯努利、二项与 Beta 分布的性质和概念

- **思考 1**：Beta 分布是连续分布，还是离散分布？
  - 参考答案：连续分布。p 可以取 $[0,1]$ 内的任意实数，对应密度 $f(p) \propto p^{\alpha-1}(1-p)^{\beta-1}$；而伯努利分布（取值 $\{0,1\}$）与二项分布（取值 $\{0,1,\ldots,n\}$）都是离散分布。
  - 实际上，真实概率 p 可以是 0 到 1 之间的任何一个小数，我们无法预知它究竟是 0.3 还是 0.30001，所以必须用连续的分布来刻画这种“概率的不确定性”。
- **思考 2**：抛一枚硬币 n 次，正面出现的次数服从什么分布？当 $n=1$ 时呢？
  - 参考答案：若各次试验相互独立且成功概率恒为 p，则成功次数 $\theta \sim \text{Binomial}(n,p)$；当 $n=1$ 时退化为 Bernoulli(p)，即二项分布是伯努利分布的推广。
- **思考 3**：设先验为 Beta$(2,2)$，观测到 8 次成功、2 次失败，后验分布是什么？p 的后验期望是多少？

思考：伯努利、二项与 Beta 分布的性质和概念

- **思考 1**：Beta 分布是连续分布，还是离散分布？
  - 参考答案：连续分布。p 可以取 $[0,1]$ 内的任意实数，对应密度 $f(p) \propto p^{\alpha-1}(1-p)^{\beta-1}$；而伯努利分布（取值 $\{0,1\}$）与二项分布（取值 $\{0,1,\ldots,n\}$）都是离散分布。
  - 实际上，真实概率 p 可以是 0 到 1 之间的任何一个小数，我们无法预知它究竟是 0.3 还是 0.30001，所以必须用连续的分布来刻画这种“概率的不确定性”。
- **思考 2**：抛一枚硬币 n 次，正面出现的次数服从什么分布？当 $n=1$ 时呢？
  - 参考答案：若各次试验相互独立且成功概率恒为 p，则成功次数 $\theta \sim \text{Binomial}(n,p)$；当 $n=1$ 时退化为 Bernoulli(p)，即二项分布是伯努利分布的推广。
- **思考 3**：设先验为 Beta$(2,2)$，观测到 8 次成功、2 次失败，后验分布是什么？p 的后验期望是多少？
  - 参考答案：由共轭性，后验为 $\text{Beta}(2+8,\ 2+2) = \text{Beta}(10,4)$，于是 $\mathbb{E}[p \mid \mathcal{I}] = \frac{10}{10+4} \approx 0.71$。

思考：伯努利、二项与 Beta 分布的性质和概念

- **思考 1**：Beta 分布是连续分布，还是离散分布？
  - 参考答案：连续分布。p 可以取 $[0,1]$ 内的任意实数，对应密度 $f(p) \propto p^{\alpha-1}(1-p)^{\beta-1}$；而伯努利分布（取值 $\{0,1\}$）与二项分布（取值 $\{0,1,\ldots,n\}$）都是离散分布。
  - 实际上，真实概率 p 可以是 0 到 1 之间的任何一个小数，我们无法预知它究竟是 0.3 还是 0.30001，所以必须用连续的分布来刻画这种“概率的不确定性”。
- **思考 2**：抛一枚硬币 n 次，正面出现的次数服从什么分布？当 $n=1$ 时呢？
  - 参考答案：若各次试验相互独立且成功概率恒为 p，则成功次数 $\theta \sim \text{Binomial}(n,p)$；当 $n=1$ 时退化为 Bernoulli(p)，即二项分布是伯努利分布的推广。
- **思考 3**：设先验为 Beta$(2,2)$，观测到 8 次成功、2 次失败，后验分布是什么？p 的后验期望是多少？
  - 参考答案：由共轭性，后验为 $\text{Beta}(2+8,\ 2+2) = \text{Beta}(10,4)$，于是 $\mathbb{E}[p \mid \mathcal{I}] = \frac{10}{10+4} \approx 0.71$。
- **思考 4**：样本频率 k/n 也能估计 p，为什么还需要 Beta 分布？

思考：伯努利、二项与 Beta 分布的性质和概念

- **思考 1**：Beta 分布是连续分布，还是离散分布？
  - 参考答案：连续分布。p 可以取 $[0,1]$ 内的任意实数，对应密度 $f(p) \propto p^{\alpha-1}(1-p)^{\beta-1}$；而伯努利分布（取值 $\{0,1\}$）与二项分布（取值 $\{0,1,\ldots,n\}$）都是离散分布。
  - 实际上，真实概率 p 可以是 0 到 1 之间的任何一个小数，我们无法预知它究竟是 0.3 还是 0.30001，所以必须用连续的分布来刻画这种“概率的不确定性”。
- **思考 2**：抛一枚硬币 n 次，正面出现的次数服从什么分布？当 $n=1$ 时呢？
  - 参考答案：若各次试验相互独立且成功概率恒为 p，则成功次数 $\theta \sim \text{Binomial}(n,p)$；当 $n=1$ 时退化为 Bernoulli(p)，即二项分布是伯努利分布的推广。
- **思考 3**：设先验为 Beta$(2,2)$，观测到 8 次成功、2 次失败，后验分布是什么？p 的后验期望是多少？
  - 参考答案：由共轭性，后验为 $\text{Beta}(2+8,\ 2+2) = \text{Beta}(10,4)$，于是 $\mathbb{E}[p \mid \mathcal{I}] = \frac{10}{10+4} \approx 0.71$。
- **思考 4**：样本频率 k/n 也能估计 p，为什么还需要 Beta 分布？
  - 参考答案：k/n 只是**点估计**，不提供不确定性的度量，样本量很小时也不稳定；Beta 先验既能纳入先验信息，又能给出 p 的**整个后验分布**，且样本量增大时后验会自动集中到 k/n 附近。

伯努利变量：使用离散先验的更新

- 在离散情况下，我们考虑一个关于未知概率 p的先验信念 p_0，它由一组 K 个离散值 $\{\pi_1, \pi_2, \ldots, \pi_K\}$ 和对应的概率 $\{\omega_1, \omega_2, \ldots, \omega_K\}$ 组成。
- 我们能够观察到 N 个独立的伯努利数据点 $\mathcal{I} = \{\theta_n\}_{n=1}^N$，这些数据点取值均为 0 或 1。
- 设 $s = \sum_{n=1}^N \theta_n$ 表示成功的次数，$f = N - s$ 表示失败的次数。
- 伯努利似然函数为，单次：$\Pr(\theta_n = 1 \mid p) = p$, $\Pr(\theta_n = 0 \mid p) = 1 - p$，全样本：

$$\Pr[\mathcal{I}|p = \pi_k] = \frac{N!}{s!\,(N-s)!}\pi_k^s(1-\pi_k)^f, \quad \forall k \in \{1, 2, \ldots, K\}.$$

- 请计算后验概率：$\Pr[p = \pi_k \mid \mathcal{I}]$

伯努利变量：使用离散先验的更新

后验概率的计算

- 对每个 k，用 Bayes'law，后验概率为：

$$\Pr[\pi_k|\mathcal{I}] = \frac{\omega_k \Pr[\mathcal{I}|\pi_k]}{\sum_{l=1}^{K} \omega_l \Pr[\mathcal{I}|\pi_l]} = \frac{\omega_k \pi_k^s (1-\pi_k)^f}{\sum_{l=1}^{K} \omega_l \pi_l^s (1-\pi_l)^f} \quad \forall k \in \{1, 2, \ldots, K\}.$$

- 每个后验概率都是由先验信念 ω_k 和观察到数据的似然 $\Pr[\mathcal{I}|\pi_k]$ 的乘积构成。
- 似然函数服从二项分布，其中二项式系数 $\binom{N}{s}$ 被抵消了，因为它在分子和分母中都出现。

贝叶斯后验推导：离散先验下的伯努利变量

设参数 p 的可能取值为 $\{\pi_1, \pi_2, \ldots, \pi_K\}$，对应先验概率为 $\{\omega_1, \omega_2, \ldots, \omega_K\}$。
我们观察到 N 个伯努利样本 $\mathcal{I} = \{\theta_n\}_{n=1}^N$，其中每个 $\theta_n \in \{0, 1\}$，记：

- 成功次数：$s = \sum_{n=1}^N \theta_n$
- 失败次数：$f = N - s$

根据贝叶斯定理，后验概率为：

$$\Pr[p = \pi_k \mid \mathcal{I}] = \frac{\Pr[\mathcal{I} \mid p = \pi_k] \cdot \Pr[p = \pi_k]}{\sum_{l=1}^K \Pr[\mathcal{I} \mid p = \pi_l] \cdot \Pr[p = \pi_l]}$$

由伯努利似然函数（提示：$\Pr[\theta_n = x \mid p = \pi_k] = \pi_k^x (1 - \pi_k)^{1-x}$）：

$$\Pr[\mathcal{I} \mid p = \pi_k] = \pi_k^s (1 - \pi_k)^f$$

因此后验概率为：

$$\boxed{\Pr[p = \pi_k \mid \mathcal{I}] = \frac{\omega_k \pi_k^s (1 - \pi_k)^f}{\sum_{l=1}^K \omega_l \pi_l^s (1 - \pi_l)^f} \quad \forall k \in \{1, 2, \ldots, K\}}$$

即：后验 = 先验 × 似然，再标准化。

伯努利变量：使用连续先验的更新

- 上一页我们讨论了使用离散先验的情况:p_0 由一组 K 个离散值 $\{\pi_1, \pi_2, \ldots, \pi_K\}$ 和对应的概率 $\{\omega_1, \omega_2, \ldots, \omega_K\}$ 组成。
- 另一种方法是使用连续先验p_0。通常，将其看成是区间 $[0, 1]$ 上的连续随机变量，并服从一特定分布。
- 在这种情况下，通常假设其服从Beta 分布，因为它是伯努利分布的共轭先验分布：

$$p_0 \sim \text{Beta}(a_0, b_0) \propto p_0^{a_0-1}(1-p_0)^{b_0-1}, \quad p_0 \in [0,1].$$

- **Beta 分布的优点**：
  - **参数控制**：参数 (a_0, b_0) 可以灵活控制分布的形状。
  - **均值和方差便于计算**：其均值等于 $\frac{a_0}{a_0+b_0}$，方差为 $\frac{a_0 b_0}{(a_0+b_0)^2(a_0+b_0+1)}$。
  - **共轭性**：Beta 分布与二项式似然函数具有相似的数学形式，使得后验分布仍然是 Beta 分布，从而大大简化了计算。

Beta 分布的参数更新

- 和前面相同，假设我们再次观察到 N 个独立的数据点 $\mathcal{I} = \{\theta_n\}_{n=1}^N$。
- 后验密度 $\hat{p} = p|\mathcal{I}$ 服从 Beta 分布 $\text{Beta}(a_N, b_N)$，其形状参数为：

$$a_N = a_0 + s$$
$$b_N = b_0 + N - s$$

其中 $s = \sum_{n=1}^N \theta_n$ 是成功的次数。

参数更新的经济学含义

- 参数 a_0 可以被理解为先验中“成功”的次数，b_0 可以被理解为先验中“失败”的次数。
- 观察到 s 次成功和 $N-s$ 次失败后，新的参数 a_N 和 b_N 分别等于先验信念加上观察到的成功和失败次数。
- 这体现了贝叶斯更新的核心思想：新信念是旧信念和新数据的结合。

Beta 先验 + 伯努利似然的贝叶斯更新公式

设定：

- 成功概率 p 的先验分布为：$p \sim \mathsf{Beta}(a_0, b_0)$
- 观测到 N 个伯努利试验结果 $\{\theta_n\}_{n=1}^{N}$
- 成功次数为 $s = \sum \theta_n$，失败次数为 $f = N - s$

目标： 推导后验分布 $p \mid \mathcal{I}$

应用贝叶斯定理：

$$f(p \mid \mathcal{I}) \propto \underbrace{p^{a_0-1}(1-p)^{b_0-1}}_{\text{先验 Beta}} \cdot \underbrace{p^{s}(1-p)^{f}}_{\text{伯努利似然}}$$

$$f(p \mid \mathcal{I}) \propto p^{a_0+s-1}(1-p)^{b_0+f-1} \Rightarrow p \mid \mathcal{I} \sim \mathsf{Beta}(a_n, b_n)$$

$$\boxed{a_n = a_0 + s, \quad b_n = b_0 + f = b_0 + N - s}$$

直观解释： Beta 分布的参数表示伪观测次数。先验中的“成功伪样本”与“失败伪样本”分别加上真实观测的成功/失败次数，得到后验。

案例设定：创新策略的成功概率如何学习？

案例情境：

某企业正在评估是否实施一项新的数字化创新项目。由于缺乏内部先验经验，企业管理层基于历史印象设定：

- 创新成功概率 p 为不确定的；
- 初始信念为 $p \sim \text{Beta}(2,2)$，均值为 0.5，表达“中性、略谨慎”态度。

企业决定借助外部数据（数据要素）辅助决策，从相关行业中采集到 10 个类似项目实施案例：

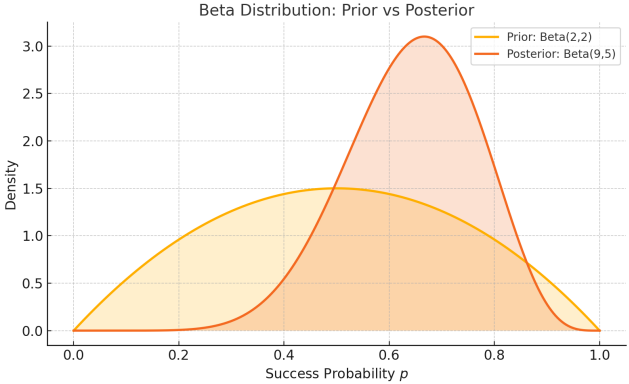
- 成功案例：7 个
- 失败案例：3 个

问题：基于这 10 个外部数据，企业对成功概率的信念如何更新？数据如何改变预期？

数据如何更新对创新成功概率的信念?

贝叶斯更新:

- 初始先验: $p \sim \text{Beta}(2,2)$
- 观测数据: $s=7$ 次成功, $f=3$ 次失败
- 后验分布: $p \mid \mathcal{I} \sim \text{Beta}(9,5)$, 均值提升至 0.643



数据如何更新对创新成功概率的信念?

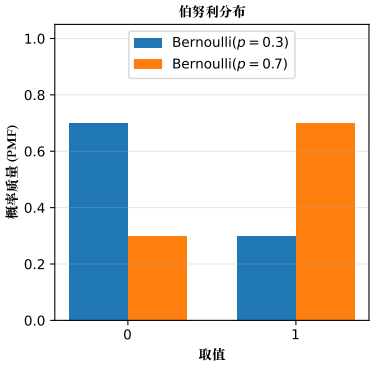
结论:

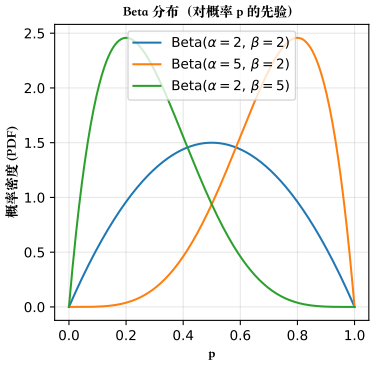
- 先验分布 Beta(2,2): 较为平坦，对成功概率 p 表示“中性”态度;
- 后验分布 Beta(9,5): 在观察到 7 次成功、3 次失败后，分布明显向右偏，均值约为 0.64，表明我们对较高成功概率的信心增强。
- 数据要素（外部案例）显著增强了管理层对创新成功的信心;
- 贝叶斯更新提供了将主观信念与客观数据融合的结构化方法;
- 这种框架可广泛用于策略评估、试点设计、动态调整等数据驱动管理情境中。

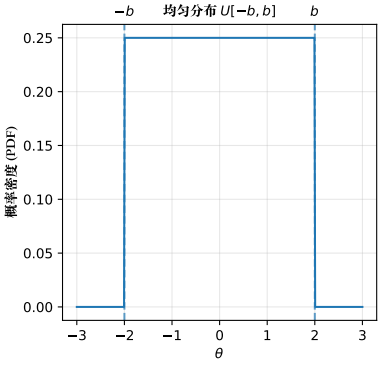
非高斯贝叶斯更新：均匀分布

- 刚才我们讨论了 **伯努利–Beta** 模型：适用于 **二元结果（成功/失败）** 的情境。
- 在这个模型中，先验–后验的更新关系非常直观：Beta 分布是伯努利/二项分布的共轭先验。
- 但是，在很多经济学与数据科学应用中，我们并不是处理二元变量，而是处理 连续型状态变量。
- 一个最常见的例子就是：我们只知道某个状态 θ 落在一个区间内 $([-b, b])$，且区间内的值等可能——即 **均匀分布**。——回忆你学过的均匀分布。
- 接下来，我们将进入 **均匀分布** 情形下的贝叶斯更新。

不同分布对比模拟图


伯努利分布
Bernoulli($p = 0.3$)
Bernoulli($p = 0.7$)
概率质量 (PMF)
取值
0
1
0.0
0.2
0.4
0.6
0.8
1.0


Beta 分布（对概率 p 的先验）
Beta($\alpha = 2$, $\beta = 2$)
Beta($\alpha = 5$, $\beta = 2$)
Beta($\alpha = 2$, $\beta = 5$)
概率密度 (PDF)
p
0.0
0.5
1.0
1.5
2.0
2.5
0.2
0.4
0.6
0.8


$-b$
均匀分布 $U[-b, b]$
b
概率密度 (PDF)
θ
0.00
0.05
0.10
0.15
0.20
0.25
−3
−2
−1
0
1
2
3

均匀随机变量 (Uniform Random Variables)

- 均匀分布也是一个非常常见的设定。
- 使用均匀变量进行更新在概念上很容易，但必须小心避免处理均匀区间边界的问题。
- 假设先验信念是 $\theta \sim \mathcal{U}[-b, b]$，表明先验认为，$\theta$ 在区间 [-b, b] 内取值是等可能等。
- 现在收到一个信号 s，信号的生成机制是：

$$s = \theta + \eta, \quad \eta \sim \mathcal{U}[-a, a].$$

- 现在，想更新对 θ 的信念，换句话说，就是求 $f(\theta|s)$。
- 如何计算？
- 需要注意什么问题？————分段

均匀随机变量的贝叶斯更新

- 先验密度（由均匀分布概率密度函数公式）：

$$f(\theta) = \frac{1}{2b}, \quad \theta \in [-b, b] \tag{9}$$

- 似然函数：

$$f(s \mid \theta) = \frac{1}{2a}, \quad \text{只要} s \in [\theta - a, \theta + a] \tag{10}$$

这是因为 $\eta = s - \theta \sim \mathcal{U}[-a, a]$，换句话说，给定对 θ ，s 是在 $[\theta - a, \theta + a]$ 区间上均匀分布的

- 利用贝叶斯公式，后验密度：

$$f(\theta \mid s) \propto f(s \mid \theta) \cdot f(\theta) \tag{11}$$

我们知道，$f(s \mid \theta) = \frac{1}{2a}$ 当 $\theta \in [s - a, s + a]$，否则为 0;$f(\theta) = \frac{1}{2b}$ 当 $\theta \in [-b, b]$，否则为 0。

- 所以两者都为正的区间是两者的交集：$\theta \in [\max(-b, s - a),\ \min(b, s + a)]$

均匀随机变量的贝叶斯更新

最终，$f(\theta \mid s)$ 表达式为：

$$f(\theta \mid s) = \begin{cases} \dfrac{1}{\min(b,\ s+a) - \max(-b,\ s-a)}, & \theta \in [\max(-b,\ s-a),\ \min(b,\ s+a)] \\ 0, & \text{otherwise} \end{cases} \tag{12}$$

- 在均匀分布的贝叶斯更新中，后验分布的区间是先验区间和似然区间的交集。
- 当信号落在先验区间的内部时，后验区间由信号决定。
- 当信号落在先验区间的边界附近时，后验区间由先验和信号的交集决定。

均匀分布的经济学应用

- **案例 1：消费者偏好的不确定性**
  - **背景**：一个厂商想要了解消费者对某产品的价值评估 θ。它知道这个价值评估均匀分布在 $[10, 50]$ 美元之间。
  - **信号**：厂商进行了一个市场调查，得到一个信号 s。这个信号存在测量误差 η，其均匀分布在 $[-5, 5]$ 美元之间。
  - **决策**：如果调查结果 $s = 40$ 美元，那么厂商的后验信念区间将是?

均匀分布的经济学应用

- **案例 1：消费者偏好的不确定性**
  - **背景**：一个厂商想要了解消费者对某产品的价值评估 θ。它知道这个价值评估均匀分布在 $[10, 50]$ 美元之间。
  - **信号**：厂商进行了一个市场调查，得到一个信号 s。这个信号存在测量误差 η，其均匀分布在 $[-5, 5]$ 美元之间。
  - **决策**：如果调查结果 $s = 40$ 美元，那么厂商的后验信念区间将是?
  - $[40 - 5, 40 + 5] = [35, 45]$ 美元。
  - 如果调查结果 $s = 12$ 美元，那么后验信念将是?

均匀分布的经济学应用

案例 1：消费者偏好的不确定性

- **背景**：一个厂商想要了解消费者对某产品的价值评估 θ。它知道这个价值评估均匀分布在 $[10, 50]$ 美元之间。
- **信号**：厂商进行了一个市场调查，得到一个信号 s。这个信号存在测量误差 η，其均匀分布在 $[-5, 5]$ 美元之间。
- **决策**：如果调查结果 $s = 40$ 美元，那么厂商的后验信念区间将是?
- $[40 - 5, 40 + 5] = [35, 45]$ 美元。
- 如果调查结果 $s = 12$ 美元，那么后验信念将是?
- $\mathcal{U}[\max(10, 12 - 5), \min(50, 12 + 5)] = \mathcal{U}[\max(10, 7), \min(50, 17)] = \mathcal{U}[10, 17]$ 美元。

均匀分布的经济学应用

- **案例 2：资产价格的贝叶斯更新**
  - **背景**：一个交易员认为某个资产的真实价值 θ 均匀分布在一个区间 $[L, H]$ 内。
  - **信号**：他从另一个交易员那里获得一个交易信号 s，这个信号也具有均匀分布的噪声。
  - **应用**：交易员可以根据这个信号和总方差定律，量化这个信号所能减少的不确定性，并决定是否值得付费购买这个信息。

案例引入：创新项目评估中的信号与不确定性

场景设定

一家风险投资公司正在评估某创业项目 θ 的内在技术潜力，先验认为其潜力值 $\theta \sim \mathcal{U}[-b,\ b]$，即可能“非常差”到“非常好”之间均匀分布。

- 公司通过专家打分、网络舆情等方式获得一条 noisy 信号 s，但该信号受噪声影响：$s = \theta + \eta$，其中 $\eta \sim \mathcal{U}[-a,\ a]$。
- 问题：观察到打分 s 后，投资人该如何更新对 θ 的认知？即如何计算 $f(\theta \mid s)$？
- 思考：这个“分数”靠不靠谱？我们如何量化不确定性范围？

似然函数数据作为信号，更新信念，决定是否下注：这正是“贝叶斯更新”的力量

后验分布形状：数据越精确信念越集中

结论：后验分布 $f(\theta \mid s)$ 也是一个均匀分布

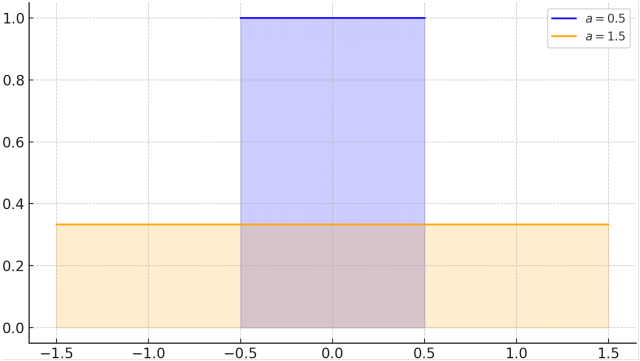
$$f(\theta \mid s) = \begin{cases} \dfrac{1}{\min(b,\ s+a) - \max(-b,\ s-a)}, & \theta \in [\max(-b,\ s-a),\ \min(b,\ s+a)] \\ 0, & \text{otherwise} \end{cases}$$

- 如果 a（噪声）越小，后验分布越集中 $\rightarrow$ 数据更精准；
- 如果 a 越大，后验越分散 $\rightarrow$ 信息含量更低。
- $\Rightarrow$ 数据的“质量”决定了信念更新的“效率”。

拓展思考：

- 如果你是风投人，你更希望观察哪种信号？
- 你如何决定再继续收集数据 vs. 直接决策？

后验分布的形状对比：不同信号噪声水平



图：固定 $b = 2$，比较 $a = 0.5$ 与 $a = 1.5$ 下后验分布 $f(\theta \mid s)$

- 噪声小（$a = 0.5$）$\Rightarrow$ 后验分布集中，精度高
- 噪声大（$a = 1.5$）$\Rightarrow$ 后验分布分散，信息不确定
- 体现贝叶斯更新中“信息越精确，结论越集中”

七、弥散先验

从具体分布到无信息分布

- 到目前为止，我们学习了几类常见先验分布的贝叶斯更新：
  - 正态先验：适合连续变量和对称噪声；
  - Beta 先验：伯努利模型的自然共轭分布；
  - 均匀先验：假设区间内所有值等可能。
- 这些先验都假设我们对参数有一定的了解或约束。
- 但在实际研究中，有时我们对参数几乎一无所知，甚至不敢限定在一个区间或具体分布上。
- 在这种情况下，我们会使用 **弥散先验 (Diffuse Prior)**，它表示“无信息的起点”。

弥散先验 (A Diffuse Prior)——对无先验知识建模

- 有时候，我们对参数也存在一无所知的情形。
- 弥散先验是指我们对参数几乎完全不了解，因此给定一个在整个实数轴上均匀分布先验信念的一种方式。

$$\theta \sim \mathcal{U}[-\infty, +\infty]$$

- 这种假设代表了对随机变量 θ 的值一无所知。这个“无限区间上的均匀分布”在数学上是一个极限意义下的假设，表达“对所有值一视同仁”的无信息立场。
- 由于连续均匀区间的概率密度为 $1/(b-a)$，因此弥散先验的密度为零。
- 如果一个主体拥有弥散先验并获得一个信号，后验分布将是该信号的条件分布。

弥散先验下的贝叶斯更新

- 假设信号是 $s = \theta + \eta$，其中 $\eta \sim \mathcal{U}[-a, a]$。
- 应用均匀变量的贝叶斯法则并取极限 $b \to \infty$，得到后验分布：$\theta|s \sim \mathcal{U}[s-a, s+a]$。
- 换句话说，后验概率密度 $f(\theta|s)$ 在区间 $[s-a, s+a]$ 上是 $1/(2a)$，在其他地方是 0。
- 后验分布的形式与信号的形式相同，即后验只由信号的“误差窗口（区间）”确定。
- 如果先验是弥散的，但信号为正态分布，这个结果同样成立。

弥散先验的推论

- 这一性质的一个推论是，以下两个建模假设是等价的：
  1. Agent 先验是弥散的，看到信号再更新。
  2. Agent 一开始就持有 $f(\theta|s)$ 的信念。

案例：对完全未知市场价格判断中的弥散先验

背景设定： 一家初创公司试图判断某种新材料未来的市场价格 θ，但完全缺乏历史经验或专家先验，故可建模为弥散先验：

$$\theta \sim \mathcal{U}[-\infty, +\infty]$$

接收到一个信号： $s = \theta + \eta$，其中误差项 $\eta \sim \mathcal{U}[-2, 2]$。

问题： 公司在看到价格信号 $s = 10$ 后，应如何更新对 θ 的信念？

案例：对完全未知市场价格判断中的弥散先验

背景设定： 一家初创公司试图判断某种新材料未来的市场价格 θ，但完全缺乏历史经验或专家先验，故可建模为弥散先验：

$$\theta \sim \mathcal{U}[-\infty, +\infty]$$

接收到一个信号： $s = \theta + \eta$，其中误差项 $\eta \sim \mathcal{U}[-2, 2]$。

问题： 公司在看到价格信号 $s = 10$ 后，应如何更新对 θ 的信念？

结论：

- 根据贝叶斯更新，后验分布为：

$$\theta \mid s = 10 \sim \mathcal{U}[8, 12]$$

- 后验密度为：$f(\theta \mid s) = 1/4$ 在区间 $[8, 12]$ 内，其它为 0。
- 等价于认为 agent 拥有 $f(\theta \mid s)$ 为先验。

本节小结：从先验到后验的贝叶斯更新

核心逻辑

- 贝叶斯定理将“数据/信号”与“先验信念”结合，形成后验分布
- 在二项模型中，Beta 分布与 Bernoulli 数据天然匹配（共轭）
- 在均匀模型下，先验与信号的交集决定了后验的区间与形状
- 当先验为弥散分布时，后验即为似然的标准化版本

方法论启发

贝叶斯推理不仅是概率计算工具，更是“如何使用数据修正信念”的理论框架，是建模、政策与经济行为决策的重要基础。

思考与讨论

- 在什么情形下，你会认为“无先验”（弥散先验）是合理的建模假设？
- 如果一个 agent 不相信先验知识，而完全依赖于数据信号，他的判断会比有经验的人更好吗？
- 数据质量（例如 a 的大小）如何影响后验的收缩程度？在经济决策中有哪些类似现象？
- 在预测技术投资回报、市场趋势、政策效果时，贝叶斯视角能提供哪些新视角？

我们如何相信数据？我们又该如何使用信念？