Lecture 3：贝叶斯定理在经济学建模中的应用

谢佳松

东北财经大学

Fall 2026

目录

1. 职业关注模型
2. 线性—二次协调博弈
3. 数据共享博弈
4. 公共数据与创新边界

参考论文 I



Holmstrom, Bengt. 1999. "Managerial Incentive Problems: A Dynamic Perspective."*The Review of Economic Studies*, 66(1): 169–182.



Morris, Stephen, and Hyun Song Shin. 2002. "Social Value of Public Information."*American Economic Review*, 92(5): 1521–1534.



Acemoglu, Daron, Ali Makhdoumi, Azarakhsh Malekian, and Asu Ozdaglar. 2022. "Too Much Data: Prices and Inefficiencies in Data Markets."*AEJ: Microeconomics.*,14(4): 218-256.



谢佳松、樊嘉诚、林建浩，2025:《信息摩擦、公共数据与企业创新边界》,《经济研究》第 11 期：51–69。

一、声誉激励与职业关注模型

Holmstrom（1999）

为什么研究职业关注（Career Concerns）？

- 现实职场中：
  - 年轻员工/分析师的晋升与薪酬，取决于上级对其**能力**的评价。
  - 学术界的 tenure、职称评审，依赖同行对研究**能力**的判断。
- 难点：每个人的能力 θ 不可见（一个未知状态），只能通过含噪声的绩效信号间接推断。
- 个人的**努力** a 不可验证，**经理/市场**只能根据**绩效** X 来更新对能力的信念。
- 问题：如何用贝叶斯更新刻画“信号 $\Rightarrow$ 声誉 $\Rightarrow$ 努力”的机制？

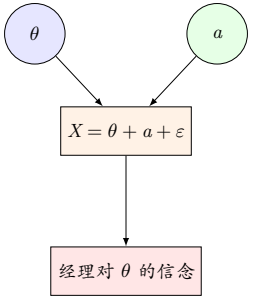
$$\text{努力}\, a \quad \longrightarrow \quad \text{绩效}\, X \quad \longrightarrow \quad \text{经理更新}\, \mathbb{E}[\theta \mid X] \quad \longrightarrow \quad \text{未来回报}$$

委托代理问题与职业关注（Career Concerns）

委托代理问题中的核心难点：信息不对称——CEO 与股东、经理与员工、大学老师与学生。

- **委托人（经理/公司）**希望根据绩效考核来判断**代理人（员工/经理）**的能力与努力。
- 但是：**能力 θ 不可观测，努力 a 不可验证**，只能通过含噪声的绩效信号 X 来推断。————员工的努力，大学老师的真实水平。

问题：当回报取决于市场/经理对能力的信念时，个体会如何选择努力？



能力不可见 $\Rightarrow$ 绩效信号噪声 $\Rightarrow$ 信息更新与激励扭曲

应用 1：职业关注模型

- 我们的第一个应用是求解 Holmstrom（1999）关于职业关注模型的两期版本。
- 这个模型旨在探讨在信息不对称的环境下，代理人（员工）如何通过努力来影响管理者对其“类型”的评估，从而影响其职业声誉和未来的报酬。
- Holmstrom, Bengt. 1999. “Managerial Incentive Problems: A Dynamic Per-spective.”The Review of Economic Studies, 66(1): 169–182.
- 进入模型前，我们先思考一个现实问题：员工（学生）如何确定自己的努力程度？老板如何确定员工的能力？
- 在缺乏正式激励合同的情况下，员工如何为了提升自己在劳动力市场的声誉而付出相应的努力？

Holmstrom (1999)：两期职业关注模型（简化版）

基本设定:

- 参与者：模型存在一个代理人（员工）和一个委托人（经理）。
- 代理人类型: 代理人有一个**固定但未知的能力** θ，影响其绩效。θ 服从均值为 μ、方差为 σ_θ^2 的正态分布，即 $\theta \sim \mathcal{N}(\mu, \sigma_\theta^2)$（经理与个体均未知）。
- 代理人努力：第一期：代理人选择一个努力水平 $a \geq 0$，付出该努力所需的成本 $c(a) = \frac{1}{2}a^2$(递增)。
- 绩效信号：代理人的类型和努力共同决定了一个可观察到的绩效信号 X:

$$X = \theta + a + \varepsilon, \qquad \varepsilon \sim \mathcal{N}(0, \sigma_\varepsilon^2), \quad \theta \perp \varepsilon. \tag{1}$$

- 其中，ε 是一个均值为零、方差为 σ_ε^2 的正态噪声项，且与 θ 独立。

Holmstrom (1999)：两期职业关注模型（简化版）

- 第二期，经理根据第一期观测到的绩效 X 来更新对代理人能力 θ 的信念。代理人获得的报酬就是管理者对他们能力的期望。
- 一个直观的发现是，由于经理无法观察到 a，该期望基于经理可能错误设定的 X 分布认知。
- 对于任意的 $a \in \mathbb{R}_+$，令 $\mathbb{E}_a(\theta \mid X)$ 表示在 $X = \theta + a + \varepsilon$ 条件下 θ 的条件期望。如果经理预期代理人会选择努力水平 a^*，而代理人实际选择的努力水平为 a，则代理人的总预期收益为：

$$U(a; a^*) = \mathbb{E}^a \left[\mathbb{E}^{a^*}(\theta \mid X) \right] - c(a) \tag{2}$$

- 其中，内部期望值 $\mathbb{E}^{a^*}(\theta \mid X)$ 是经理对代理人类型的预期；
- 而 $\mathbb{E}^a \left[\mathbb{E}^{a^*}(\theta \mid X) \right]$ 是代理人对经理的预期。

Holmstrom (1999)：两期职业关注模型（简化版）

- 公式 $U(a; a^*) = \mathbb{E}^a \left[\mathbb{E}^{a^*}(\theta \mid X) \right] - c(a)$ 的意义：
- 这个公式是员工的效用函数，它描述了员工在给定市场（管理者）预期 a^* 的情况下，选择实际努力 a 所能获得的总效用。
- 分开来看，$\mathbb{E}^{a^*}(\theta \mid X)$ 是市场（管理者）的信念。管理者看不到员工实际的努力 a，他只能假设员工选择了某个特定的努力水平 a^*，意味着，管理者需要认为员工会按其自身最优策略行动 a^* 进行决策（博弈论思想）。
- 因此，管理者计算的是：在假设员工努力为 a^* 的前提下，给定观测到的 X，员工能力 θ 的条件期望，即

$$\mathbb{E}^{a^*}(\theta \mid X)$$

- 思考，管理者的预期 a^* 是否为员工的真实努力水平？——理性预期

直观案例：a 与 a^* 到底有什么不同？

案例：程序员赶项目。真实能力 θ 无法直接观察；经理只能看到交付绩效 $X = \theta + a + \varepsilon$，再据此推断能力。

员工的实际努力 a

- 员工自己知道真实付出；例如实际加班 3 小时，即 $a = 3$。
- a 直接进入绩效 X，并由员工承担努力成本 $c(a)$。

经理的预期努力 a^*

- 经理看不到 a，只能预期员工会加班 2 小时，即 $a^* = 2$。
- a^* 是经理解读 X、推断能力时的**评价基准**，不是另一份努力。

一句话总结

a 是员工的**实际选择**，a^* 是经理的**预期与推断基准**；理性预期均衡要求 $a = a^*$，但二者的经济含义不同。

Holmstrom (1999)：两期职业关注模型（简化版）

- $\mathbb{E}^a\left[\mathbb{E}^{a^*}(\theta \mid X)\right]$ 是员工对市场信念的预期，即员工视角下的预期收益
- 现在我们站在员工的角度看问题：
- 员工知道自己的实际努力是 a。员工也知道管理者会用 a^* 来解读 X，并据此形成对 θ 的期望 $\mathbb{E}^{a^*}(\theta \mid X)$。
- 员工关心的是：在我实际付出努力 a 的情况下，管理者对我能力的期望值 $\mathbb{E}^{a^*}(\theta \mid X)$ 的平均值是多少？这就是外围 $\mathbb{E}^a[...]$ 的含义。
- 更重要的是，在理性预期均衡中，所有人的预期都必须是正确的。这意味着，市场对你的努力 a^* 的信念，必须等于你实际选择的最优努力 a (FOC 需满足 $a = a^*$)。

Holmstrom (1999)：两期职业关注模型（简化版）

Claim 1: 存在唯一均衡，其中代理人的均衡努力为

$$a^* = \frac{\sigma_\theta^2}{\sigma_\theta^2 + \sigma_\varepsilon^2}.$$

直觉：信号越精确（$\sigma_\varepsilon^2 \downarrow$）或能力越不确定（$\sigma_\theta^2 \uparrow$），努力越“值钱”，$a^* \uparrow$。

如何证明？

目标： 证明唯一均衡努力水平为：

$$a^* = \frac{\sigma_\theta^2}{\sigma_\theta^2 + \sigma_\varepsilon^2}.$$

步骤 1：均衡条件 (FOC)

$$\frac{\partial}{\partial a}\mathbb{E}^{a}\big[\mathbb{E}^{a^*}(\theta \mid X)\big]\Big|_{a=a^*} = a^*.$$

步骤 2：贝叶斯更新（线性高斯情形）

$$\mathbb{E}^{a^*}(\theta \mid X) = \frac{\sigma_\theta^2}{\sigma_\theta^2 + \sigma_\varepsilon^2}\,(X - a^*) + \frac{\sigma_\varepsilon^2}{\sigma_\theta^2 + \sigma_\varepsilon^2}\,\mu.$$

步骤 3：代入 $X = \theta + a + \varepsilon$，对 θ, ε 取期望

$$\mathbb{E}^{a}\big[\mathbb{E}^{a^*}(\theta \mid X)\big] = \mu + \frac{\sigma_\theta^2}{\sigma_\theta^2 + \sigma_\varepsilon^2}\,(a - a^*).$$

步骤 4：代回均衡条件，解出 a^*

$$\frac{\sigma_\theta^2}{\sigma_\theta^2 + \sigma_\varepsilon^2} = a^* \quad \Longrightarrow \quad a^* = \frac{\sigma_\theta^2}{\sigma_\theta^2 + \sigma_\varepsilon^2}.$$

结论： 均衡努力唯一确定，取决于 **能力不确定性**与 **信号精度**。

核心公式与经济学直觉

$$a^* = \frac{\sigma_\theta^2}{\sigma_\theta^2 + \sigma_\varepsilon^2}$$

- **分子** σ_θ^2：能力的不确定性（区分度）——“有人行有人不行”
- **分母** $\sigma_\theta^2 + \sigma_\varepsilon^2$：总不确定性——“工作表现还受运气影响”
- 当能力方差 σ_θ^2 减小时（区分度低），均衡努力 a^* 也减小。——如果市场对能力的不确定性较小，努力就越不重要，因为努力对市场更新信念的边际效应会减弱。
- 当你对自己的能力越不确定，且绩效信号越可靠时，你越愿意努力“证明自己”。

类比：面试中的努力

面试官不知道你真实能力（θ），只能看表现（$X = \theta + a + \varepsilon$）。
当你面临的任务或岗位区分度很高，且运气成分很低时，你付出的努力 a^* 才最容易被市场识别和定价，因此你会有最大的动力去努力（因为你的努力能转化为未来的高收益）。

现实案例：职业关注问题无处不在

案例 1：投行分析师的“拼命文化”

- 新人能力未知（σ_θ^2 高），第一年表现决定是否留用/升职。
- 绩效评估相对清晰（σ_ε^2 较低）$\rightarrow$ 努力回报高。
- 结果：新人自愿加班、主动承担项目 $\rightarrow$ a^* 很大。

案例 2：学术界的“非升即走”与学术不端问题

- 青年教师能力未被确认，6 年内需发表顶刊。
- 期刊审稿有噪音（σ_ε^2 高），但学校仍用论文数评估。
- 为应对审稿噪音，青年教师倾向于“安全型研究”或“高产策略”，牺牲创新性与长期价值 $\rightarrow$ a^* 过度。

政策启示

- 减少绩效噪音，设计更科学制度，提升考核规范性 $\rightarrow$ 提高 a^*
- 增加能力透明度（如技能认证）$\rightarrow$ 降低 σ_θ^2 $\rightarrow$ 降低过度努力

从基准设定到模型拓展

基准模型回顾：

$$X = \theta + a + \varepsilon, \qquad \theta \sim \mathcal{N}(\mu, \sigma_\theta^2),\ \ \varepsilon \sim \mathcal{N}(0, \sigma_\varepsilon^2).$$

- 经理只能观察绩效 X，并通过贝叶斯更新来推断能力 θ。
- 均衡努力水平：$a^* = \dfrac{\sigma_\theta^2}{\sigma_\theta^2 + \sigma_\varepsilon^2}$。

思考：现实中信息结构可能更加复杂——你要是做一篇新论文，可以从哪些角度扩展这个模型？

从基准设定到模型拓展

基准模型回顾：

$$X = \theta + a + \varepsilon, \qquad \theta \sim \mathcal{N}(\mu, \sigma_\theta^2),\ \ \varepsilon \sim \mathcal{N}(0, \sigma_\varepsilon^2).$$

- 经理只能观察绩效 X，并通过贝叶斯更新来推断能力 θ。
- 均衡努力水平：$a^* = \dfrac{\sigma_\theta^2}{\sigma_\theta^2 + \sigma_\varepsilon^2}$。

思考：现实中信息结构可能更加复杂——你要是做一篇新论文，可以从哪些角度扩展这个模型？

- 除了绩效，还能额外获得**关于能力**的 signal（例：学历、证书、推荐信）。
- 或者，额外获得**关于噪声**的 signal（例：市场基准、外部环境等）。

这两种信息扩展 $\Rightarrow$ 不同的激励效果，正好可以对比分析。

扩展一：额外的绩效信号

假设除了工人的绩效信号外，企业（通过收集关于工人类型的额外数据）能够单独观察到一个额外信号 S。

现实动机（S 的来源）：

- 背景调查/推荐信：学校、实习、前雇主评价（间接反映能力 θ）。
- 证书与考试：CFA/CPA/编程竞赛/资格考试等（带噪的“能力测评”）。
- 行为/心理测评：在线测评、代码面试、作品集审核。
- 平台数据：GitHub/论文发表记录/比赛排名/模拟交易成绩等。

扩展设定（在基线 $X = \theta + a + \varepsilon$ 基础上），有一个额外信号 S：

$$S = \theta + \delta, \qquad \delta \sim \mathcal{N}(0, \sigma_\delta^2), \quad \delta \perp (\theta, \varepsilon).$$

经理仍用**预期努力** a^* 去“去偏”绩效：$Y \equiv X - a^* = \theta + \varepsilon$。

直觉：公司拿到了“关于类型”的额外噪声观测，不再仅依赖员工的当期努力 a。

扩展一：额外的绩效信号（改用精度写法）

用**精度**（precision）$\tau \equiv 1/\sigma^2$ 表示更简洁：

$$\tau_\theta = \frac{1}{\sigma_\theta^2}, \quad \tau_\varepsilon = \frac{1}{\sigma_\varepsilon^2}, \quad \tau_\delta = \frac{1}{\sigma_\delta^2}.$$

联合正态的后验均值（经理在 a^* 下的更新）：

$$\mathbb{E}(\theta \mid Y, S) \;=\; \frac{\tau_\theta \mu \;+\; \tau_\varepsilon Y \;+\; \tau_\delta S}{\tau_\theta + \tau_\varepsilon + \tau_\delta}, \qquad Y \equiv X - a^*.$$

外层对真实生成机制（含 a）取期望：

$$\mathbb{E}^{a}\big[\mathbb{E}^{a^*}(\theta \mid X, S)\big] \;=\; \mu \;+\; \underbrace{\frac{\tau_\varepsilon}{\tau_\theta + \tau_\varepsilon + \tau_\delta}}_{\kappa_{\theta\text{-extra}}} (a - a^*).$$

直觉：额外的信号 S“分走”了对 θ 的解释力，X 中由 a 带来的边际影响被稀释。

扩展一：额外的绩效信号

代理人目标：$\max_a \ \mathbb{E}^a[\mathbb{E}^{a^*}(\theta \mid X, S)] - \frac{1}{2}a^2$。

$$\Rightarrow \quad \frac{\partial}{\partial a} = \kappa_{\theta\text{-extra}} - a = 0, \qquad \kappa_{\theta\text{-extra}} = \frac{\tau_\varepsilon}{\tau_\theta + \tau_\varepsilon + \tau_\delta}.$$

均衡（$a = a^*$）：

$$\boxed{a^* = \frac{\tau_\varepsilon}{\tau_\theta + \tau_\varepsilon + \tau_\delta} = \frac{\frac{1}{\sigma_\varepsilon^2}}{\frac{1}{\sigma_\theta^2} + \frac{1}{\sigma_\varepsilon^2} + \frac{1}{\sigma_\delta^2}}}$$

比较静态：

- 相比基线 $a_0^* = \dfrac{\tau_\varepsilon}{\tau_\theta + \tau_\varepsilon}$，增加 $\tau_\delta \Rightarrow a^*$ **下降**。
- 直觉：能力被“独立测量”得更准后，操纵声誉的空间变小，员工努力激励减弱。

制度含义：

- *HR* 设计权衡：加大“入职前筛查/测评”会降低在职早期努力；若岗位更看重短期学习与适应，需平衡筛查强度。

拓展一的经济学直觉

- 信息稀释效应
- 在最初的模型中，员工之所以付出努力，是因为他们的努力 a 和能力 θ 都被混合在唯一的产出信号 X 中。市场无法完全区分这两者，因此当产出 X 表现好时，市场会将其归因于员工有更高的能力 θ，从而给予更高的预期薪酬。这给了管理者一个强烈的“职业顾虑激励”来付出努力。
- 然而，当引入了新的信号 $S = \theta + \delta$ 时，情况发生了根本性的变化：
  - 这个新信号 S 直接包含了关于管理者真实能力 δ 的信息。
  - 市场现在有了另一个学习管理者能力 θ 的渠道。
  - 由于市场可以从 S 中获取能力信息，它对产出 X 的依赖程度就降低了。
  - 因此，员工所付出的努力 a 对市场信念的 边际影响变小了。换句话说，每多付出一单位努力所带来的声誉提升收益变少了。
- 因此，额外、更直接的能力信息会削弱职业顾虑激励，导致员工付出更少的努力。
- 一句话总结：额外精准信号让能力更透明，努力对能力声誉的贡献变小，因此努力激励下降。

扩展二：额外的噪声信号

假设企业获得了一类数据，使其能更准确地监控工人所经历的绩效冲击（噪声的额外信号）：

- 业务背景数据：市场行情/突发事件/客户难度/舆情等（解释当期绩效中的外部冲击）。
- 工业/平台场景的传感器/日志：把生产噪声、系统抖动单独记录下来。
- 教育/科研评审：统一试卷难度、考试事故、审稿轮空等环境噪声的侧证。

意味着，市场现在能够更准确地将产出信号 X 中的能力和努力部分与随机噪声分离开来。扩展设定：

$$X = \theta + a + \varepsilon, \qquad S = \varepsilon + \delta, \qquad \delta \sim \mathcal{N}(0, \sigma_\delta^2), \ \ \delta \perp (\theta, \varepsilon).$$

经理仍用 a^* 去“去偏”：$Y \equiv X - a^* = \theta + \varepsilon$，但现在可用 S 校准 噪声。

扩展二：额外的噪声信号

关键： 由 $S = \varepsilon + \delta$ 得到

$$\varepsilon \mid S \sim \mathcal{N}\Big(\mathbb{E}[\varepsilon \mid S],\ \mathrm{Var}(\varepsilon \mid S)\Big), \qquad \mathrm{Var}(\varepsilon \mid S) = \frac{\sigma_\varepsilon^2\,\sigma_\delta^2}{\sigma_\varepsilon^2 + \sigma_\delta^2}.$$

令有效精度

$$\tau_{\varepsilon|S} \;=\; \frac{1}{\mathrm{Var}(\varepsilon \mid S)} \;=\; \frac{1}{\sigma_\varepsilon^2} + \frac{1}{\sigma_\delta^2} \;=\; \tau_\varepsilon + \tau_\delta.$$

后验均值（经理在 a^* 下的更新）：

$$\mathbb{E}(\theta \mid Y, S) \;=\; \frac{\tau_\theta \mu + \tau_{\varepsilon|S}\, Y}{\tau_\theta + \tau_{\varepsilon|S}}, \qquad Y \equiv X - a^*.$$

外层期望（含真实 a）：

$$\mathbb{E}^a\big[\mathbb{E}^{a^*}(\theta \mid X, S)\big] \;=\; \mu \;+\; \underbrace{\frac{\tau_{\varepsilon|S}}{\tau_\theta + \tau_{\varepsilon|S}}}_{\kappa_{\varepsilon\text{-extra}}}\,(a - a^*).$$

扩展二：额外的噪声信号

FOC 与均衡：

$$\frac{\partial}{\partial a} = \kappa_{\varepsilon\text{-extra}} - a = 0, \quad a = a^* \;\Rightarrow\; \boxed{a^* = \frac{\tau_{\varepsilon|S}}{\tau_\theta + \tau_{\varepsilon|S}} = \frac{\tau_\varepsilon + \tau_\delta}{\tau_\theta + \tau_\varepsilon + \tau_\delta}}.$$

比较静态：

- 相比基准 $a^* = \dfrac{\tau_\varepsilon}{\tau_\theta + \tau_\varepsilon}$，增加 $\tau_\delta \Rightarrow a^*$ **上升**（新努力总大于旧努力）。
- 直觉：噪声被更好地识别/扣除后，X 中可归因于努力的成分更清晰，此时操纵声誉更有效，努力激励增强。
- 新信号 S 帮助市场更好地将员工努力与随机绩效冲击区分开来。这提高了努力的边际收益，使得员工有更大的动力在均衡状态下付出更多的努力。

制度含义 & 进一步拓展：

- 绩效体系设计：引入对噪声的观察能提高员工努力程度。
- 内生信息获取：以成本 $C(\tau_\delta)$ 投入数据基础设施（日志/传感器/基准指数）来提升 τ_δ，提高 a^*。

总结与重要启示

- **模型核心经济学机制：**职业关注的的激励源于不完美信息下市场对员工行为的推断。
- **信息的作用：**信息的价值取决于其类型。
  - **关于能力的额外信息**（如学历）会削弱职业关注激励。
  - 关于噪声的额外信息（如过程监控）会增强职业关注激励。
- **现实联系：**
  - 解释了为什么在没有显性合同的情况下，员工依然有高努力的动力。
  - 揭示了信息设计的重要性：在设计组织或激励机制时，不仅要考虑信息量，还要考虑信息的类型。

二、公共信息与线性—二次协调模型

Morris & Shin（2002）

应用 2：线性—二次协调博弈（Morris & Shin, 2002）

- 贝叶斯定理在经济学中的另一个重要应用是信息级联与协调博弈。
- 信息级联：个体放弃私人信息，单纯跟随他人行动的现象。
- 经典的**信息级联**模型最早由 Banerjee (1992) 和 Bikhchandani, Hirshleifer & Welch (1992) 提出，用于解释**社会学习**与**从众行为**。
- Morris & Shin (2002) 将信息级联的思想引入到**金融市场**，分析投资者如何通过观察他人行为来推断资产的真实价值，从而影响市场均衡。
- 该模型揭示了在不完全信息下，投资者如何通过贝叶斯更新来协调他们的行动，从而导致市场价格的波动和金融危机的发生。
- Morris, Stephen, and Hyun Song Shin. 2002. “Social Value of Public Information.”American Economic Review, 92(5): 1521–1534.

模型设定

- 场景：两个代理人 $i=1,2$ 进行协调博弈，目标是同时选择行动 $a_i \in \mathbb{R}$，使其尽可能贴近一个**共同但未知的真实状态** $\theta \in \mathbb{R}$。
- 目标是：（1）贴近真实、共同的未知状态 θ；（2）与对方行动靠拢。
- **真实状态，未知的公共变量** θ：所有参与者都想与之匹配。它遵循正态分布，这代表了参与者在获得任何私人信息前的共同信念：
$$\theta \sim \mathcal{N}(\mu, \sigma_\theta^2)$$
- **私人信号** X_i：每个参与者 i 都会收到一个关于状态 θ 的私人信号 X_i。这个信号是带有噪声的，其公式为：
$$X_i = \theta + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, \sigma_\varepsilon^2) \text{ i.i.d.}$$
- 这意味着即使他们对 θ 的先验信念相同，他们的私人信号也会因这个噪声而有所不同。

模型设定

- 收益函数 U_i：每个参与者 i 的收益取决于他们自己的行动 a_i 和另一个参与者的行动 a_j。收益函数为（简化忽略成本）：

$$U_i(a_i, a_j) = -(1-\beta)(a_i-\theta)^2 - \beta(a_i-a_j)^2 \qquad \beta \in (0,1).$$

- 与状态的协调：第一项 $-(1-\beta)(a_i-\theta)^2$ 衡量了行动 a_i 与真实状态 θ 之间的偏差。当 a_i 越接近 θ，这一项的损失越小。

- 与对方的协调：第二项 $-\beta(a_i-a_j)^2$ 衡量了行动 a_i 与另一个参与者 a_j 之间的偏差。它反映了参与者希望与对方的行动保持一致，以实现协调。当 a_i 越接近 a_j，这一项的损失越小。

- 协调权重：参数 $\beta \in (0,1)$ 决定了两种协调目标的相对重要性。当 β 越大，参与者越看重与对方“协调”；当 β 越小，参与者越看重与状态 θ 的匹配。

- 最终目标：在信息不对称下，求解贝叶斯对称纳什均衡（BNE）。

均衡策略推导

我们将求解一个对称的线性贝叶斯纳什均衡（(a_1^*, a_2^*)）假设策略形式为线性：$a_i^*(X_i) = cX_i + \kappa$（在博弈论求解中，经常先假设均衡策略可能是某种线性形式，再进行验证）

步骤 1：由 FOC 求参与者的最优反应函数（类比古诺模型）

$$a_i^*(X_i) = (1-\beta)\mathbb{E}[\theta \mid X_i] + \beta(\mathbb{E}[a_j^*(X_j) \mid X_i] + \kappa)$$

带入对称线性策略形式

$$a_i^*(X_i) = (1-\beta)\mathbb{E}[\theta \mid X_i] + \beta(c\mathbb{E}[X_j \mid X_i] + \kappa)$$

步骤 2：计算条件期望

$$\mathbb{E}[\theta \mid X_i = x_i] = \frac{\sigma_\theta^2}{\sigma_\theta^2 + \sigma_\varepsilon^2} x_i + \frac{\sigma_\varepsilon^2}{\sigma_\theta^2 + \sigma_\varepsilon^2}\mu$$

$$\mathbb{E}[X_j \mid X_i] = \mathbb{E}[\theta \mid X_i]$$

步骤 3：基于线性策略形式求解系数 c 和 κ

$$c = \frac{(1-\beta)\sigma_\theta^2}{\sigma_\varepsilon^2 + (1-\beta)\sigma_\theta^2}$$

$$\kappa = \frac{\sigma_\varepsilon^2}{\sigma_\varepsilon^2 + (1-\beta)\sigma_\theta^2}\mu$$

均衡策略与比较静态分析

最终均衡策略：对称线性 BNE

$$a_i^*(x_i) = \frac{\sigma_\theta^2(1-\beta)}{\sigma_\varepsilon^2 + \sigma_\theta^2(1-\beta)}\, x_i + \frac{\sigma_\varepsilon^2}{\sigma_\varepsilon^2 + \sigma_\theta^2(1-\beta)}\, \mu, \qquad i = 1, 2.$$

这个策略均衡结果有几个重要的含义：

1. 行动是私人信号和先验信念的加权平均：参与者的最优行动是其私人信号 x_i 和先验均值 μ 的加权平均。
2. 权重取决于协调动机和信息精度
   - 信号噪声方差：分母中 σ_ε^2 越大，表示信号越不准确。此时，x_i 的权重越小，μ 的权重越大。这意味着当信号不准确时，参与者更依赖先验信念。
   - 先验不确定性：分母中 σ_θ^2 越大，表示先验越不确定。此时，x_i 的系数（权重）越大，μ 的系数越小。这意味着当先验不确定时，参与者更依赖私人信号。
   - 协调权重：β 越大，表示参与者越看重与对方的协调。此时，x_i 的系数（权重）越小，μ 的系数越大。这意味着当协调动机强时，参与者更倾向于跟随“大家都知道的”公共信息。——放弃私人信号。

经济含义与现实案例

关键洞见：

- **公共信息越强**（σ_θ^2 小）$\rightarrow$ 个体越依赖 μ，越忽略私人信号。
- **协调压力越大**（β 大）$\rightarrow$ 行动更趋同，可能引发“羊群行为”。
- **唯一纯策略均衡**：Morris & Shin (2002) 证明无其他均衡。

现实案例：

经济含义与现实案例

关键洞见：

- **公共信息越强**（σ_θ^2 小）$\rightarrow$ 个体越依赖 μ，越忽略私人信号。
- **协调压力越大**（β 大）$\rightarrow$ 行动更趋同，可能引发“羊群行为”。
- **唯一纯策略均衡**：Morris & Shin (2002) 证明无其他均衡。

现实案例：

- 金融危机：2008 年金融危机前，评级机构（AAA 评级）作为“高质量公共信号”，导致投资者忽视底层房贷风险（私人尽调信号），导致集体误判。
- 政策响应：央行预测通胀温和，但超市物价（你的私人信号）每天上涨 $\rightarrow$ 你本应调整消费，但为“不偏离主流”选择相信央行，导致个人财务受损 。
- 社交媒体：社交媒体算法推送“热门内容”（高质量公共信号）$\rightarrow$ 用户不再点击小众但有价值内容，导致信息茧房。

启示：高质量公共信息 $\neq$ 更优决策——可能导致信息多样性丧失。

集体行为悖论

- 常识：信息越准，决策越好。
- 但该模型揭示了一个集体行为的悖论：当所有人都依赖同一个高质量公共信号时，私人信息被系统性忽略，导致社会整体信息多样性丧失，反而可能做出更差的集体决策。
- 回顾均衡策略：

$$a_i^*(x_i) = \underbrace{\frac{(1-\beta)\sigma_\theta^2}{\sigma_\varepsilon^2 + (1-\beta)\sigma_\theta^2}}_{\text{私人信号权重}} x_i + \underbrace{\frac{\sigma_\varepsilon^2}{\sigma_\varepsilon^2 + (1-\beta)\sigma_\theta^2}}_{\text{公共先验权重}} \mu$$

- 当 $\sigma_\theta^2 \to 0$（公共信息极其精准）时，私人信号权重趋近于零，所有人行动趋同于 μ。
- 结果：个体失去利用私人信息的动力，社会整体信息多样性降低，可能导致集体决策失误。
- **政策含义**：在设计信息披露与传播机制时，需权衡公共信息的质量与多样性，避免过度依赖单一信息源。

集体行为悖论

领域	高质量公共信号	私人信号被忽略的后果
📈 金融市场	标普500指数、美联储声明	投资者忽视公司基本面 → 泡沫/崩盘
🏦 银行信贷	央行指导利率、行业评级	银行忽视企业实际现金流 → 坏账累积
📰 媒体舆论	热搜榜、主流媒体报道	用户不看小众真相 → 舆论极化、假新闻扩散
🩺 医疗决策	临床指南、权威论文	医生忽视患者个体差异 → 误诊

拓展：如果代理人还能观察到一个公共信号，结果如何？

原模型

$$\theta \sim \mathcal{N}(\mu, \sigma_\theta^2), \qquad X_i = \theta + \varepsilon_i.$$

X_i 只被个体 i 观察，因而每个人的行动可能不同。

新增公共信号

$$Y = \theta + \eta, \qquad \eta \sim \mathcal{N}(0, \sigma_\eta^2).$$

Y 被所有人同时观察：它既帮助判断 θ，也帮助预测“别人会怎么做”。

思考

央行的经济预测、评级机构的信用评级与企业自己的订单数据中，哪一类信息更容易使企业行动趋同？为什么？

拓展：如果代理人还能观察到一个公共信号，结果如何？

原模型

$$\theta \sim \mathcal{N}(\mu, \sigma_\theta^2), \qquad X_i = \theta + \varepsilon_i.$$

X_i 只被个体 i 观察，因而每个人的行动可能不同。

新增公共信号

$$Y = \theta + \eta, \qquad \eta \sim \mathcal{N}(0, \sigma_\eta^2).$$

Y 被所有人同时观察：它既帮助判断 θ，也帮助预测“别人会怎么做”。

思考

央行的经济预测、评级机构的信用评级与企业自己的订单数据中，哪一类信息更容易使企业行动趋同？为什么？

答案：公共信息。因为它是共同可见的行动锚点，而私人信息会使行动分散。

第一步：先用公共信号更新共同信念

将方差写成精度：

$$\tau_\theta = \frac{1}{\sigma_\theta^2}, \qquad \tau_y = \frac{1}{\sigma_\eta^2}.$$

所有人观察 $Y = y$ 后，得到相同的中间后验：

$$\theta \mid y \sim \mathcal{N}(m_y, V_y),$$

$$\boxed{m_y = \frac{\tau_\theta \mu + \tau_y y}{\tau_\theta + \tau_y}}, \qquad \boxed{V_y = \frac{1}{\tau_\theta + \tau_y}}.$$

- m_y：观察公共信号后，大家共同认为的基本面均值；
- V_y：公共信号更新后仍然存在的不确定性；
- $\tau_y \uparrow \Rightarrow m_y$ 更接近 y，且 $V_y \downarrow$。

关键技巧

给定 y 后，原模型仍然成立：只需把原来的先验均值 μ 换成 m_y，把先验方差 σ_θ^2 换成 V_y。

第二步：公共信号如何进入均衡行动？

在观察 $Y=y$ 后，个体 i 再观察私人信号 $X_i=x_i$。沿用原模型的对称线性均衡：

$$a_i^*(x_i,y)=c_y x_i+(1-c_y)m_y,$$

$$\boxed{c_y=\frac{(1-\beta)\,V_y}{\sigma_\varepsilon^2+(1-\beta)\,V_y}}$$

将 m_y 展开，就能看到三种信息共同决定行动：

$$\boxed{a_i^*=\underbrace{c_y}_{w_x}x_i+\underbrace{(1-c_y)\frac{\tau_y}{\tau_\theta+\tau_y}}_{w_y}y+\underbrace{(1-c_y)\frac{\tau_\theta}{\tau_\theta+\tau_y}}_{w_\mu}\mu},$$

$$w_x+w_y+w_\mu=1.$$

经济学直觉

Y 有“双重权重”：它因为预测 θ 而有信息权重，又因为大家都看得见而有协调权重。

比较静态：什么时候大家更容易跟随公共信号？

1. 公共信号更精确：$\sigma_\eta^2 \downarrow$（$\tau_y \uparrow$）$\Rightarrow w_y \uparrow$；
2. 私人信号更噪杂：$\sigma_\varepsilon^2 \uparrow \Rightarrow c_y \downarrow$，共同信念的权重上升；
3. 协调动机更强：$\beta \uparrow \Rightarrow c_y \downarrow$，个体更少依赖自己的 x_i。

思考：更精确的公共信息一定提高社会福利吗？

设所有企业都依据同一份宏观预测决定投资。如果这份预测恰好出错，高度协调会改变错误的后果吗？

比较静态：什么时候大家更容易跟随公共信号？

1. 公共信号更精确：$\sigma_\eta^2 \downarrow$（$\tau_y \uparrow$）$\Rightarrow w_y \uparrow$；
2. 私人信号更噪杂：$\sigma_\varepsilon^2 \uparrow \Rightarrow c_y \downarrow$，共同信念的权重上升；
3. 协调动机更强：$\beta \uparrow \Rightarrow c_y \downarrow$，个体更少依赖自己的 x_i。

思考：更精确的公共信息一定提高社会福利吗？

设所有企业都依据同一份宏观预测决定投资。如果这份预测恰好出错，高度协调会改变错误的后果吗？

答案

不一定。公共信号能减少个体之间的行动偏差，却也可能让所有人在同一个错误方向上行动。β 越大，这种“集体性错误”越可能被放大。

现实背景：公共信号为什么是一把“双刃剑”？

央行前瞻指引

它降低企业对利率路径的不确定性，也让市场围绕同一预期定价。若政策反应不及预期，价格可能同时大幅调整。

信用评级

统一评级降低投资者搜索成本，但如果所有机构都把同一评级当作准入标准，一次误评就可能成为系统性风险。

热搜与销量榜

榜单既反映真实热度，又影响每个人对“别人会选什么”的预期，因而可能形成自我强化的流行。

信息设计启示

除了提高公共信息的精度，还应披露不确定性区间、保留多元信息源，并避免把单一指标机械地变成统一行动标准。

三、数据外部性与数据共享博弈

Acemoglu et al.（2022）

应用 3：数据共享博弈（Acemoglu et al., 2022）

- 我们的第三个应用是 Acemoglu et al. (2022) 关于数据共享的模型。它是一个平台与两个数据代理人之间的博弈。
- Acemoglu, Daron, Ali Makhdoumi, Azarakhsh Malekian, and Asu Ozdaglar. 2022. “Too Much Data: Prices and Inefficiencies in Data Markets.”AEJ: Microeconomics.
- 基于现实的观察：为什么用户的数据不值钱？为什么平台不需要付费就能获得用户数据？
- 我们每天在社交媒体、搜索引擎、购物网站上留下大量数据（点击记录、位置、偏好等），但这些平台几乎从不直接向我们支付费用。
- 直觉上，数据是有价值的 $\rightarrow$ 应该付费 $\rightarrow$ 但现实中却与之相反
- Acemoglu et al.(2022) 用一个精巧的贝叶斯博弈模型揭示了一个关键机制：当用户类型高度相关时，平台可以通过“负外部性”降低激励成本，从而以更低甚至零成本诱导用户共享数据。

模型设定（Acemoglu et al., 2022）

- 参与者：存在一个**单一平台**和两个代理人（用户）$i = 1, 2$。
- 未知状态：每个代理人可能有两种类型 $\theta = (\theta_1, \theta_2)$，满足联合正态分布：

$$\begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix} \right)$$

- 即：θ_1 和 θ_2 均值为 0，方差均为 1，相关系数为 ρ（等于协方差）。ρ 越大，表示用户越相似（比如同龄人、同地区、同类兴趣）。——ρ 的经济学含义?
- 私人信号 X_i：每个代理人 i 私下能够观察关于自己的一个带噪声信号：

$$X_i = \theta_i + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, 1).$$

- 这意味着：用户通过自己的行为（如浏览历史）获得了对自己类型的“私人信号”。

模型设定（Acemoglu et al., 2022）

- 行动选择 a_i：每个代理人 i 有两个行动选项：$a_i = 1$：分享数据，即分享信号 X_i；$a_i = 0$：不分享数据，即保留信号 X_i。记行动组合为 $a = (a_1, a_2)$。
- 平台收益：平台的收益来自其对 θ 的不确定性的减少，设定为后验方差的负数，即 $U_P(a) = -v \cdot \mathrm{Var}(\theta \mid X_a)$。平台向代理人 i 提出支付 p_i，来激励他们分享数据 X_i。
- 代理人收益（效用）：每个代理人 i 的收益 U_i 包括两部分：隐私成本，平台的不确定性：$Var(\theta \mid X_a)$ 和平台的支付 p_i。
- 因此，代理人 i 的收益为：

$$u_i(a, p) \;=\; v \cdot \mathrm{Var}(\theta_i \mid X_a) + p_i \cdot \mathbf{1}(a_i = 1),$$

其中：

  - $v > 0$：隐私参数，表示代理人希望保持对自己类型的**不确定性**；用户越重视隐私，v 越大。
  - $\mathrm{Var}(\theta_i \mid X_a)$：平台在观测到共享数据集 X_a 后，对 θ_i 的后验不确定性（方差）——即个体隐私。

- 问题：平台对用户数据的定价策略是什么？

推导与证明技巧

1. 若 $\theta \sim \mathcal{N}(0, \sigma_\theta^2)$，观测 $X = \theta + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, \sigma_\varepsilon^2)$ 独立，则 $\mathrm{Var}(\theta \mid X) = \left(\frac{1}{\sigma_\theta^2} + \frac{1}{\sigma_\varepsilon^2}\right)^{-1}$. 在该模型设定下，$\sigma_\theta^2 = 1$, $\sigma_\varepsilon^2 = 1$，有：
$$\mathrm{Var}(\theta \mid X) = \tfrac{1}{2}$$
2. 若 $\begin{pmatrix} A \\ B \end{pmatrix} \sim \mathcal{N}\Big(\mathbf{0}, \begin{pmatrix} \sigma_A^2 & \sigma_{AB} \\ \sigma_{AB} & \sigma_B^2 \end{pmatrix}\Big)$，则
$$\mathrm{Var}(A \mid B) = \sigma_A^2 - \frac{\sigma_{AB}^2}{\sigma_B^2}.$$
3. 在该模型设定下,$\mathrm{Var}(X_j) = \mathrm{Var}(\theta_j) + \mathrm{Var}(\varepsilon_j) = 1 + 1 = 2$，$\mathrm{Cov}(\theta_i, X_j) = \mathrm{Cov}(\theta_i, \theta_j) = \rho$, 因此:
$$\mathrm{Var}(\theta_i \mid X_j) = 1 - \frac{\rho^2}{2}.$$

(1) 平台使两人都分享的支付情形 $p^{(2)}$

设 $(\theta_1,\theta_2)\sim\mathcal{N}\left(\begin{pmatrix}0\\0\end{pmatrix},\begin{pmatrix}1&\rho\\\rho&1\end{pmatrix}\right)$，$X_i=\theta_i+\varepsilon_i$，$\varepsilon_i\sim\mathcal{N}(0,1)$ 独立。

只见 X_j（i 不分享）：

$$\mathrm{Var}(\theta_i\mid X_j)=1-\frac{\rho^2}{2}\quad\Rightarrow\quad u_i^{\mathsf{no}}=v\left(1-\frac{\rho^2}{2}\right).$$

在已知 X_j 基础上再见 X_i（i 分享）：

$$\mathrm{Var}(\theta_i\mid X_i,X_j)=\left(\frac{1}{1-\rho^2/2}+1\right)^{-1}=\frac{2-\rho^2}{4-\rho^2},\qquad u_i^{\mathsf{yes}}=v\cdot\frac{2-\rho^2}{4-\rho^2}+p_i.$$

使 i 愿意分享的最小支付（无差异 $u_i^{\mathsf{yes}}\geq u_i^{\mathsf{no}}$）：

$$\boxed{p_i^{(2)}=v\left(1-\frac{\rho^2}{2}-\frac{2-\rho^2}{4-\rho^2}\right)=v\cdot\frac{(2-\rho^2)^2}{2(4-\rho^2)}}.$$

若要两人都分享（对称）：

$$\boxed{P^{(2)}=2p_i^{(2)}=v\cdot\frac{(2-\rho^2)^2}{4-\rho^2}}.$$

(2) 平台只让一人分享的支付情形 $p^{(1)}$

不分享：对 θ_1 的不确定性为先验方差 1，故

$$u_1^{\mathsf{no}} = v.$$

分享：单变量先验（方差 1）＋噪声方差 1 的观测 X_1，

$$\mathrm{Var}(\theta_1 \mid X_1) = \frac{1}{1+1} = \frac{1}{2}, \qquad u_1^{\mathsf{yes}} = \frac{v}{2} + p_1.$$

使该用户愿意分享的最小支付：

$$\boxed{p_1^{(1)} = \frac{v}{2}}.$$

恰好一人分享（对另一人给不超过 $v/2$ 使其拒绝）$\Rightarrow$

$$\boxed{P^{(1)} = \frac{v}{2}}.$$

(3) 何时“两人都分享”更便宜?

比较总成本：$P^{(2)} < P^{(1)}$

$$v \cdot \frac{(2-\rho^2)^2}{4-\rho^2} < \frac{v}{2} \iff \frac{(2-\rho^2)^2}{4-\rho^2} < \frac{1}{2} \iff 2\rho^4 - 7\rho^2 + 4 < 0.$$

令 $t = \rho^2 \in [0,1]$:

$$2t^2 - 7t + 4 < 0 \quad \Rightarrow \quad t \in \Big(\frac{7-\sqrt{17}}{4},\ \frac{7+\sqrt{17}}{4}\Big).$$

由于 $t \le 1$，得到阈值

$$\boxed{\rho^2 \ \ge \ \frac{7-\sqrt{17}}{4} \ \approx \ 0.71}.$$

解读：当相关性高（ρ 大）时（经济含义是?），第二位用户的边际信息含量低，因而诱使两人同时分享的总补偿反而低于只买一人的数据。

(4) 结论与启示

模型结论：

- 当用户数据高度相关时（ρ 较大），单个用户的边际信息价值下降。
- 平台在均衡下可能以更低支付同时诱使多人分享数据。
- 在极限情形下，用户数量多且数据高度相关，单个用户的补偿趋近于零。

经济学含义：

- 数据的负外部性：一个用户的分享降低了其他用户的议价能力。
- 数据的公共品特征：平台视角下，数据间高度可替代。
- 解释现实现象：在大规模数据流情况下，在线平台往往不向用户补偿其数据价值。

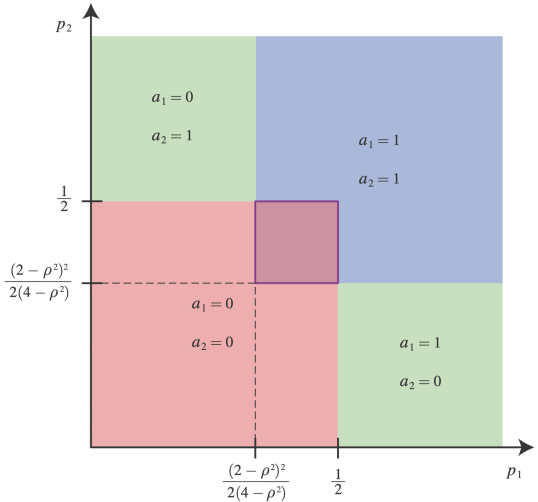
现实案例与经济学启示

现实案例：

- **社交媒体：** Facebook/抖音收集数亿用户数据，单个用户数据的边际价值趋零。
- **地图导航：** 高德/Google Maps 依赖海量司机上传数据，个体边际价值极小。
- **语音助手：** Siri/Bixby 语音样本越多，单用户贡献越低。
- **金融风控：** 征信平台大数据覆盖下，新增个体数据对整体模型影响有限。

这支持了“免费模式”的可持续性：平台通过聚合大量相关数据，实现信息效率最大化。但也引发了隐私权与数据所有权的伦理争议。

用户均衡


p_2
$a_1 = 0$
$a_2 = 1$
$a_1 = 1$
$a_2 = 1$
$\frac{1}{2}$
$\frac{(2-\rho^2)^2}{2(4-\rho^2)}$
$a_1 = 0$
$a_2 = 0$
$a_1 = 1$
$a_2 = 0$
$\frac{(2-\rho^2)^2}{2(4-\rho^2)}$
$\frac{1}{2}$
p_1

拓展：从“分享或不分享”到“匿名化分享”

原模型中，用户只有两种选择：完整分享 X_i 或完全不分享。现实中还有一个中间选择：

$$\widetilde{X}_i = X_i + \nu_i = \theta_i + \varepsilon_i + \nu_i, \qquad \nu_i \sim \mathcal{N}(0, \sigma_\nu^2).$$

完整分享

$\sigma_\nu^2 = 0$
精度高，平台价值高，但用户隐私损失大。

匿名化分享

$0 < \sigma_\nu^2 < \infty$
通过加噪、分组或脱敏，在信息价值与隐私之间折中。

不分享

$\sigma_\nu^2 \to \infty$
平台几乎无法从该数据中学习，用户隐私最强。

新的经济学问题

隐私保护并非只是“要或不要”，而是应选择多大的 σ_ν^2？这取决于隐私收益与数据失真成本的权衡。

匿名化如何改变数据价值?

先看单个用户。因为 $\mathrm{Var}(\theta_i)=1$，且原始测量噪声 $\mathrm{Var}(\varepsilon_i)=1$，观察匿名化数据后：

$$\mathrm{Var}(\theta_i \mid \widetilde{X}_i)=\left(1+\frac{1}{1+\sigma_\nu^2}\right)^{-1}=\boxed{\frac{1+\sigma_\nu^2}{2+\sigma_\nu^2}}.$$

平台从该数据中获得的信息价值，可用“后验方差降低量”表示：

$$\Delta V(\sigma_\nu^2)=1-\mathrm{Var}(\theta_i \mid \widetilde{X}_i)=\boxed{\frac{1}{2+\sigma_\nu^2}}.$$

- $\sigma_\nu^2=0$：$\mathrm{Var}(\theta_i \mid X_i)=1/2$，$\Delta V=1/2$；
- $\sigma_\nu^2\uparrow$：平台的后验方差上升，数据价值下降；
- $\sigma_\nu^2\to\infty$：$\mathrm{Var}(\theta_i \mid \widetilde{X}_i)\to 1$，数据几乎不再提供信息。

匿名化的本质：用一部分信息精度，换取更多隐私保护。

课堂练习：应该选择多强的匿名化？

假设隐私保护给用户带来的收益为

$$B(\sigma_\nu^2) = \frac{\sigma_\nu^2}{1+\sigma_\nu^2},$$

数据失真给平台造成的成本为

$$C(\sigma_\nu^2) = \lambda\sigma_\nu^2, \qquad \lambda > 0.$$

社会规划者选择 $z = \sigma_\nu^2 \geq 0$ 使净收益最大：

$$\max_{z\geq 0} \; W(z) = \frac{z}{1+z} - \lambda z.$$

请思考

一阶条件是什么？最优噪声 z^* 如何随数据失真成本 λ 变化？

课堂练习：应该选择多强的匿名化？

假设隐私保护给用户带来的收益为

$$B(\sigma_\nu^2) = \frac{\sigma_\nu^2}{1+\sigma_\nu^2},$$

数据失真给平台造成的成本为

$$C(\sigma_\nu^2) = \lambda\sigma_\nu^2, \qquad \lambda > 0.$$

社会规划者选择 $z = \sigma_\nu^2 \geq 0$ 使净收益最大：

$$\max_{z\geq 0} \; W(z) = \frac{z}{1+z} - \lambda z.$$

请思考

一阶条件是什么？最优噪声 z^* 如何随数据失真成本 λ 变化？

$$W'(z) = \frac{1}{(1+z)^2} - \lambda = 0 \quad \Rightarrow \quad \boxed{z^* = \max\left\{\frac{1}{\sqrt{\lambda}} - 1,\, 0\right\}}.$$

$\lambda \uparrow \Rightarrow z^* \downarrow$：医疗诊断、金融风控等对精度敏感的场景，应使用更少噪声，并配合更严格的访问控制。

现实制度：隐私保护不只有“删除数据”

差分隐私

在统计结果中加入可控噪声，限制单个用户对输出的影响。常用于统计发布和终端数据收集。

联邦学习

原始数据留在医院或设备本地，只交换模型更新。它降低原始数据集中泄露风险，但不能自动消除所有隐私风险。

医疗数据脱敏

删除姓名和证件号还不够；罕见病、时间与地域组合仍可能实现重新识别。因此需要分级授权与安全计算环境。

制度启示

同一个“隐私强度”不适用于所有数据。合理制度应联合选择加噪强度、访问权限、用途限制与违规责任。

四、公共数据、信息精度与创新边界模型

谢佳松等（2025）

应用 4：公共数据如何拓展企业创新边界？

- 企业选择研发方向时，无法直接观察外部创新基本面 θ：政策导向、技术趋势与市场机会均存在信息摩擦。
- 企业拥有生产经营形成的**私有数据**，政府开放平台进一步提供所有企业可共同使用的**公共数据**。
- 两类数据都是关于 θ 的含噪信号；数据价值首先体现为提高预测精度、降低研发决策的不确定性。
- 但公共数据还有第二层作用：它是**共同知识**，能够帮助创新网络中的企业协调研发方向。

模型的核心问题

为什么同一份公共数据，对突破式创新更有价值，并最终推动企业创新边界拓展？

资料来源：谢佳松等（2025），《经济研究》第 11 期。

第一步：把创新中的信息摩擦写进模型

企业 f 从事创新类型 $i \in \{d, m\}$：d 表示突破式创新，m 表示渐进式创新。研发策略为 a_{fi}。

$$A_{fi} = \bar{A} - L_i(a_{fi}), \qquad L_i(a_{fi}) = (1 - r_i)(a_{fi} - \theta)^2 + r_i(a_{fi} - \bar{a}_i)^2.$$

匹配基本面

$(a_{fi} - \theta)^2$：研发方向偏离真实技术机会或政策环境所造成的预测损失。

匹配创新网络

$(a_{fi} - \bar{a}_i)^2$：研发方向偏离合作伙伴和行业共同方向所造成的协调损失。

$r_i \in (0, 1)$ 衡量创新对协同的依赖。模型设定 $r_d > r_m$：突破式创新更依赖跨组织知识、资源与技术协作。

第二步：私有数据与公共数据都是信号

企业不能直接观察 θ，只能观察两类关于创新基本面的数据：

$$\underbrace{s_f^{pr} = \theta + e_f}_{\text{私有数据形成的信号}}, \qquad e_f \sim \mathcal{N}(0, \tau_e^{-1}),$$

$$\underbrace{s^{pb} = \theta + \xi}_{\text{公共数据形成的信号}}, \qquad \xi \sim \mathcal{N}(0, \tau_\xi^{-1}).$$

- τ_e、τ_ξ 是信号**精度**：精度越高，噪声方差越小，数据越有信息。
- s_f^{pr} 只被企业 f 观察，体现企业之间的信息差异。
- s^{pb} 被所有企业共同观察，既提供信息，又形成协调研发预期的共同参照。
- 未开放公共数据可表示为 $\tau_\xi = 0$；开放且具有有效信息则为 $\tau_\xi > 0$。

第三步：贝叶斯更新如何提高预测精度？

基准模型采用弥散先验。给定信息集 $\Omega_f = \{s_f^{pr}, s^{pb}\}$，正态信号的后验均值为精度加权平均：

$$\mathbb{E}(\theta \mid \Omega_f) = \frac{\tau_e}{\tau_e + \tau_\xi} s_f^{pr} + \frac{\tau_\xi}{\tau_e + \tau_\xi} s^{pb}, \qquad \mathrm{Var}(\theta \mid \Omega_f) = \frac{1}{\tau_e + \tau_\xi}.$$

与基准模型的直接联系

新增公共数据使后验精度从 τ_e 提高到 $\tau_e + \tau_\xi$。因此，公共数据的基本价值是减少对创新环境的预测误差，而不是直接替代研发投入。

- $\tau_\xi \uparrow$：后验方差下降，企业对基本面的判断更稳定；
- $\tau_e \uparrow$：企业自身数据更可靠，对公共信号的相对依赖下降。

第四步：从贝叶斯信念到最优研发策略

企业在信息集 Ω_f 下最小化预期效率损失：

$$a_{fi}^* = \arg\min_{a_{fi}} \mathbb{E}[L_i(a_{fi}) \mid \Omega_f].$$

一阶条件给出：

$$a_{fi}^* = (1 - r_i)\mathbb{E}(\theta \mid \Omega_f) + r_i\mathbb{E}(\bar{a}_i \mid \Omega_f).$$

猜测并验证对称线性策略 $a_{fi}^* = (1 - \phi_i)s_f^{pr} + \phi_i s^{pb}$，得到：

$$\boxed{a_{fi}^* = (1 - \phi_i)s_f^{pr} + \phi_i s^{pb}, \qquad \phi_i = \frac{\tau_\xi}{\tau_\xi + \tau_e(1 - r_i)}}$$

关键区别

如果只考虑预测，公共信号权重由相对精度决定；加入策略互补后，协调需求 r_i 还会进一步放大公共数据的权重。

权重公式告诉了我们什么？

$$\phi_i = \frac{\tau_\xi}{\tau_\xi + \tau_e(1 - r_i)}$$

- **公共数据质量：** $\tau_\xi \uparrow \Rightarrow \phi_i \uparrow$。数据更准确，研发策略更靠近公共信号。
- **私有数据质量：** $\tau_e \uparrow \Rightarrow \phi_i \downarrow$。企业已有高质量专有知识时，新增公共数据的相对影响较小。
- **协同依赖：** $r_i \uparrow \Rightarrow \phi_i \uparrow$。越需要与外部伙伴协作，越需要共同可见的数据来形成一致预期。

突破式创新为什么反应更强？

$r_d > r_m \Rightarrow \phi_d > \phi_m$。公共数据不仅让企业“看得更准”，还让高度互补的创新主体“朝着可协调的方向行动”。

数据如何转化为研发效率？

在最优策略下，企业的预期研发效率为：

$$A_{fi}^{*} = \bar{A} - \Sigma_i, \qquad \boxed{\Sigma_i = \frac{1 - r_i}{\tau_\xi + \tau_e(1 - r_i)}}.$$

Σ_i 汇总了信息摩擦产生的两类损失：对基本面的预测误差，以及与创新网络的协调误差。

没有公共数据：$\tau_\xi = 0$

$$\Sigma_i^0 = \frac{1}{\tau_e}.$$

企业只能依靠私有信息，不同创新类型没有获得公共信息的额外优势。

开放公共数据：$\tau_\xi > 0$

$$\Sigma_i^1 < \Sigma_i^0.$$

后验更精确、协调偏差更小，因而研发效率提高。

从研发效率到创新边界

企业分别选择突破式创新强度 x_d^* 与渐进式创新强度 x_m^*。模型中，研发投入随预期研发效率提高而增加：

$$x_i^* \text{ 随 } A_i^* = \bar{A} - \Sigma_i \text{ 单调增加.}$$

以两类研发强度之比刻画创新边界：

$$\widetilde{x} \equiv \frac{x_d^*}{x_m^*}, \qquad \widetilde{x} \text{ 随 } A_d^* - A_m^* = \Sigma_m - \Sigma_d \text{ 增加.}$$

当公共数据开放且 $r_d > r_m$ 时：

$$\Sigma_d^1 < \Sigma_m^1 \quad \Longrightarrow \quad A_d^* > A_m^* \quad \Longrightarrow \quad \boxed{\widetilde{x}(\tau_\xi > 0) > \widetilde{x}(\tau_\xi = 0)}.$$

核心结论

公共数据对协同依赖更高的突破式创新改善更大，促使企业把更多研发资源配置到新技术路径，推动创新边界外移。

两条机制：信息供给与协调强化

信息供给效应

- 公共数据增加关于 θ 的独立信号；
- 后验精度提高、预测方差下降；
- 企业更准确地识别政策、技术与市场机会；
- 研发资源错配减少。

协调强化效应

- 公共数据是所有主体可见的共同知识；
- 合作各方更容易形成一致预期；
- 沟通、匹配和跨组织协作成本下降；
- 对 r_i 较高的创新价值更大。

公共数据开放 $\Rightarrow$ 看得更准 + 更易协同 $\Rightarrow$ 研发效率提高 $\Rightarrow$ 创新边界拓展

现实拓展：开放数据不等于自动产生价值

1. **普及程度有限：**只有部分企业能够发现、获取或使用公共数据时，信息供给与协调效应都会打折；覆盖企业越广，公共信息越接近真正的共同知识。
2. **接收者噪声：**同一数据若结构混乱、口径不清，不同企业会形成不同理解。接收噪声越大，有效精度越低，协同效果越弱。
3. **企业既有先验：**经验丰富、先验精度高的企业本已掌握较多信息，新增公共数据对其信念的边际更新可能更小。
4. **企业需求异质：**公共数据主要刻画共同趋势，私有数据更贴近企业特定技术目标；二者通常是互补而非简单替代。

数据要素政策含义

除“开放多少”外，还应重视数据质量、元数据与口径解释、接口可用性、企业数据能力及跨主体协作机制；这些条件共同决定有效精度 τ_ξ。

拓展一：刻画不同企业面对同一份公共数据，收益的异质性

设企业 f 的数据能力为 $q_f > 0$。原始公共信号精度为 τ_ξ，企业实际可以利用的有效精度为：

$$\boxed{\tau_{\xi f} = q_f \tau_\xi}.$$

将原模型中的 τ_ξ 换成 $q_f\tau_\xi$，得到：

$$\phi_{if} = \frac{q_f\tau_\xi}{q_f\tau_\xi + \tau_e(1-r_i)}, \qquad \Sigma_{if} = \frac{1-r_i}{q_f\tau_\xi + \tau_e(1-r_i)}.$$

- $q_f \uparrow \Rightarrow \phi_{if} \uparrow$：企业更能读懂和使用公共数据；
- $q_f \uparrow \Rightarrow \Sigma_{if} \downarrow$：预测与协调损失下降，研发效率提高；
- 因此，只增加数据供给，可能让数据能力强的企业率先受益。

政策含义

公共数据开放与数据能力建设是互补品：标准化接口、数据字典、人才培训与公共算力都可以提高 q_f。

课堂练习：数据能力如何改变研发损失?

设突破式创新的协同依赖为 $r_d = 0.6$，私有数据精度 $\tau_e = 2$，公共数据原始精度 $\tau_\xi = 1$。

$$\Sigma_{df} = \frac{1 - r_d}{q_f \tau_\xi + \tau_e(1 - r_d)}.$$

请分别计算

数据能力较弱的企业 $q_L = 0.5$ 与数据能力较强的企业 $q_H = 2$，其研发损失 Σ_{dL} 和 Σ_{dH} 各为多少?

课堂练习：数据能力如何改变研发损失?

设突破式创新的协同依赖为 $r_d = 0.6$，私有数据精度 $\tau_e = 2$，公共数据原始精度 $\tau_\xi = 1$。

$$\Sigma_{df} = \frac{1 - r_d}{q_f \tau_\xi + \tau_e(1 - r_d)}.$$

请分别计算

数据能力较弱的企业 $q_L = 0.5$ 与数据能力较强的企业 $q_H = 2$，其研发损失 Σ_{dL} 和 Σ_{dH} 各为多少?

$$\Sigma_{dL} = \frac{0.4}{0.5 \times 1 + 2 \times 0.4} = \frac{0.4}{1.3} \approx \boxed{0.308},$$

$$\Sigma_{dH} = \frac{0.4}{2 \times 1 + 2 \times 0.4} = \frac{0.4}{2.8} \approx \boxed{0.143}.$$

面对完全相同的开放数据，高能力企业的研发损失更低。数据开放可能扩大企业间的数字鸿沟。

拓展二：高精度但有偏的公共数据

现实中的公共数据可能非常稳定，却存在系统性偏差：

$$s^{pb} = \theta + b + \xi, \qquad \mathbb{E}(\xi) = 0,$$

其中 $b \neq 0$ 是因统计口径、样本选择或模型设定造成的偏差。

课堂思考

当噪声方差 $\mathrm{Var}(\xi)$ 趋近于零时，这份数据变得极其“精确”。它是否一定能提高企业决策质量？

拓展二：高精度但有偏的公共数据

现实中的公共数据可能非常稳定，却存在系统性偏差：

$$s^{pb} = \theta + b + \xi, \qquad \mathbb{E}(\xi) = 0,$$

其中 $b \neq 0$ 是因统计口径、样本选择或模型设定造成的偏差。

课堂思考

当噪声方差 $\mathrm{Var}(\xi)$ 趋近于零时，这份数据变得极其“精确”。它是否一定能提高企业决策质量？

答案：精度不等于准确性

如果企业没有识别出 b，它会将“稳定的偏差”当成“可靠的信息”。当 τ_ξ 或 r_i 较高时，公共信号权重 ϕ_i 更大，所有企业会更一致地偏离真实的 θ。

- 历史招聘数据可能把过去的性别或学历偏好当成“成功规律”；
- 历史交通数据在大型活动当日可能系统性失效；
- 若市场主体都依赖同一有偏数据源，协调效应还会放大集体错误。

课堂小结：这一模型和前面模型的联系

- **与职业关注模型相通：**信号精度改变贝叶斯权重，进而改变主体的最优行为。
- **与协调博弈相通：**公共信息不仅帮助预测，还会成为协调行动的共同锚点。
- **与数据共享博弈相通：**数据具有跨主体关联与外部性，其价值不能只按单条记录理解。
- **本模型的新增之处：**把上述信息机制嵌入企业异质性创新选择，解释公共数据为什么更可能推动创新边界而非只增加常规创新。

本课程最应记住的公式

$$\text{后验精度} = \tau_e + \tau_\xi, \qquad \phi_i = \frac{\tau_\xi}{\tau_\xi + \tau_e(1 - r_i)}.$$

数据价值既取决于**信息精度**，也取决于数据进入决策与协同过程的**组织环境**。