Lecture 4 动态信念更新与滤波

谢佳松

东北财经大学

Fall 2026

目录

1. 卡尔曼滤波
2. 卡尔曼-布西滤波
3. 带跳跃的卡尔曼-布西滤波
4. 伯努利随机变量的连续时间滤波

一、卡尔曼滤波

在离散时间状态空间模型中，通过“预测—观测—修正”递归更新对隐藏状态的信念

回顾第 2-3 讲：贝叶斯更新（核心：静态）

- 核心任务：用数据 s 更新对未知状态 θ 的信念。
- 以线性高斯 + 无偏数据情形为例：$\theta \sim \mathcal{N}(\mu_\theta, \tau_\theta^{-1})$，$s = \theta + \eta$，$\eta \sim \mathcal{N}(0, \tau_s^{-1})$。

$$\mathbb{E}[\theta \mid s] = \frac{\tau_\theta \mu_\theta + \tau_s s}{\tau_\theta + \tau_s}, \qquad \mathrm{Var}(\theta \mid s) = \frac{1}{\tau_\theta + \tau_s}.$$

- 等价性：在无偏独立噪声下，**后验均值 = 总体最优线性预测**（可靠度加权）。
- 扩展：有偏信号的再校准、总方差定律、非高斯更新（Bernoulli–Beta、均匀先验等）、弥散先验。

静态假设的局限

静态假设的局限：

- 真实世界中，宏观状态、风险参数等，几乎一切的变量都在**随时间演化**；
- 数据是**序列化**到达的（股票、价指数），需要边观测边更新。
- 更广义地说，甚至先验，$f(\theta)$，也是之前无数轮的后验形成的——思考之前的案例。

核心问题：当 状态本身在变 时，如何**持续**、**实时**地更新我们的信念？

典型场景：

- 央行用高频数据预测经济；投资者用价格与成交量**跟踪**内在价值。
- 工业传感器**在线监测**设备状态。
- 医疗中用连续生命体征**追踪**病情。
- 雷达实时更新飞行器具体位置。

现实中的动态学习问题

- 当状态本身在变化时，我们如何持续地更新我们的信念？
- 实际上，我们需要随时间“更新”对不可观测状态的信念——这是数据驱动学习的核心。例如：
  - 宏观经济学中，中央银行需要根据不断变化的经济数据（如通胀率、失业率）动态估计经济的真实状况。
  - 金融市场中，投资者需要根据价格、成交量等信息动态推断资产的“内在价值”。
  - 工业生产中，自动化系统需要根据传感器数据实时估计机器的运行状态或故障概率。
  - 医疗领域，医生根据患者的连续检测数据动态判断病情的进展。
- 这些场景都有一个共性：**状态变量不可观测，需要动态估计**。

滤波与卡尔曼滤波

- **问题引出**：能否用一种系统的方法**根据已有数据估计不可见变量**，并**随着数据流入持续更新**？（对比上一讲内容静态数据流设定：$S = \theta + \eta$）。
- 这正是滤波（Filtering）技术的核心目标。滤波旨在从一系列带有噪声的观测数据中，估计出隐藏状态变量的真实值。
- 滤波是一种核心的统计工具，其本质是利用数据来预测（prediction）和减少不确定性（reduces uncertainty）。
- 在 Data Economy 中，数据被视为数字化信息，可以帮助我们对未来经济相关的结果做出更精准的预测，从而降低其中的不确定性。
- 当我们将贝叶斯更新应用于正态分布变量的动态模型时，在线性状态与观测方程、联合高斯假设下，其递推就是卡尔曼滤波 (Kalman Filter)。

卡尔曼滤波的本质

卡尔曼滤波提供了一套优雅且高效的递归公式，用于在动态系统中，通过一系列带有噪声的测量值，估计出隐藏状态变量的真实值。

鲁道夫·卡尔曼

鲁道夫·卡尔曼 [编辑]

31种语言

条目 讨论 大陆简体 阅读 编辑 查看历史 工具

维基百科，自由的百科全书

匈牙利语人名顺序为先姓后名。此条目中的译名遵从此顺序。

鲁道夫·埃米尔·卡尔曼（匈牙利语：Rudolf Emil Kálmán[3]，1930年5月19日—2016年7月2日）是一名匈牙利裔美国电机工程师、数学家和发明家。他最著名的是共同发明和开发卡尔曼滤波，这是一种数学算法，被广泛用于信号处理、控制系统和制导、导航和控制。由于这项工作，美国总统奥巴马于2009年10月7日授予卡尔曼美国国家科学奖章[4]。



生平 [编辑]

1930年5月19日出生于布达佩斯。

1943年移民美国，并于1953年和1954年分别获得麻省理工学院电机工程学士学位和硕士学位。

1957年在哥伦比亚大学完成他的博士学位。

1958年至1964年，卡尔曼在马里兰州巴尔的摩高级研究机构担任研究数学家。

1964年至1971年，他在斯坦福大学担任教授，然后于1971年至1992年在佛罗里达大学担任研究生研究教授和数学系统理论中心主任。

1969年至1972年，他定期回到国立巴黎高等矿业学校担任自动研究中心的科学顾问。1973年起，他还在瑞士联邦理工学院担任数学系统理论的主席。

2016年7月2日上午，在他位于佛罗里达州盖恩斯维尔的家中去世[5]。

卡尔曼滤波

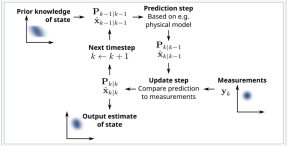
卡尔曼滤波 [编辑]

33种语言

条目 讨论 汉 漢 大陆简体 阅读 编辑 查看历史 工具

维基百科，自由的百科全书

卡尔曼滤波（英语：Kalman filter）是一种高效率的递归滤波器（自回归滤波器），它能够从一系列的不完全及包含噪声的测量中，估计动态系统的状态。卡尔曼滤波会根据各测量量在不同时间下的值，考虑各时间下的联合分布，再产生对未知变量的估计，因此会比只以单一测量量为基础的估计方式要准。卡尔曼滤波得名自主要贡献者之一的鲁道夫·卡尔曼。



卡尔曼滤波器会追踪系统的估计状态，以及估计的变异量或是不确定性。会透过状状态变换模型以及其量测来更新估计值。$\hat{x}_{k|k-1}$ 是指时间k时的估计，还没有考虑第k次量测y_k的信息，$P_{k|k-1}$为对应的不确定性

卡尔曼滤波在技术领域有许多的应用。常见的有飞机及太空船的导引、导航及控制[1]。卡尔曼滤波也广为使用在时间序列的分析中，例如信号处理及计量经济学中。卡尔曼滤波也是机器人运动规划及控制的重要主题之一，有时也包括在轨迹优化。卡尔曼滤波也用在中轴神经系统运动控制的建模中。因为从给与运动命令到收到感觉神经的回授之间有时间差，使用卡尔曼滤波有助于建立符合实际的系统，估计运动系统的目前状态，并且更新命令[2]。

卡尔曼滤波的算法是二步骤的程序。在估计步骤中，卡尔曼滤波会产生有关目前状态的估计，其中也包括不确定性。只要观察到下一个量测（其中一定含有某种程度的误差，包括随机噪声）。会通过加权平均来更新估计值，而确定性越高的量测加权比重也越高。算法是迭代的，可以在实时控制系统中执行，只需要目前的输入量测、以往的计算值以及其不确定性矩阵，不需要其他以往的信息。

使用卡尔曼滤波不用假设误差是正态分布[3]，不过若所有的误差都是正态分布，卡尔曼滤波可以得到正确的条件概率估计。

也发展了一些扩展或是广义的卡尔曼滤波，例如运作在非线性系统的扩展卡尔曼滤波及无迹卡尔曼滤波（英语：unscented Kalman filter）。底层的模型类似隐马尔可夫模型，不过潜在变量的状态空间是连续的，而且所有潜在变量及可观测变量都是正态分布。

为什么叫滤波 (Filtering)?

核心直觉

- 在动态学习中，我们观测到的信号 s_t 往往是 **真实状态 θ_t 加上噪声**。
- 我们的目标：**从嘈杂的信号中提取出最接近真实状态的成分**。
- 这就像工程学中的“滤波”：从嘈杂的信号中“滤掉噪声”。

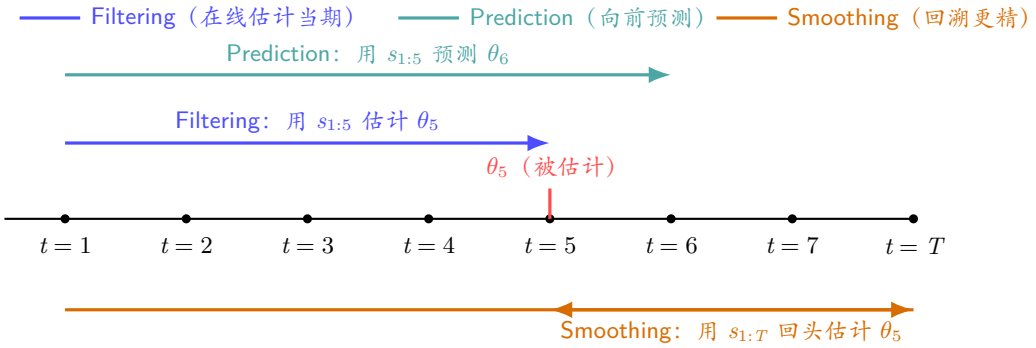
Filtering 与其他相关概念的区分

- **Filtering (滤波)**：基于 $1{:}t$ 期数据，估计当期状态 θ_t。
- **Prediction (预测)**：基于 $1{:}t$ 期数据，预测未来状态 $\theta_{t+1}, \theta_{t+2}, \ldots$。
- **Smoothing (平滑)**：基于 $1{:}T$ 全部数据，回头估计过去状态 θ_t。

通俗比喻

- 戴上降噪耳机：耳机实时接收含噪声的声音，并“滤波”后让你听到接近真实的音乐。
- 滤波：每一期“听到”数据后，滤掉噪声，得到对真实状态的最佳估计。

Filtering / Prediction / Smoothing 的时间轴对比



- **Filtering**：基于 $s_{1:t}$ 估计当期 θ_t（实时、在线；卡尔曼滤波）。
- **Prediction**：基于 $s_{1:t}$ 预测未来 θ_{t+1}、s_{t+1}（一步或多步预测）。
- **Smoothing**：基于全样本 $s_{1:T}$ 回头估计过去 θ_t（离线、更精确）。

卡尔曼滤波的数学设定

- 前面我们直观区分了 Filtering / Prediction / Smoothing，现在需要一个数学框架来刻画“状态如何演化”和“我们如何观测到信号”。

卡尔曼滤波的数学设定

- 前面我们直观区分了 Filtering / Prediction / Smoothing，现在需要一个数学框架来刻画“状态如何演化”和“我们如何观测到信号”。

1. 状态方程 (State Equation)

一个未知的状态变量，θ_t 随时间的线性演化：

$$\theta_{t+1} = D\theta_t + Fe_{t+1}, \quad e_{t+1} \sim \mathcal{N}(0,1)$$

卡尔曼滤波的数学设定

- 前面我们直观区分了 Filtering / Prediction / Smoothing，现在需要一个数学框架来刻画“状态如何演化”和“我们如何观测到信号”。

1. 状态方程 (State Equation)

一个未知的状态变量，θ_t 随时间的线性演化：

$$\theta_{t+1} = D\theta_t + Fe_{t+1}, \quad e_{t+1} \sim \mathcal{N}(0,1)$$

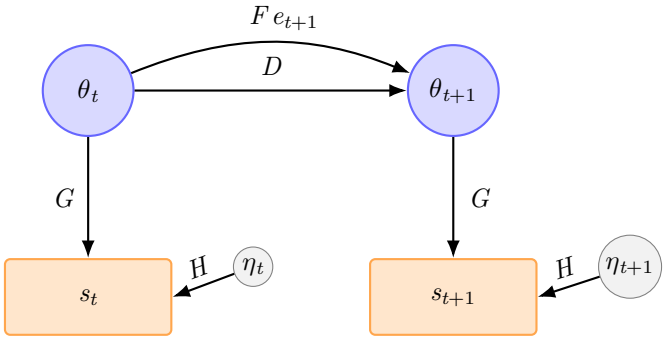
2. 观测方程 (Observation Equation)

在每个周期 t，我们能观测到一个与 θ_t 相关的数据信号：

$$s_t = G\theta_t + H\eta_t, \quad \eta_t \sim \mathcal{N}(0,1)$$

- 我们无法直接观测 θ_t，只能通过观测数据 s_t 来学习。
- 假设 e_t 和 η_t 独立且跨期 i.i.d.，这是卡尔曼滤波能闭式求解的关键。
- 这两个方程即为卡尔曼滤波的核心方程。

卡尔曼滤波的状态空间图示



- 上层：状态变量 θ_t 随时间演化（状态方程）——预测
- 下层：观测 s_t 来自 θ_t 加上观测噪声（观测方程）——更新
- 这就是典型的状态空间模型 (State-Space Model)，卡尔曼滤波即在此框架下推导。

用回归形式来理解 Kalman 滤波

- 总结：我们看不见“真相”(θ_t，如飞机真实位置、经济变量)，但能看见“带噪的影子”(s_t，如雷达检测位置、传感器读数)，我们要用这些影子去猜真相，并且每次看到新影子时都更新我们的猜测。
- 核心：预测 + 更新
- 卡尔曼滤波是一个递归算法，它的核心循环只有两个步骤：预测 → 观测 → 更新 → 预测 → 观测 → 更新 → ...
- 当我们发现观测值和预测值不一致时 ($s_t \neq G\hat{\theta}_t$)，我们就知道我们的状态估计 $\hat{\theta}_t$ 可能不准了，需要调整。而调整的方向和幅度，就由这个“偏差”($s_t - G\hat{\theta}_t$) 来决定。
- 卡尔曼滤波核心更新步骤可以被理解为一种回归：用观测信号与预测信号的偏差，去解释和修正状态估计的误差。——最优线性估计器。

用回归形式来理解 Kalman 滤波

- 在状态空间模型中：
  - 状态 θ_t 不可观测；
  - 信号 s_t 可观测；
  - 我们的目标是：利用 s_t 来不断更新对 θ_t 的估计。
- Kalman 滤波的关键思想：
  - **预测（Prediction）**：基于过去信息得到 $\hat{\theta}_t$；
  - **更新（Update）**：利用新观测 s_t 来修正 $\hat{\theta}_t$。
  - 整个过程为：预测 $\rightarrow$ 观测 $\rightarrow$ 更新 $\rightarrow$ 预测 $\rightarrow \ldots$
- 为了更直观地理解更新步骤，我们可以把它改写为：

回归视角

$$\theta_t - \hat{\theta}_t \quad \text{回归于} \quad (s_t - G\hat{\theta}_t)$$

即："真实状态与预测值的差（预测偏差）"由"观测信号的偏差（信号偏差）"来解释。

先看一个例子：今天室外到底多少度？

我们看不到真实气温 θ_t，只能结合过去信息与带噪读数判断。为方便说明，令观测矩阵 $G = 1$。

1. 预测：先有一个估计

根据昨天到今天的降温趋势，预测：

$$\hat{\theta}_t = 18^\circ\mathrm{C}, \qquad G\hat{\theta}_t = 18^\circ\mathrm{C}.$$

$G\hat{\theta}_t$ 是由旧信息预测出的“应该看到的读数”。

2. 观测：新数据到来

打开窗户看温度计，它显示：

$$s_t = 20^\circ\mathrm{C}.$$

温度计也可能有误差，所以不应立即把估计改成 $20^\circ\mathrm{C}$。

3. 偏差：新数据带来多少“意外”？

$$\underbrace{s_t - G\hat{\theta}_t}_{\text{创新项 / news}} = 20 - 18 = 2^\circ\mathrm{C}.$$

这个正偏差告诉我们：之前的温度预测偏低了。

4. 修正：只吸收可信的部分

若对新观测的信任权重为 $\beta_t = 0.8$：

$$\beta_t(s_t - G\hat{\theta}_t) = 0.8 \times 2 = 1.6,$$

$$\boxed{\hat{\theta}_{t|t} = 18 + 1.6 = 19.6^\circ\mathrm{C}}.$$

从例子到卡尔曼滤波：新估计 = 原预测 + 信任权重 × 观测偏差

$$\boxed{\hat{\theta}_{t|t} = \hat{\theta}_t + \beta_t(s_t - G\hat{\theta}_t)}.$$

Kalman 滤波的回归形式

我们希望用 s_t 来更新对 θ_t 的估计：

定义

- 令 $\hat{\theta}_t \equiv \mathbb{E}[\theta_t \mid s_{t-1}, ..., s_0]$，为时点 t 前的状态预测；
- 令状态估计的先验精度为 $\hat{\Sigma}_t^{-1} = [\mathrm{Var}(\theta_t \mid s_0, s_1, \ldots, s_{t-1})]^{-1}$；
- 定义状态误差项（待纠正部分）：$\theta_t - \hat{\theta}_t$；
- 信号观测偏差项（创新部分）：$s_t - G\hat{\theta}_t$。

这里的“回归”是给定过去信息的总体线性投影：用模型的协方差求最优系数，并非每期拿不可观测的 θ_t 运行样本 OLS。下列期望均在过去信息集下计算。**最小二乘形式为：**

$$\theta_t - \hat{\theta}_t = \beta_t(s_t - G\hat{\theta}_t) + \nu_t \tag{1}$$

其中 ν_t 是回归残差，满足正交性条件：

$$\mathbb{E}[\nu_t(s_t - G\hat{\theta}_t)'] = 0 \tag{2}$$

补充知识复习：OLS 回归

- 在 OLS 回归中，我们通过最小化残差平方和来估计参数 β：

$$\hat{\beta} = \arg\min_{\beta} \sum_{i=1}^{n} (y_i - X_i\beta)^2$$

即：

$$\min_{\beta_t} \mathbb{E}\left[\left(\theta_t - \hat{\theta}_t - \beta_t(s_t - G\hat{\theta}_t)\right)^2\right]$$

- 根据 OLS 原理，残差项 ν_t 应该和解释变量正交：

$$\mathbb{E}\left[\nu_t(s_t - G\hat{\theta}_t)'\right] = 0$$

因此：

$$\mathbb{E}\left[(\theta_t - \hat{\theta}_t)(s_t - G\hat{\theta}_t)'\right] = \beta_t \mathbb{E}\left[(s_t - G\hat{\theta}_t)(s_t - G\hat{\theta}_t)'\right]$$

- 在卡尔曼滤波中，我们类似地通过最小化预测误差来更新对状态的估计。

Kalman 滤波的回归形式

- 如何计算 β_t?
- 由公式:

$$\mathbb{E}\left[\nu_t(s_t - G\hat{\theta}_t)'\right] = 0$$

- 请推导出: β_t 的表达式。

Kalman 滤波的回归形式

- 如何计算 β_t?
- 由公式:

$$\mathbb{E}\left[\nu_t(s_t - G\hat{\theta}_t)'\right] = 0$$

- 请推导出: β_t 的表达式。

$$\beta_t = \hat{\Sigma}_t G'(G\hat{\Sigma}_t G' + HH')^{-1} \tag{3}$$

Kalman 滤波的回归形式

- 有了 β_t 的表达式，我们可以将其代入到卡尔曼滤波的更新公式中。
- 由 $\theta_{t+1} = D\theta_t + Fe_{t+1}$，

$$\theta_{t+1} = D\hat{\theta}_t + D(\theta_t - \hat{\theta}_t) + Fe_{t+1} \tag{4}$$

- 代入回归形式：

$$\theta_{t+1} = D\hat{\theta}_t + D\beta_t(s_t - G\hat{\theta}_t) + D\nu_t + Fe_{t+1} \tag{5}$$

- 对上式按截至 t 的信息取条件期望，得到卡尔曼滤波的均值更新公式：

$$\hat{\theta}_{t+1} = D\hat{\theta}_t + \underbrace{D\hat{\Sigma}_t G'(G\hat{\Sigma}_t G' + HH')^{-1}}_{\equiv K_t \text{ Kalman gain}} \underbrace{(s_t - G\hat{\theta}_t)}_{\text{news}}$$

- news表示：不能从过去数据中预测出来、真正带来更新的新信息。

对 news 的理解

- news表示：不能从过去数据中预测出来、真正带来更新的新信息。
- 如果 $s_t = G\hat{\theta}_t$，说明观测值完全符合预期 → 没有新信息 →均值不变，但后验方差仍会下降。
- 如果 $s_t \neq G\hat{\theta}_t$，说明观测值与预期不符 → 实际观测偏离了预测 → 有额外新信息 → 需要根据偏差调整状态估计。

总结

这正是卡尔曼滤波的核心思想：用新信息不断修正旧估计。

- 想象你是一个天气预报员：你根据昨天的模型预测今天气温是 20°C；但今天实际测得是 25°C；差值 5°C 就是“news”。
- ——它告诉你模型可能低估了升温趋势，你需要据此调整明天的预测。

Kalman 滤波的回归形式

- 简写前面这个等式，我们就得到了卡尔曼滤波的核心公式：

$$\hat{\theta}_{t+1} = D\hat{\theta}_t + K_t(s_t - G\hat{\theta}_t) \tag{6}$$

- 第一项 $D\hat{\theta}_t$ 为无当期新观测时的下一期预测；本式已把当期更新与下一期预测合并。
- 第二项为基于最新观测数据对先验的误差修正项，根据预测误差 $s_t - G\hat{\theta}_t$ 调整估计。K_t 是卡尔曼增益 (Kalman gain)，反映了我们对信号的信任程度，即决定了信号的权重。类似于贝叶斯更新中的权重项：$\tau_s/(\tau_s + \tau_\theta)$。
- 卡尔曼增益 K_t 的计算公式为：

$$K_t = D\hat{\Sigma}_t G'(G\hat{\Sigma}_t G' + HH')^{-1} \tag{7}$$

- 其中，$\hat{\Sigma}_t$ 是预测误差协方差矩阵。衡量了在看到第 t 期观测数据 s_t 之前，我们对当前状态 θ_t 的“不确定性”有多大。——先验方差。
- $G\hat{\Sigma}_t G'$ 代表了先验信息的不确定性。
- HH' 为信号噪声，代表了数据信息的不确定性。

深入理解 Kalman 增益

- 卡尔曼增益 K_t 是一个动态调整的信任权重：它衡量了“当前预测的不确定性”与“观测噪声的不确定性”之间的相对大小——预测越不准、观测越准，K_t 就越大，我们就越相信新数据。

$$K_t = \underbrace{D}_{\text{状态权重}} \cdot \underbrace{\hat{\Sigma}_t}_{\text{预测误差协方差}} \cdot \underbrace{G'}_{\text{观测映射转置}} \cdot \underbrace{(G\hat{\Sigma}_t G' + HH')^{-1}}_{\text{观测残差协方差的逆}}$$

- 在一维且 $D, G > 0$ 的情形，当观测噪声 $\mathbf{HH}'$ 很大（数据精度低）时：分母增大，导致 $\mathbf{K}_t$ 变小。这与贝叶斯公式中 τ_s 变小导致数据权重变小一致。
- 当先验预测误差 $\mathbf{G}\hat{\Sigma}_t\mathbf{G}'$ 很小（先验精度高）时：分母相对减小，分子减小。如果分子 $\hat{\Sigma}_t$ 很小，将导致 $\mathbf{K}_t$ 变小。这与贝叶斯公式中 τ_θ 变大导致 $\mathbf{S}$ 权重变小一致。
- 分子 $\mathbf{D}\hat{\Sigma}_t\mathbf{G}'$：先验不确定性。主要由预测误差协方差 $\hat{\Sigma}_t$ 驱动。当分子（先验不确定性）越大，意味着我们对先验估计越不自信，因此卡尔曼增益 $\mathbf{K}_t$ 也会越大，从而给观测数据更大的权重，以修正不准确的先验估计。

Kalman 滤波的回归形式

- 更新后的状态方差为：

$$\hat{\Sigma}_{t+1} = (D - K_t G)\hat{\Sigma}_t (D - K_t G)' + FF' + K_t HH' K_t' \tag{8}$$

- 其中，第一项，$(D - K_t G)\hat{\Sigma}_t (D - K_t G)'$：是对状态方差的预测更新，反映了系统动态对状态不确定性的影响。
- 第二项：状态方程的系统扰动引入的新不确定性：FF' 为状态噪声的协方差矩阵。
- 第三项：$K_t HH' K_t'$ 是观测噪声经增益传递后的方差，必须取正号。
- 通过这种方式，卡尔曼滤波能够在每个时间点根据最新的观测数据 s_t 动态更新对状态 θ_t 的估计 $\hat{\theta}_t$，并调整对未来状态的预测。

卡尔曼滤波的核心思想

等价的“新增减消除”形式为

$$\hat{\Sigma}_{t+1} = D\hat{\Sigma}_t D' + FF' - D\hat{\Sigma}_t G'(G\hat{\Sigma}_t G' + HH')^{-1} G\hat{\Sigma}_t D'.$$

Kalman Filter 的特例结构：一维 AR(1) 状态模型

在单变量、一阶自回归过程的特殊情况下，卡尔曼滤波的公式可以简化，这有助于理解其核心逻辑。

设定：隐藏状态 θ_t 满足一阶自回归过程，观测信号 s_t 带有误差。

状态方程（State transition）：

$$\theta_{t+1} = \rho\theta_t + \varepsilon_{t+1}, \quad \varepsilon_{t+1} \sim \mathcal{N}(0, \tau_\theta^{-1})$$

观测方程（Measurement equation）：

$$s_t = \theta_t + \eta_t, \quad \eta_t \sim \mathcal{N}(0, \tau_s^{-1})$$

其中：

- τ_θ 表示状态方程噪声的精度（precision）；
- τ_s 表示观测信号的精度；
- 求此时的 Kalman 滤波更新公式

一维状态下的 Kalman Filter：均值更新公式

我们使用递推方式估计状态变量 θ_t 的条件期望 $\hat{\theta}_t$：

状态均值更新公式：

$$\hat{\theta}_{t+1} = \rho\hat{\theta}_t + K_t(s_t - \hat{\theta}_t)$$

解释：

- 第一项 $\rho\hat{\theta}_t$ 是对 θ_{t+1} 的先验预测；
- 第二项是**观测误差**，反映预测与信号之间的差异；
- K_t 为 Kalman 增益（Kalman gain），决定我们对数据修正的强度。

Kalman 增益：信号的信任程度如何影响修正强度？

Kalman 增益为：

$$K_t = \rho \cdot \frac{\tau_s}{\hat{\Sigma}_t^{-1} + \tau_s}$$

解释：

- $\hat{\Sigma}_t^{-1}$ 是状态估计的先验精度——总预测误差精度；
- τ_s 是观测信号的精度；
- 在 $\rho > 0$ 下，信号越精确，$\tau_s \uparrow \Rightarrow K_t \uparrow$；
- 若 $\hat{\Sigma}_t^{-1} \to 0$（完全不确定），则当期更新权重趋于 1，下一期预测趋于 ρs_t。

问题：

$\Rightarrow$ 思考：$\hat{\Sigma}_t^{-1}$ 是预测精度，而 τ_θ 是状态扰动精度，二者为何不同？

$\Rightarrow$ 如果信号噪声极大（$\tau_s \to 0$），K_t 会趋向于？

Kalman Filter：方差更新公式

状态方差更新公式：

$$\hat{\Sigma}_{t+1} = \rho^2 \cdot \left(\frac{1}{\hat{\Sigma}_t^{-1} + \tau_s} \right) + \frac{1}{\tau_\theta}$$

解释：

- 在用 Kalman 滤波时，既依赖自己的信念（先验），也会观察新的市场价格（信号），于是：
- 当前信念的置信度 $= \hat{\Sigma}_t^{-1}$——之前的信念有多准
- 新观察的置信度 $= \tau_s$——新来的信号有多准
- 系统噪声产生了额外的不确定性 $= \frac{1}{\tau_\theta}$

总结

贝叶斯思想下，Kalman 滤波就是递归地整合 你原来有多自信和新消息有多可靠，从而不断更新你的估计值和不确定性。

案例：预测宏观经济变量

- **背景**：一个宏观经济学家想要预测一个国家当季的 GDP 增长率 θ_t。
- **状态方程**：经济学家相信 GDP 增长率服从一个简单的自回归 AR(1) 过程：

$$\theta_{t+1} = \rho\theta_t + \epsilon_{t+1}, \quad \epsilon_{t+1} \sim \mathcal{N}(0, \sigma_\epsilon^2)$$

- **观测方程**：他每个季度可以得到一个 GDP 的初步估计 s_t，这个估计是有误差的：

$$s_t = \theta_t + \eta_t, \quad \eta_t \sim \mathcal{N}(0, \sigma_\eta^2)$$

案例：预测宏观经济变量

- **背景**：一个宏观经济学家想要预测一个国家当季的 GDP 增长率 θ_t。
- **状态方程**：经济学家相信 GDP 增长率服从一个简单的自回归 AR(1) 过程：

$$\theta_{t+1} = \rho\theta_t + \epsilon_{t+1}, \quad \epsilon_{t+1} \sim \mathcal{N}(0, \sigma_\epsilon^2)$$

- **观测方程**：他每个季度可以得到一个 GDP 的初步估计 s_t，这个估计是有误差的：

$$s_t = \theta_t + \eta_t, \quad \eta_t \sim \mathcal{N}(0, \sigma_\eta^2)$$

- **如何估计?**

1. **先验**：在第一季度开始时，他有一个关于 GDP 增长率的先验信念（均值和方差）。
2. **预测**：他使用上一季度后验和状态方程预测当前季度的 GDP 增长率。
3. **更新**：当他得到第一季度的初步 GDP 数据 s_1 时，他用卡尔曼滤波公式将这个数据与他的预测相结合，得到一个更新后的更精确的 GDP 增长率信念。
4. **重复**：他不断重复这个过程，每当得到新的数据，就更新他的信念，从而动态地追踪 GDP 增长率的真实值。

案例：金融市场中如何动态估计股票内在价值？

- **背景**：假设你是一名投资者，想要估计某只股票的“内在价值”θ_t，但你只能观察到市场价格 s_t，而市场价格受到噪声和短期情绪影响。
- **状态方程**：股票的内在价值随时间缓慢变化，可建模为：

$$\theta_{t+1} = \theta_t + \epsilon_{t+1}, \quad \epsilon_{t+1} \sim \mathcal{N}(0, \tau_\theta^{-1})$$

- **观测方程**：市场价格为内在价值加上市场噪声：

$$s_t = \theta_t + \eta_t, \quad \eta_t \sim \mathcal{N}(0, \tau_s^{-1})$$

- **问题**：如果你认为市场价格的噪声很大（$\tau_s \to 0$），你会更相信自己的预测还是市场价格？如果噪声很小呢？

案例：金融市场中如何动态估计股票内在价值？

- **背景**：假设你是一名投资者，想要估计某只股票的“内在价值”θ_t，但你只能观察到市场价格 s_t，而市场价格受到噪声和短期情绪影响。
- **状态方程**：股票的内在价值随时间缓慢变化，可建模为：

$$\theta_{t+1} = \theta_t + \epsilon_{t+1}, \quad \epsilon_{t+1} \sim \mathcal{N}(0, \tau_\theta^{-1})$$

- **观测方程**：市场价格为内在价值加上市场噪声：

$$s_t = \theta_t + \eta_t, \quad \eta_t \sim \mathcal{N}(0, \tau_s^{-1})$$

- **问题**：如果你认为市场价格的噪声很大（$\tau_s \to 0$），你会更相信自己的预测还是市场价格？如果噪声很小呢？
- 每位同学模拟一轮“投资者”，每轮我公布一个“市场价格”，同学们尝试用 Kalman 滤波公式更新对 θ_t 的估计。
- 通过这个过程，你将看到如何在动态环境中利用卡尔曼滤波来持续更新对股票内在价值的估计。

案例：金融市场中如何动态估计股票内在价值?

- 初始（t=0）信号精度：$\tau_s = 1.25$
- 初始（t=0）状态精度：$\tau_\theta = 2$
- 初始（t=0）状态估计：$\hat{\theta}_0 = 100$
- 估计先验方差：$\hat{\Sigma}_0 = 5$
- 初始（t=0）市场价格：$s_0 = 100$
- Step 1, 计算 Kalman 增益：

案例：金融市场中如何动态估计股票内在价值?

- 初始（t=0）信号精度：$\tau_s = 1.25$
- 初始（t=0）状态精度：$\tau_\theta = 2$
- 初始（t=0）状态估计：$\hat{\theta}_0 = 100$
- 估计先验方差：$\hat{\Sigma}_0 = 5$
- 初始（t=0）市场价格：$s_0 = 100$
- Step 1, 计算 Kalman 增益：

$$K_0 = \frac{\tau_s}{\frac{1}{\hat{\Sigma}_t} + \tau_s} = \frac{1.25}{\frac{1}{5} + 1.25} = \frac{1.25}{0.2 + 1.25} = \frac{1.25}{1.45} \approx 0.86207$$

- Step 2, 更新状态估计：

案例：金融市场中如何动态估计股票内在价值?

- 初始（t=0）信号精度：$\tau_s = 1.25$
- 初始（t=0）状态精度：$\tau_\theta = 2$
- 初始（t=0）状态估计：$\hat{\theta}_0 = 100$
- 估计先验方差：$\hat{\Sigma}_0 = 5$
- 初始（t=0）市场价格：$s_0 = 100$
- Step 1, 计算 Kalman 增益：

$$K_0 = \frac{\tau_s}{\frac{1}{\hat{\Sigma}_t} + \tau_s} = \frac{1.25}{\frac{1}{5} + 1.25} = \frac{1.25}{0.2 + 1.25} = \frac{1.25}{1.45} \approx 0.86207$$

- Step 2, 更新状态估计：

$$\hat{\theta}_1 = \hat{\theta}_0 + K_0(s_0 - \hat{\theta}_0) = 1 \cdot 100 + 0.86207 \cdot (100 - 100) = 100$$

案例：金融市场中如何动态估计股票内在价值?

- 初始（t=0）信号精度：$\tau_s = 1.25$
- 初始（t=0）状态精度：$\tau_\theta = 2$
- 初始（t=0）状态估计：$\hat{\theta}_0 = 100$
- 估计先验方差：$\hat{\Sigma}_0 = 5$
- 初始（t=0）市场价格：$s_0 = 100$
- Step 1, 计算 Kalman 增益：

$$K_0 = \frac{\tau_s}{\frac{1}{\hat{\Sigma}_t} + \tau_s} = \frac{1.25}{\frac{1}{5} + 1.25} = \frac{1.25}{0.2 + 1.25} = \frac{1.25}{1.45} \approx 0.86207$$

- Step 2, 更新状态估计：

$$\hat{\theta}_1 = \hat{\theta}_0 + K_0(s_0 - \hat{\theta}_0) = 1 \cdot 100 + 0.86207 \cdot (100 - 100) = 100$$

- Step 3, 更新估计方差：

$$\hat{\Sigma}_1 = \rho^2 \cdot \frac{1}{\hat{\Sigma}_0^{-1} + \tau_s} + \frac{1}{\tau_\theta} = \frac{1}{0.2 + 1.25} + \frac{1}{2} = \approx 0.6897 + 0.5 = 1.1897$$

案例：金融市场中如何动态估计股票内在价值?

- 第二轮，真实市场价格：$s_1 = 110$
- Step 1, 计算 Kalman 增益：

$$K_1 = \frac{\tau_s}{\hat{\Sigma}_1^{-1} + \tau_s} = \frac{1.25}{0.8403 + 1.25} = \frac{1.25}{2.0903} \approx 0.5981$$

- Step 2, 更新状态估计：

$$\hat{\theta}_2 = \rho \cdot \hat{\theta}_1 + K_1(s_1 - \hat{\theta}_1) = 1 \cdot 100 + 0.5981 \cdot (110 - 100) = 100 + 5.981 = 105.981$$

- Step 3, 更新估计方差：

$$\hat{\Sigma}_2 = \rho^2 \cdot \left(\frac{1}{\hat{\Sigma}_1^{-1} + \tau_s} \right) + \frac{1}{\tau_\theta} = 1 \cdot \left(\frac{1}{0.8403 + 1.25} \right) + \frac{1}{2} \approx 0.9785$$

股票案例：第三轮由你完成

沿用 $\rho = 1$、$\tau_s = 1.25$、$\tau_\theta = 2$。上一轮得到 $\hat{\theta}_2 \approx 105.981$、$\hat{\Sigma}_2 \approx 0.9785$。新价格 $s_2 = 102$。请算 K_2、$\hat{\theta}_3$ 和 $\hat{\Sigma}_3$。

股票案例：第三轮由你完成

沿用 $\rho = 1$、$\tau_s = 1.25$、$\tau_\theta = 2$。上一轮得到 $\hat{\theta}_2 \approx 105.981$、$\hat{\Sigma}_2 \approx 0.9785$。新价格 $s_2 = 102$。请算 K_2、$\hat{\theta}_3$ 和 $\hat{\Sigma}_3$。

$$K_2 = \frac{1.25}{1/0.9785 + 1.25} \approx \boxed{0.5502},$$

$$\hat{\theta}_3 = 105.981 + 0.5502(102 - 105.981) \approx \boxed{103.791},$$

$$\hat{\Sigma}_3 = \frac{1}{1/0.9785 + 1.25} + \frac{1}{2} \approx \boxed{0.9402}.$$

价格下降使均值下调；预测方差由信息带来的下降与状态噪声带来的上升共同决定。

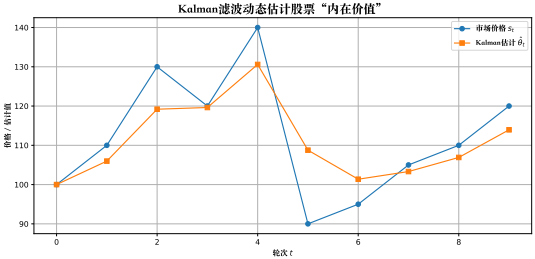


图: 卡尔曼滤波动态估计示意图（一）

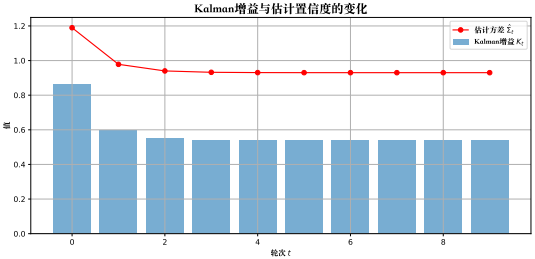


图: 卡尔曼滤波动态估计示意图（二）

总结：卡尔曼滤波的核心思想

- 卡尔曼滤波的核心思想是通过对系统状态的动态建模和对观测数据的加权融合与递归，实现对系统状态的最优估计。
- **数据作为要素：**卡尔曼滤波整合不同来源（市场价格、先验信念）和质量的数据。
- **数据质量与价值：**精度参数（τ_S）直接决定了数据的权重和价值。
- **课程价值：**上述案例将抽象的“数据要素”概念具象化为实际的金融应用。
- 这种方法充分考虑了系统模型和观测数据的不确定性，使得在面对噪声和不确定性时，依然能够做出合理的判断和决策。
- 卡尔曼滤波的应用场景非常广泛，包括但不限于金融市场、自动驾驶、机器人导航等领域。

总结：卡尔曼滤波与数据价值

- 卡尔曼滤波完美地体现了数据的价值。
- 数据价值是通过减少不确定性来体现的。在卡尔曼滤波中，这种不确定性的减少体现在方差的更新中。
- 卡尔曼增益 K_t 的大小，直接反映了新数据（信号 s_t）的价值。
- 当信号的精确度 τ_s 越高（即噪声 σ_s^2 越小），卡尔曼增益 K_t 越大。
- 这意味着，当数据更精确时，我们对其给予的权重更高，从而对信念的修正也更大。
- 卡尔曼滤波提供了一个定量框架，让我们能够精确地衡量和利用不同质量的数据，在动态环境中做出最优决策。

二、卡尔曼–布西滤波

将卡尔曼滤波从离散时间推广到连续时间，利用连续流入的数据修正状态估计

卡尔曼-布西滤波（Kalman-Bucy Filter）

- 前文我们学习了基础的卡尔曼滤波，细心的你可能会发现，它适用于离散时间动态系统。
- 和贝叶斯定律相同，连续时间动态模型中的信念更新也非常重要。
- 卡尔曼-布西滤波 (Kalman-Bucy Filter) 就是为了解决连续时间动态系统中的状态估计问题而设计的滤波技术。它由鲁道夫·卡尔曼（Rudolf E. Kalman）和理查德·布西（Richard S. Bucy）在 1961 年提出，扩展了卡尔曼滤波的离散时间框架。
- 在卡尔曼-布西滤波中，系统状态和观测数据都被建模为连续时间随机过程，通常使用随机微分方程来描述。
- 该滤波器通过最小化估计误差的均方值，递归地更新对系统状态的估计。
- 卡尔曼-布西滤波在许多领域有广泛应用，包括自动控制、信号处理、导航系统等。

从离散到连续：把“一期”切得越来越细，会怎样？

离散时间：每隔一期观察、更新一次。连续时间：让间隔 $\Delta t \to 0$，刻画状态持续变化、信念随数据流入实时更新。

先思考：一天改成四个时段，每段的变化还和一天一样大吗？

假设一天的平均变化为 a，随机扰动的标准差为 σ。把一天等分为四段，且各段扰动独立：每段的趋势变化和噪声标准差应是多少？

趋势相加：按时间长度缩小

每段趋势为 $a/4$，四段合计：

$$4 \times \frac{a}{4} = a.$$

一般地，长度为 Δt 的趋势变化为 $a\Delta t$。

独立噪声的方差相加

每段方差应为 $\sigma^2/4$，因此标准差为 $\sigma/2$：

$$4 \times \left(\frac{\sigma}{2}\right)^2 = \sigma^2.$$

一般地，标准差为 $\sigma\sqrt{\Delta t}$。

从短时段到连续时间的写法

$$\theta_{t+\Delta t} - \theta_t = a\Delta t + \sigma\sqrt{\Delta t}\varepsilon \quad \longrightarrow \quad d\theta_t = a\,dt + \sigma\,dW_t, \qquad \varepsilon \sim N(0,1).$$

dt 表示极短的时间；dW_t 表示布朗运动的微小增量，其对应的有限增量满足 $\Delta W_t \sim N(0, \Delta t)$。时间切细后，单位时间的趋势与总波动保持一致。

补充复习：维纳过程（Wiener Process）

- 维纳过程（Wiener Process），也称为标准布朗运动（Brownian Motion），是一种基础的连续时间随机过程，常记为 W_t，广泛应用于物理学、金融学和经济学等领域。
- 维纳过程 W_t 具有以下几个关键性质：
  1. $W_0 = 0$：过程从零开始。
  2. W_t 具有独立增量性：任意时间段内的增量彼此独立（未来不依赖过去）。即对于任意 $0 \leq s < t$，$W_t - W_s$ 与 W_u $(u \leq s)$ 独立。
  3. W_t 具有正态分布，增量服从正态分布，均值为 0，方差为区间长度（标准布朗运动）。对于任意 $0 \leq s < t$，$W_t - W_s \sim \mathcal{N}(0, t-s)$。
  4. W_t 具有连续路径：在时间轴上不会突然跳跃。

补充复习：维纳过程（Wiener Process）

- 维纳过程在金融学中被广泛应用于模型化股票价格、利率等金融变量的随机波动。它是布莱克-斯科尔斯模型（Black-Scholes Model）的基础。
- 通常，一个包含维纳过程 W_t 的公式常写作如下随机微分方程（SDE）：

$$X_t = \mu t + \sigma W_t$$

- 其中，μ 是漂移项（drift term，控制趋势），σ 是波动率（volatility，控制扩散速度），W_t 是维纳过程。
- 其微分形式为：

$$dX_t = \mu dt + \sigma dW_t$$

- 维纳过程的应用非常广泛，包括但不限于：
  - 金融市场中的资产定价模型（如布莱克-斯科尔斯模型）；
  - 物理学中的粒子运动模型；
  - 生物学中的种群动态模型；
  - 工程学中的噪声建模等。

一般模型：状态方程与共享噪声

- 同样，卡尔曼-布西滤波的数学设定包括两个主要的随机微分方程：状态方程和观测方程。
- **状态方程 (State Equation，不可观测)**：描述系统状态 θ_t 的动态演化：

$$d\theta_t = (a_0 + a_1\theta_t)dt + \sigma_1 dW_t + \sigma_2 dZ_t \tag{9}$$

- 其中：
  - θ_t：是我们想估计的隐藏状态（如公司真实价值、宏观因子）。
  - 假设 W_t、Z_t 独立；dW_t、dZ_t 是其增量，两个维纳过程（Wiener processes），又称：标准布朗运动（Brownian motion），即两个不同的信息源或随机扰动。
  - a_0常数漂移项：描述系统的内在趋势，是常数，代表一个不受当前状态影响的、持续的、线性的变化趋势。
  - a_1线性漂移项：描述系统的“回归均值”或“自增强”特性：描述系统的状态的变化率与其自身的大小有关，即状态越大，变化率越大（或越小），体现了系统的自增强或自抑制特性。
  - W_t：驱动隐藏状态的独立扰动，不直接进入观测噪声；
  - Z_t：既影响状态又影响信号的扰动 $\rightarrow$ 提供信息。

一般模型：观测方程

- **观测方程 (Observation Equation)，可观测**：描述我们如何通过观测数据 s_t 来获取关于 θ_t 的信息：

$$ds_t = (A_0 + A_1\theta_t)dt + \gamma dZ_t \tag{10}$$

- 其中：
  - s_t：是我们实际观测到的数据（如市场价格、经济指标）。
  - s_t 受到 θ_t 的影响（通过 A_1），也受到 dZ_t 的噪声影响
  - A_0、A_1：是观测方程的参数，描述了观测数据与隐藏状态之间的关系。
  - γ：是观测噪声的强度，反映了观测数据的不确定性。
  - dZ_t：是与观测相关的随机扰动，通常建模为标准布朗运动。

卡尔曼-布西滤波的条件均值与条件方差

- 如何在给定状态方程和观测方程前提下，估计系统状态 θ_t 的条件均值和方差？
- 条件均值（状态估计）：
$$\hat{\theta}_t = \mathbb{E}[\theta_t \mid \{s_u, u \leq t\}]$$
- 条件方差（估计的不确定性）：
$$\hat{\Sigma}_t = \mathbb{E}[(\theta_t - \hat{\theta}_t)^2 \mid \{s_u, u \leq t\}]$$
- 拓展阅读：一般公式使用投影定理与伊藤引理；课堂重点掌握独立噪声特例。方差方程是确定性的 Riccati(黎卡提) 常微分方程。

条件均值推导过程

- 记条件期望 $\hat{\theta}_t = \mathbb{E}[\theta_t \mid \mathcal{F}_t^s]$。$\mathcal{F}_t^s = (s_u, 0 \le u \le t)$ 为截至时点 t 我们知道的全部信息。
- 利用伊藤引理与投影定理，可得：

$$d\hat{\theta}_t = \mathbb{E}[d\theta_t \mid \mathcal{F}_t^s] + K_t \left(ds_t - \mathbb{E}[ds_t \mid \mathcal{F}_t^s] \right)$$

- 代入状态与信号方程，并令 Kalman 增益

$$K_t = \frac{\sigma_2 \gamma + \hat{\Sigma}_t A_1}{\gamma^2}$$

- 得到：

$$d\hat{\theta}_t = (a_0 + a_1 \hat{\theta}_t)\, dt + \frac{\sigma_2 \gamma + \hat{\Sigma}_t A_1}{\gamma^2} \Big[ds_t - (A_0 + A_1 \hat{\theta}_t) dt \Big]$$

- 进一步简化，得到条件均值的随机微分方程 SDE：

$$d\hat{\theta}_t = (a_0 + a_1 \hat{\theta}_t) dt + \frac{\sigma_2 \gamma + \hat{\Sigma}_t A_1}{\gamma^2} \big[ds_t - (A_0 + A_1 \hat{\theta}_t) dt \big] \tag{11}$$

条件方差 $\hat{\Sigma}_t$ 推导

- 条件方差定义为：

$$\hat{\Sigma}_t = \mathbb{E}[(\theta_t - \hat{\theta}_t)^2 \mid \mathcal{F}_t^s]$$

- 利用伊藤引理与状态-观测噪声协方差结构，有：

$$d\hat{\Sigma}_t = \left(2a_1\hat{\Sigma}_t + \sigma_1^2 + \sigma_2^2\right) dt - K_t^2\gamma^2\, dt$$

- 代入 K_t 表达式，得到条件方差的 Riccati 常微分方程：

$$d\hat{\Sigma}_t = \left[2a_1\hat{\Sigma}_t + \sigma_1^2 + \sigma_2^2 - \left(\frac{\sigma_2\gamma + \hat{\Sigma}_t A_1}{\gamma}\right)^2\right] dt \tag{12}$$

状态更新方程的经济直觉

$$d\hat{\theta}_t = (a_0 + a_1\hat{\theta}_t)dt + \frac{\sigma_2\gamma + \hat{\Sigma}_t A_1}{\gamma^2}\left[ds_t - (A_0 + A_1\hat{\theta}_t)dt\right]$$

- 它描述了我们对状态变量 θ_t 的最佳估计（给定信号历史 $\mathcal{F}_t^s$）是如何随时间更新的。
- 第一部分：漂移项 $(a_0 + a_1\hat{\theta}_t)dt$：如果没有任何新信息，我们的估计会按照系统本身的动态规律去自然演化。
- 第二部分：修正项 $\frac{\sigma_2\gamma+\hat{\Sigma}_t A_1}{\gamma^2}[ds_t - (A_0 + A_1\hat{\theta}_t)dt]$：当我们观察到新的信号 s_t 时，我们会根据这个信号与我们预测的差异来调整我们的估计。
- 这个修正项的大小由 Kalman 增益 $\frac{\sigma_2\gamma+\hat{\Sigma}_t A_1}{\gamma^2}$ 决定，它反映了我们对新信号的信任程度。
- 如果信号噪声 γ 很小（信号很可靠），我们会更加强调新的观测信息，从而对状态估计进行更大幅度的调整。

条件方差演化的经济直觉

$$d\hat{\Sigma}_t = \left[2a_1\hat{\Sigma}_t + \sigma_1^2 + \sigma_2^2 - \left(\frac{\sigma_2\gamma + \hat{\Sigma}_t A_1}{\gamma} \right)^2 \right] dt$$

- 它描述了我们对 θ_t 估计的不确定性（给定当前观测的后验方差）是如何随时间演化的。
- 第一部分：不确定性的自然增长 $2a_1\hat{\Sigma}_t + \sigma_1^2 + \sigma_2^2$：来自状态方程中的固有噪声（$\sigma_1, \sigma_2$）和系统动态。
- 第二部分：不确定性的减少 $\left(\frac{\sigma_2\gamma + \hat{\Sigma}_t A_1}{\gamma} \right)^2$：来自利用新观测更新估计，这正是 Kalman 滤波里的“信息增益”部分。
- 观测越精确（γ 小）或先验越不确定（$\hat{\Sigma}_t$ 大），这个项越大 $\rightarrow$ 不确定性下降得越快。
- 这是一个信号-噪声权衡过程：系统动态增加不确定性，观测信息减少不确定性。

特殊设定：无漂移布朗运动（Driftless BM）

基础设定：状态与信号

$$d\theta_t = \sigma\, dW_t, \qquad ds_t = \theta_t\, dt + \gamma\, dZ_t,$$

其中 W_t, Z_t 为独立 Wiener 过程。

- 状态是随机游走（连续时间版的随机游走），无漂移 (指方程中的漂移项 adt 不存在，即 $a = 0$)，其运动纯粹是随机的，变化完全由噪声项决定；
- 信号以 θ_t 为漂移并叠加观测噪声（波动率 γ)；
- 该设定对应一般 Kalman–Bucy 中 $a_0 = a_1 = \sigma_2 = 0,\ A_1 = 1$。

无漂移特例：代入一般公式

Kalman 增益

一般式 $K_t = \dfrac{\sigma_2\gamma + \hat{\Sigma}_t A_1}{\gamma^2}$，在本特例为

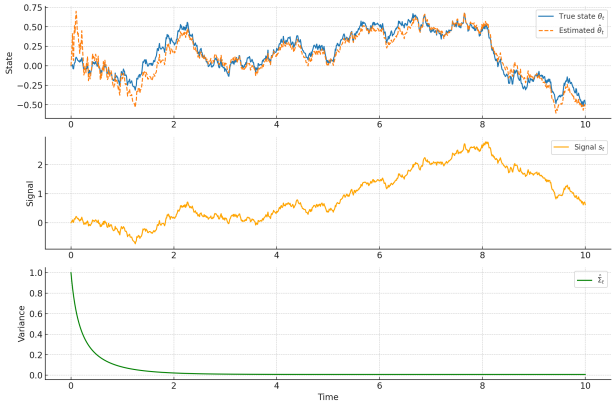
$$K_t = \frac{\hat{\Sigma}_t}{\gamma^2}.$$

创新过程

$$d\widehat{W}_t \equiv \gamma^{-1}\big(ds_t - \hat{\theta}_t\,dt\big), \quad \mathbb{E}[d\widehat{W}_t \mid \mathcal{F}_t^s] = 0, \quad d\langle \widehat{W}\rangle_t = dt.$$

结论

$$\boxed{d\hat{\theta}_t = \frac{\hat{\Sigma}_t}{\gamma}\,d\widehat{W}_t}, \qquad \boxed{d\hat{\Sigma}_t = \left(\sigma^2 - \frac{\hat{\Sigma}_t^2}{\gamma^2}\right)dt}.$$



- 蓝色：真实状态 θ_t
- 橙色虚线：估计值 $\hat{\theta}_t$，快速跟踪真实值
- 绿色：估计方差 $\hat{\Sigma}_t$；图中初值高于稳态，因而随时间下降
- 观测信号 s_t 受噪声影响，但仍为状态提供关键信息

长期性质：方程稳态

由 $d\hat{\Sigma}_t/dt = \sigma^2 - \hat{\Sigma}_t^2/\gamma^2$ 在稳态下，其不再变化，为 0。得到稳态：

$$\hat{\Sigma}_\infty = \lim_{t\to\infty} \hat{\Sigma}_t = \begin{cases} 0, & \sigma^2 = 0 \text{ (学习固定参数)}, \\ \sigma\gamma, & \sigma > 0 \text{ (随机游走状态)}. \end{cases}$$

含义：

- 随机游走存在不可消除的不确定性，稳态误差 $\propto$ 状态波动 σ 与观测噪声 γ 的乘积。
- 后验方差 $\hat{\Sigma}_\infty$ 通常被称：长期可学性（long-run learnability）：当观测时间趋向无穷时，代理人最终能够把未知状态估计得多精确。
- 它刻画了一个学习的上限：无论数据收集多久、算法多聪明，最终你只能把不确定性降到 $\hat{\Sigma}_\infty$ 这个水平。
- 在政策或运营决策中，如果希望长期预测或控制更准确，就必须降低 σ（系统本身波动）或 γ（提高数据质量）。

课堂练习：学习中的方差一定下降吗？

设 $\sigma = 0.5$、$\gamma = 2$，于是

$$\dot{\hat{\Sigma}}_t = 0.25 - \frac{\hat{\Sigma}_t^2}{4}, \qquad \hat{\Sigma}_\infty = \sigma\gamma = 1.$$

若初值 $\hat{\Sigma}_0$ 分别为 0.5 和 2，方差最初怎样变化（求 $\dot{\hat{\Sigma}}_0$）？

课堂练习：学习中的方差一定下降吗？

设 $\sigma = 0.5$、$\gamma = 2$，于是

$$\dot{\hat{\Sigma}}_t = 0.25 - \frac{\hat{\Sigma}_t^2}{4}, \qquad \hat{\Sigma}_\infty = \sigma\gamma = 1.$$

若初值 $\hat{\Sigma}_0$ 分别为 0.5 和 2，方差最初怎样变化（求 $\dot{\hat{\Sigma}}_0$）？

$$\hat{\Sigma}_0 = 0.5: \quad \dot{\hat{\Sigma}}_0 = 0.25 - 0.0625 = \boxed{0.1875 > 0},$$

$$\hat{\Sigma}_0 = 2: \quad \dot{\hat{\Sigma}}_0 = 0.25 - 1 = \boxed{-0.75 < 0}.$$

答案

方差低于稳态时上升，高于稳态时下降。持续学习消除不确定性，但状态自身也持续产生新的不确定性。

为什么需要用 Kalman–Bucy model 建模数据要素？

数据要素的价值 = 不确定性减少

- **状态**（不可直接观测）用 θ_t 记； **数据/信号**用 s_t 记。
- 数据产生价值的核心：通过**滤波/更新**把先验不确定性降低为后验不确定性。

现实数据特征与理论模型的对齐

- 数据要素：数据质量（低 γ）；
- 数据新鲜度：高采样频率；
- 在理论上把数据 $\rightarrow$ 不确定性减少 $\rightarrow$ 决策价值贯穿起来。

案例 1：城市温度的连续估计（传感器部署）

场景

- 城市物联网部署若干温度传感器（**数据要素资源**）。
- 真实温度 θ_t 随时间随机波动：$d\theta_t = \sigma dW_t$。
- 传感器上报 $ds_t = \theta_t dt + \gamma dZ_t$，$\gamma$ 反映传感器噪声/标定水平。

运营决策

- 选择更高精度传感器（降 γ），或增加采样频率（增 数据新鲜度）。
- 价值衡量：稳态方差 $\hat{\Sigma}_\infty = \sigma\gamma$ 的**下降**可换算为节能与服务质量收益。

问题

- 若 $\sigma = 0.8$（城市天气多变），$\gamma \in \{0.2, 0.5\}$。哪种传感器长期更值钱？为什么？
- 若每降低 0.1 方差的货币化收益为 500 万元，那么更换传感器的收益增量是多少？当其价格区间是如何时更换更划算？

设定（Driftless BM 特例）

稳态后验方差（不确定性）：

$$\boxed{\hat{\Sigma}_\infty = \sigma\gamma} \qquad (\sigma > 0)$$

给定：$\sigma = 0.8$、$\gamma \in \{0.2, 0.5\}$。

数值计算

低噪声传感器（$\gamma = 0.2$）：

$$\hat{\Sigma}_\infty^{(0.2)} = 0.8 \times 0.2 = 0.16$$

高噪声传感器（$\gamma = 0.5$）：

$$\hat{\Sigma}_\infty^{(0.5)} = 0.8 \times 0.5 = 0.40$$

更值钱：低噪声传感器（$\gamma = 0.2$），因为 $\hat{\Sigma}_\infty$ 更小。

结论与运营收益

若每降低 0.1 方差的货币化收益为 R：

$$\text{收益增量} = \frac{0.24}{0.1} \times R = 2.4R$$

（例如 $R = 500$ 万元，则提升 $= 1200$ 万元/周期）

数据新鲜度（为何同样重要）

- **含义**：观测更新越频繁，数据越“新”。可减少预测滞后。
- **效果**：在每条测量噪声固定且相互独立的离散采样模型中，更高频率 f 可近似降低有效噪声 $\gamma_{\text{eff}}^2 \propto \gamma^2/f$，从而 $\hat{\Sigma}_\infty \downarrow$.
- **实践**：提高采样频率或多源融合（等效降噪）都能提升价值。

案例 2：股票“趋势回报率”的在线学习（量化研究）

设定与数据要素

- **状态**：日内趋势回报率 θ_t，$d\theta_t = \sigma dW_t$。
- **观测**：价格变动的信号 $ds_t = \theta_t dt + \gamma dZ_t$（含撮合噪声/冲击）。
- **数据要素投入**：提高盘口级数据质量（降 γ），或融合关于同一状态的独立有效信号（降低有效噪声）。

课堂练习

- 已知历史估计方差 $\hat{\Sigma}_t = 0.6$，$\gamma = 0.9$。求当期均值更新强度。
- 若升级数据系统把 γ 降为 0.6，增益多少？长期 $\hat{\Sigma}_\infty$ 下降几何？
- 讨论：为什么**降** γ 同时会提升当日的更新速度与长期的可学性？

案例 2 答案

(1) 当期均值更新强度（标准化创新的系数）

$$\boxed{\mathsf{Gain}_t = \frac{\hat{\Sigma}_t}{\gamma}} \quad \Rightarrow \quad \frac{0.6}{0.9} = 0.667.$$

(2) 升级数据系统：$\gamma : 0.9 \to 0.6$

当期增益变化：

$$\mathsf{Gain}_t^{\mathsf{new}} = \frac{\hat{\Sigma}_t}{0.6} = \frac{0.6}{0.6} = 1.000.$$

长期稳态不确定性（后验方差极限）：

$$\boxed{\hat{\Sigma}_\infty = \sigma\gamma} \quad \Rightarrow \quad \hat{\Sigma}_\infty^{\mathsf{old}} = \sigma \times 0.9, \quad \hat{\Sigma}_\infty^{\mathsf{new}} = \sigma \times 0.6.$$

$$\text{绝对下降} = \sigma(0.9 - 0.6) = 0.3\sigma, \qquad \text{相对下降} = \frac{0.3}{0.9} = 33.3\%.$$

案例 2 答案

(3) 经济学直觉（为什么降 γ 同时提升“当日更新”和“长期可学性”?）

- 当期：$\text{Gain}_t = \hat{\Sigma}_t/\gamma \uparrow$（$\gamma \downarrow$） $\Rightarrow$ 更快吸收“新信息”（创新项）。
- 长期：$\hat{\Sigma}_\infty = \sigma\gamma \downarrow$（$\gamma \downarrow$） $\Rightarrow$ 稳态不确定性更低，可学性更强。

可选数值示例（若取 $\sigma = 0.8$）

$$\hat{\Sigma}_\infty^{\text{old}} = 0.8 \times 0.9 = 0.72, \quad \hat{\Sigma}_\infty^{\text{new}} = 0.8 \times 0.6 = 0.48, \quad \Delta = 0.24\ (\downarrow 33.3\%).$$

案例 3：央行估计潜在增长

设定

- 潜在增长率 θ_t：$d\theta_t = \sigma dW_t$（受技术与结构性冲击）。
- 高频指标信号：$ds_t = \theta_t dt + \gamma dZ_t$（PMI、工业用电、互联网搜索等）。

问题：数据要素投向何处？

- 有同等预算用于“改善统计口径（降 γ）”与“稳定结构（降 σ）”，你选谁？
- 给出理由：先比较两者的弹性，再比较每元预算可实现的百分比改善。

解析：对 $\hat{\Sigma}_\infty$ 的弹性

$$d\hat{\Sigma}_\infty = \gamma\, d\sigma + \sigma\, d\gamma \quad \Rightarrow \quad \frac{d\hat{\Sigma}_\infty}{\hat{\Sigma}_\infty} = \frac{d\sigma}{\sigma} + \frac{d\gamma}{\gamma}.$$

结论： 在“同百分比改善”下，降低 σ 与降低 γ 对 $\hat{\Sigma}_\infty$ 的百分比影响相同。
$\Rightarrow$ 应选择**单位预算能带来更大百分比下降**的一方（性价比高者）。

数值举例：

初始 $\sigma_0 = 0.6,\ \gamma_0 = 0.8 \Rightarrow \hat{\Sigma}_{\infty,0} = 0.48.$
方案 A（数据要素）：$\gamma \downarrow 25\% \Rightarrow 0.6 \Rightarrow \hat{\Sigma}_\infty = 0.36$ $(\downarrow 25\%)$。
方案 B 的相同预算（稳结构）：$\sigma \downarrow 10\% \Rightarrow 0.54 \Rightarrow \hat{\Sigma}_\infty = 0.432$ $(\downarrow 10\%)$。
$\Rightarrow$ **优先方案 A**（同预算带来更大稳态方差下降）。

政策含义

$\sigma\downarrow$：结构更稳、潜在增长“更慢变”，便于被学到。
$\gamma\downarrow$：统计更准，政策滞后更小。
实际选择取决于每 1 元预算带来的 $\%\sigma$ 或 $\%\gamma$ 降幅。

三、带跳跃的卡尔曼–布西滤波

在连续学习过程中加入突发冲击与重大信息，刻画不确定性的瞬时跳升或下降

带跳跃的卡尔曼-布西滤波

- 在实际应用中，很多动态系统会受到突发事件的影响，这些事件会导致状态或观测数据发生跳跃。
- 在标准模型中，后验方差 $\hat{\Sigma}_t$ 会随着时间平滑收敛到一个稳态值（或持续下降），无法表现不确定性的突变。
- 真实世界中，不确定性往往呈现跳跃状变化：会因为突发事件（政策、战争、危机）瞬间变大；会因为关键数据的发布（普查、财报、审计）瞬间下降
- 例如，金融市场中的突发新闻、自然灾害、政策变动等都可能导致系统状态发生剧烈变化。
- 为了处理这种情况，卡尔曼-布西滤波可以扩展为带跳跃的版本。

带跳跃的卡尔曼-布西滤波

- 在带跳跃的卡尔曼-布西滤波中，状态方程和观测方程仍然保持不变，但需要引入一个跳跃过程来描述突发事件对系统状态的影响。
- 引入 jump 的作用：
  1. 捕捉突发信息事件：Upward jumps 模拟大小未知的状态冲击：不确定性立即上升，随后逐渐被新数据消化。Downward jumps 模拟额外的高质量数据发布：不确定性瞬间下降到接近零，然后又慢慢累积。
  2. 丰富稳态行为：引入 jump 后，$\hat{\Sigma}_t$ 不再是固定平滑路径，而是稳定地在一个分布内波动，可解释稳态下的横截面异质性。
  3. 增加模型现实性：贴合经济金融中观察到的周期性不确定性模式（uncertainty cycles）。
- 如何为突然的跳跃建模？

跳跃与泊松分布

- 回忆：泊松分布（Poisson）是一种用来描述“在固定时间或空间内，某件事情发生次数”的概率分布。它特别适合用来处理那些发生概率小、但机会很多的随机事件。
- 假设你开了一家咖啡店，平均每天有 3 位顾客在上午 10 点到 11 点之间进店。虽然每天人数可能不一样——有时 1 人，有时 5 人——但长期平均是 3 人。那么，泊松分布就可以帮你回答这样的问题：
- 今天上午 10 点到 11 点，恰好有 4 位顾客进店的概率是多少？
- 如果一个事件平均发生 λ 次，那么它恰好发生 k 次的概率是：

$$P(k) = \frac{e^{-\lambda}\lambda^k}{k!}$$

- 泊松分布就是用来预测“稀有但重复机会多”的事件发生次数的概率工具。

向上跳跃（Upward Uncertainty Cycles）

模型设定，参考 Baley and Blanco (2019)：

- 状态（跳跃过程）：
$$d\theta_t = \sigma_f \, dW_t + \sigma_u u_t \, dQ_t,$$
- 其中，Q_t 是强度为 λ 的 Poisson 过程，可以理解为突发事件到来的速率。
- 冲击发生时刻 Q_t 可观测，冲击大小 $u_t \sim N(0,1)$ 不可观测，且独立于已有信息。
- σ_u 控制每次冲击对状态的影响幅度，即冲击的强度（跳跃的大小）。
- 信号观测为：
$$ds_t = \theta_t \, dt + \gamma \, dZ_t.$$

向上跳跃的滤波方程

后验均值更新：

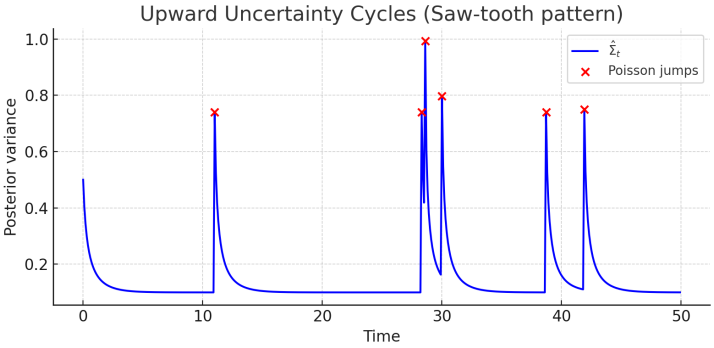
$$d\hat{\theta}_t = \frac{\hat{\Sigma}_t}{\gamma}\, d\hat{Z}_t$$

后验方差更新：

$$d\hat{\Sigma}_t = \left(\sigma_f^2 - \frac{\hat{\Sigma}_t^2}{\gamma^2}\right) dt + \sigma_u^2\, dQ_t.$$

- 冲击到达瞬间，均值不跳跃，方差跳升；日常均值仍随观测更新。
- 需要注意的是：这里的跳跃是指后验方差的跳跃，而非均值的跳跃。
- $\sigma_u^2\, dQ_t$：当 Poisson 冲击到来时，方差瞬间增加 σ_u^2。
- 两次跳跃间，方差向 $\sigma_f\gamma$ 收敛；高于该值时下降。

向上跳跃的直观图示



- 蓝线：后验方差 $\hat{\Sigma}_t$。
- 红点：Poisson 冲击发生点。
- “锯齿”模式：突升—衰减—再突升

思考

- 若 λ 提高（泊松均值参数——跳跃更频繁），长期稳态方差分布会如何变化？为什么？
- 如果 σ_u 很大，Poisson 冲击对学习速度与预测精度的影响是什么？
- 结合现实案例：在经济预测、金融市场、物联网监测中，向上跳跃对应的场景有哪些？

参考答案

- 若 λ 提高（跳跃更频繁），长期稳态方差会增大。因为更多的跳跃意味着更多的突发事件，这些事件会导致不确定性频繁上升，从而使得整体的不确定性水平提高。
- 如果 σ_u 很大 $\rightarrow$ 跳跃幅度剧烈 $\rightarrow$ 预测误差上升，同时增益 $\hat{\Sigma}_t/\gamma$ 增大，对新证据的即时响应更强。恢复到给定精度通常需要更多信息，不能简单说增益变小或学习速度变慢。
- 向上跳跃不是简单的数学技巧，而是对现实世界中“非连续性、突发性、破坏性”事件的建模工具。
  - 经济预测：自然灾害、政治危机、战争等突发事件。
  - 金融市场：突发新闻、监管变动、市场崩盘等。
  - 物联网监测：设备故障、网络攻击等突发事件。

向下跳跃（Downward Uncertainty Cycles）

- 向下跳跃意味着什么？——方差突然减少（不确定性降低）
- **潜在状态（连续时间扩散）**：
$$d\theta_t = \sigma_f \, dW_t, \qquad W_t \text{ 是 Wiener 过程}$$
- **日常观测信号（含噪）**：
$$ds_t = \theta_t \, dt + \gamma \, dZ_t, \qquad Z_t \text{ 是 Wiener 过程}$$
- 基本状态方程和观测方程不变，变化的是信息结构：
- 平时看到的是噪声信号 s_t；但有一个泊松过程，即完美信息的泊松到达：$\tilde{Q}_t$。强度 λ ——它代表“高质量信息突然到来”的时刻。
  - 当 $d\tilde{Q}_t = 1$ 时，代理人瞬时看到真实状态（一次性极其高质量的数据包）。
  - 其他时刻仅能看到噪声信号 s_t。
- 信息集包含日常信号、到达时刻，以及到达时揭示的真实状态。

完美信息到达：均值跳到真值，方差归零

令 N_t 为可观测的信息到达计数过程。到达时真实状态 θ_t 被揭示：

$$\hat{\theta}_t = \theta_t, \qquad \hat{\Sigma}_t = 0.$$

因此，采用跳前值表示的滤波方程为

$$d\hat{\theta}_t = \frac{\hat{\Sigma}_{t-}}{\gamma}\, d\hat{Z}_t + (\theta_t - \hat{\theta}_{t-})\, dN_t,$$

$$d\hat{\Sigma}_t = \left(\sigma_f^2 - \frac{\hat{\Sigma}_{t-}^2}{\gamma^2}\right) dt - \hat{\Sigma}_{t-}\, dN_t.$$

- 信息集包括日常信号、到达时刻及到达时揭示的状态值。
- 完美信息使方差当场归零；随后状态继续变化，方差又逐渐累积。
- 若只得到含噪数据，方差会下降，但通常不会归零。

向上跳跃案例：不确定性突然增加

场景：

- 你是一家投资公司的分析师，跟踪科技企业的创新能力 θ_t。
- 平时通过市场新闻与研发数据更新估计，不确定性缓慢下降。
- **突然**：媒体爆出该公司进军全新领域（量子计算芯片）。
- 由于缺乏先验知识，不确定性立即上升——这是 **向上跳跃**。

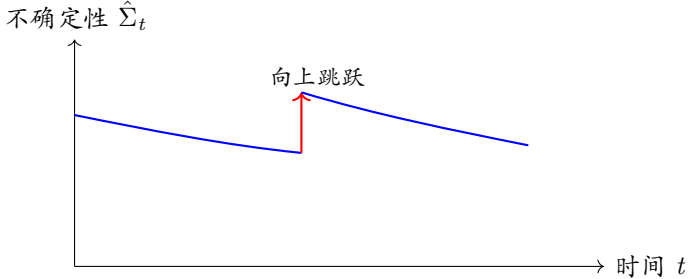
公式：

$$\hat{\Sigma}_t = \hat{\Sigma}_{t-} + \sigma_u^2$$

其中 $\hat{\Sigma}_{t-}$ 为跳前方差，σ_u^2 为不可观测冲击大小的方差。

问题： 跳前 $\hat{\Sigma}_{t-} = 0.2$，$\sigma_u^2 = 0.1$，跳后方差是多少？

向上跳跃示意图



- 跳跃发生在新闻发布的瞬间，跳后方差等于跳前方差加上冲击方差 σ_u^2。
- 已知：$\hat{\Sigma}_{t-} = 0.2, \quad \sigma_u^2 = 0.1$,
- 则：$\hat{\Sigma}_t = 0.2 + 0.1 = 0.3$
- 结果：跳后方差为 0.3（比跳前增加了 50%）。

课堂练习：高质量信息与完美信息有什么区别？

跳前信念为 $\theta_t \mid \mathcal{I}_{t-} \sim N(10, 0.5)$。一份独立审计给出 $y = \theta_t + \epsilon$，$\epsilon \sim N(0, 0.125)$，读数 $y = 11$。

1. 求观测权重、跳后均值和方差。
2. 如果审计完美揭示 $\theta_t = 11$，结果如何（卡尔曼增益公式）？

课堂练习：高质量信息与完美信息有什么区别？

跳前信念为 $\theta_t \mid \mathcal{I}_{t-} \sim N(10, 0.5)$。一份独立审计给出 $y = \theta_t + \epsilon$，$\epsilon \sim N(0, 0.125)$，读数 $y = 11$。

1. 求观测权重、跳后均值和方差。
2. 如果审计完美揭示 $\theta_t = 11$，结果如何（卡尔曼增益公式）？

$$b = \frac{0.5}{0.5 + 0.125} = 0.8, \quad \hat{\theta}_t = 10 + 0.8(11 - 10) = \boxed{10.8},$$

$$\hat{\Sigma}_t = (1 - 0.8)0.5 = \boxed{0.1}.$$

完美揭示时：$\hat{\theta}_t = \boxed{11}$，$\hat{\Sigma}_t = \boxed{0}$。

现实联系

审计报告、普查与临床检测通常属于含噪信息；“完美揭示”是帮助理解机制的极端情形。

四、伯努利随机变量的连续时间滤波

当隐藏状态只有“高/低”或“成功/失败”时，根据连续信号实时更新其后验概率

二元隐藏状态与连续观测

项目质量固定但未知：$\theta \in \{\theta^H, \theta^L\}$，$\theta^H > \theta^L$。

$$p_0 = \Pr(\theta = \theta^H), \qquad ds_t = \theta\, dt + \gamma\, dZ_t.$$

隐藏状态是二元的，累计观测信号是连续的。例如产品质量只有高低两种，但订单和试用表现可以持续提供证据信号。

$$\hat{p}_t = \Pr(\theta = \theta^H \mid \mathcal{F}_t^s), \qquad \hat{\theta}_t = \hat{p}_t \theta^H + (1 - \hat{p}_t)\theta^L.$$

p_0 是给定的先验概率，$\hat{p}_t$ 是学习后的后验概率。

先预测信号，再提取创新

$$d\hat{Z}_t = \frac{ds_t - \hat{\theta}_t dt}{\gamma}, \qquad \hat{\theta}_t = \hat{p}_t \theta^H + (1 - \hat{p}_t)\theta^L.$$

在观测信息集下，$\hat{Z}_t$ 是标准布朗运动。因此：

$$ds_t = \hat{\theta}_t dt + \gamma \, d\hat{Z}_t.$$

两个表示对应两个视角

真实信号由 θ 驱动；观测者的预测由 $\hat{p}_t$ 驱动。用条件均值替换真实状态时，噪声也应换成创新过程。

二元学习：更新系数与条件方差

令 $h=(\theta^H-\theta^L)/\gamma$，则

$$\boxed{d\hat{p}_t = h\hat{p}_t(1-\hat{p}_t)\,d\hat{Z}_t}.$$

三个量必须区分

$$\mathrm{Var}(\mathbf{1}_{\{\theta=\theta^H\}} \mid \mathcal{F}_t^s) = \hat{p}_t(1-\hat{p}_t),$$
$$\mathrm{Var}(\theta \mid \mathcal{F}_t^s) = (\theta^H-\theta^L)^2\hat{p}_t(1-\hat{p}_t).$$

信念波动系数为 $h\hat{p}_t(1-\hat{p}_t)$，它不等于状态条件方差。

给定同一个 $\hat{p}_t$，降低 γ 不会当场改变状态方差，却提高随后的证据响应强度。

课堂练习：一条新证据会使人更不确定吗？

设 $\theta^H = 1$、$\theta^L = 0$、$\gamma = 2$，因此 $h = 0.5$。

1. $\hat{p}_t = 0.5$ 时，状态条件方差和信念波动系数分别是多少？
2. $\hat{p}_t = 0.25$ 时，两者分别是多少？
3. 一条反向证据使信念从 0.9 变成 0.6，不确定性如何变化？

请分别计算。

练习答案：当前不确定性与未来学习

$$p=0.5:\quad \mathrm{Var}(\theta\mid\mathcal{F})=\boxed{0.25},\quad hp(1-p)=\boxed{0.125};$$

$$p=0.25:\quad \mathrm{Var}(\theta\mid\mathcal{F})=\boxed{0.1875},\quad hp(1-p)=\boxed{0.09375}.$$

反向证据使方差从 $0.9\times0.1=0.09$ 上升到 $0.6\times0.4=0.24$。

为什么不矛盾？

这次证据削弱了原本的自信。按总方差定律，给定当前信息，未来后验方差的期望不超过当前方差；单条路径可以上升，平均意义上学习减少不确定性。

数据质量、数量与新鲜度

- 质量：降低单个观测的噪声 γ，提高状态分辨率。
- 数量：增加关于同一状态的独立有效信号，提高总信息精度；复制同一记录不增加独立证据。
- 新鲜度：对变化中的状态缩短数据延迟，减少预测滞后。

适用边界

$h = (\theta^H - \theta^L)/\gamma$ 不是样本量。在给定连续观测模型中，仅把同一路径切成更多时间点，并不会自动增加信息；须说明新增独立测量、额外渠道或更低噪声。

全讲总结（一）：从静态贝叶斯到动态信念更新

共同问题：状态不可直接观测，如何随数据到来持续学习？

已有信念 $\longrightarrow$ 预测信号 $\longrightarrow$ 识别创新（观测偏差）$\longrightarrow$ 更新信念

模型	新增的现实特征	需要追踪什么？
卡尔曼滤波	状态按期变化，数据分批到来	观测前预测、观测后均值与方差，再预测下一期
卡尔曼–布西滤波	状态与数据在连续时间中演化	条件均值与方差的连续变化
带跳跃的扩展	未知冲击或额外信息突然到达	跳前与跳后信念；冲击大小和信息质量
二元状态滤波	隐藏状态只有高、低两种	高状态后验概率 $\hat{p}_t$ 及其对应的条件方差

贯穿全讲的区别

均值回答“我认为状态是多少”；方差回答“我对这个判断有多不确定”。数据可能只增强信心，而不改变均值。

全讲总结（二）：三个结论与应掌握的计算

1. **新信息如何改变判断？** 更新取决于创新项与增益：

$$\hat{\theta}_{t+1} = D\hat{\theta}_t + K_t(s_t - G\hat{\theta}_t).$$

这里已合并当期更新与下一期预测；一维 AR(1) 中 $K_t = \rho\beta_t$。

2. **为什么持续学习仍会有不确定性？** 状态变化不断引入新误差，观测不断消除误差。无漂移特例中：

$$\frac{d\hat{\Sigma}_t}{dt} = \sigma^2 - \frac{\hat{\Sigma}_t^2}{\gamma^2}, \qquad \hat{\Sigma}_\infty = \sigma\gamma \quad (\sigma, \gamma > 0).$$

3. **更多数据是否总让人更确定？** 固定状态的后验方差在条件期望意义上下降，但单次反向证据可能增加犹豫；未知状态冲击也会提高方差。

学完本讲，应能独立完成

算一轮“增益—均值更新—方差更新—下一期预测”；判断方差向稳态上升还是下降；区分冲击与信息到达、状态方差与信念波动系数。

数据价值：提高有效精度、缩短信息延迟，进而改善判断与决策。